






中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生数学建模竞赛

学　　校	XX大学
参赛队号	26XXXXXXXXX
队员姓名	1. XXX
	2. XXX
	3. XXX

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题　　目　面向局部模态缺失的多模态情感预测与证据追溯

摘　　要：

真实视频里，文本、声音和画面并不总能同时观测，情感判断还需要能回到原始素材上核对。本文把三问当成一条链：构造可反查的特征，在局部缺失下预测情感，再给出可回溯的解释。

针对问题一，我们用 WhisperX 对给定转写做强制对齐得到词级时间，把 BERT 子词、openSMILE 声学帧和 OpenFace 人脸动作单元帧按词时间窗对齐池化，得到 768、25、35 维特征，每个位置都能反查到原词、秒数和帧号。100 条全部保留：77 条正常、19 条需复核、4 条找不到达标的人脸帧；文本 100 条可用，声学、视觉各 92 条可用。人工核验的 583 个词全部通过。

针对问题二，我们把补齐填充、原生不可观测、人为遮蔽三种零值分开记录，建立掩码感知的池化双头模型 PM-B2，同时输出类别和强度。在 7 种遮蔽组合、3 种比例、3 种位置构成的 63 档缺失面板上，三种子平均 macro-F1 为 0.5752±0.0013、MAE 为 0.6213±0.0123，均优于 7 个基线；测试集完整输入 macro-F1 为 0.6147、MAE 为 0.6485。遮蔽含文本时 F1 比只遮蔽声学或视觉低约 0.04，缺失比例从 10% 增至 50% 时 F1 由 0.5905 降到 0.5595，位置的影响在验证集上不到 0.005。主要错误在中性类，测试集中性召回仅 0.361。另做的 15 种改进配置中，完整输入 F1 最高达 0.6244，但在更严格的整模态压力面板上只有 0.4139，故未替换正式模型。附件 3 的 30 条预测为正向 14、中性 10、负向 6 条。

针对问题三，我们固定完整输入下的预测类别，对三模态的 8 个子集精确计算 Shapley 值，全部样本的效率恒等式误差不超过10^{-6}；验证集上文本对分类的平均贡献约为声学、视觉的 6 ～ 7 倍。在附件 4 上删除得分最高的 30% 位置，目标类概率平均下降约 0.14，删除随机位置仅约 0.03。附件 4 中以非文本为主导的 5 条样本置信度都不超过 0.565，其余 15 条平均为 0.79。文字与声音不符的样本 15，其词时间被人工核验全部拒绝，只给出位置级证据。

关键字： 多模态情感分析；强制对齐；局部模态缺失；池化双头模型；Shapley 归因；删除检验

目　　录

1. 问题重述 **4**
1.1 问题背景 4
1.2 数据说明与使用边界 4
1.3 需要解决的问题 5
2. 问题分析 **5**
2.1 问题一的分析 5
2.2 问题二的分析 6
2.3 问题三的分析 6
2.4 求解思路 6
3. 模型假设 **6**
4. 符号说明 **8**
5. 问题一：原始视频的三模态特征与时间对齐 **9**
5.1 原始样本与处理流程 9
5.2 词级时间映射 9
5.3 声学与视觉特征及词窗池化 10
5.4 可观测状态与有效长度 10
5.5 典型样本验证 11
5.6 全量结果与异常核验 12
5.7 小结 13
6. 问题二：局部模态缺失下的情感预测 **14**
6.1 数据、标签与三种掩码 14
6.2 PM-B2 池化双头模型 14
6.3 局部缺失面板与评价指标 15
6.4 基线比较与缺失训练消融 16
6.5 缺失类型、比例与位置的影响 17
6.6 完整输入的结果与错误归因 19
6.7 改进尝试：A–E 五阶段开发实验 21
6.8 附件 3 推理 26
6.9 小结 27

7. 问题三：模态归因与可回溯的局部证据 27
7.1 解释对象 27
7.2 模态层：八子集精确 Shapley 值 28
7.3 位置层：局部证据与删除检验 29
7.4 素材层：人工时间核验 30
7.5 附件 4 的预测与解释 30
7.6 错误归因 31
7.7 小结 32
8. 模型评价 32
8.1 模型的优点 32
8.2 模型的缺点 33
8.3 改进方向 33
人工智能工具使用说明 34
参考文献 34
附录 A 附件 1 逐样本特征与对齐台账 36
附录 B 附件 3 全量预测 39
附录 C 附件 4 全量预测与时间核验状态 39
附录 D 文件、工具版本与运行环境 41

1. 问题重述

1.1 问题背景

人表达情绪时，说了什么、用什么语气说、说话时脸上是什么表情，三者往往同时起作用。多模态情感分析就是把这三路信号放在一起判断，它是人机对话、具身智能等应用的基础环节。CMU-MOSEI 是这一方向最常用的英文视频数据集之一[1]。

可是到了真实视频上，事情并不整齐。三路信号的时间尺度不同：文本以词为单位，声音以毫秒为单位分帧，画面以固定帧率抽取；片段里还常有静音、人脸出画、转写与声音对不上的情况。这带来两个直接的问题：模型在某一路局部缺失时是否还靠得住，以及模型给出判断后，能不能指出它依据的是哪句话、哪段声音、哪几帧画面。

赛题围绕这两个问题设置了三项任务：从原始视频提取特征并做时序对齐，在模态局部缺失下做鲁棒预测，以及做可解释的预测。本文依次完成这三项任务。

1.2 数据说明与使用边界

赛题提供四个附件，本文对它们的用法见表1。附件 2 的对齐版特征 aligned_50.pkl 共 4850 条，训练集、验证集、测试集分别为 3395、728、727 条。

表 1　题目附件及本文的使用方式

数据	规模与结构	标签	本文用途
附件 1	100 段原始视频，37 个源视频	有	只用于问题一的原始特征、时间映射与异常分析，不进入问题二的训练
附件 2	训练 3395、验证 728、测试 727；50 个位置	有	训练集拟合参数，验证集选结构和检查点；测试集只在模型冻结后评估一次
附件 3	30 条对齐特征	无	问题二的缺失专项推理
附件 4	20 条对齐特征及原始视频	无	问题三的预测、解释与人工时间核验

有两点需要事先说明。第一，测试集在模型冻结后我们评估过一次，已经看过结果，所以后面的改进实验一律不再使用它，也不把它当作从未接触过的

盲测集。第二，问题一自己提取的声学特征是 25 维，附件 2 的声学特征是 74 维，两者都来自声音，却不是同一套特征；视觉虽然都是 35 维，含义也不一定相同。问题二、三只用附件 2 的现成特征，不与问题一的特征混用。

1.3 需要解决的问题

问题一：基于附件 1 的原始视频，建立文本、语音、视觉三模态情感特征提取与时序对齐的数学模型，说明原始样本的处理流程、各模态特征的定义与提取方法、跨模态对齐的规则与实现；生成的特征要做到样本覆盖完整、时序组织可核验、方法可复现，并用典型样本展示对齐效果。

问题二：针对文本、语音或视觉中部分连续时间段不可用的情形，构建鲁棒的情感预测模型，同时输出极性和强度；分析缺失模态类型、缺失位置、缺失时长对性能的影响；对附件 3 完成推理。

问题三：针对三模态完整但决策依据难以追溯的情形，构建可解释的情感预测模型，在输出极性与强度的同时，定量给出各模态的作用程度、主要参考模态，以及能对应到原始文本片段、语音时段或视觉关键帧的关键证据；对附件 4 完成推理。

2. 问题分析

2.1 问题一的分析

问题一的难点在于让每个特征位置都能回到原始素材上。具体有三层。

第一层是时间从哪里来。文本本身没有时间戳。最省事的办法是把整段视频均匀切成若干份，按顺序分给各个词，但这样会给停顿、静音、人不在画面里的时段凭空编出“词时间”。我们更希望每个词的时间都有依据。

第二层是一词多位。BERT 按子词切分，一个英文词可能占两三个位置，这些位置应当共享同一个词的时间窗，而不是各自再切一段。

第三层是提取失败。有的片段没有语音，有的转写和声音对不上，有的全程找不到清晰的人脸。这些情况如果都用零填充，下游就分不清“这里没有表情”和“这里根本没提取到”。

据此，问题一的路线是：先用强制对齐工具 WhisperX[2] 在给定转写上求词级时间，再用字符重叠把子词对到原词，然后把声学帧和人脸动作帧按词时间窗池化到 50 个位置；凡是拿不到时间或拿不到帧的位置，都显式记录其状态，而不是悄悄补零。

2.2 问题二的分析

与问题一不同，问题二直接用附件 2 现成的 50 位置特征，重点从“特征怎么来”转到“缺了一段还能不能判断准”。难点有两层。

第一层是零值有三种来源：序列本身较短留下的补齐填充、原始数据里就没有观测、我们为做实验人为遮掉的部分。三者如果混在一起，模型和评估都会被误导。因此我们对每个位置分别记录这三种掩码。

第二层是评估的独立性。同一条样本会在很多个缺失档位里重复出现，同一个源视频也会切出多个片段，它们都不是彼此独立的样本。所以我们对 63 个缺失档先分别算指标再等权平均，比较两个模型时按源视频成组做配对重抽样。

在模型选择上，张量融合 TFN[3]、低秩融合 LMF[4] 和跨模态 Transformer MulT[5] 代表了表达能力逐步增强的几类融合方式。但本题训练样本只有 3395 条，输入又已经按 50 个位置对齐，复杂模型不一定占优。我们因此以参数很少的池化双头模型为主线，把低秩融合、文本 BiLSTM、跨模态时序网络等作为同一评估口径下的对照，让数据来决定用哪个。

2.3 问题三的分析

与问题二相比，问题三的输入是完整的，难点从“预测得稳”转到“说得清”。这里要回答三个问题：模态重要性的排序针对的是哪一个输出；被选出来的词或帧，删掉以后是不是真的会改变这个输出；给出的时间位置在原始视频里是否真有其事。

这三个问题需要三种不同的检验。模态层面，我们用 Shapley 值[6]把完整预测与各模态子集预测之间的差分摊给三个模态，三模态只有 8 个子集，可以精确计算，不需要采样近似。局部证据层面，参照 ERASER[7]的做法，用删除高分位置后预测的变化来检验证据是否忠实于模型。时间层面，则由人工对照视频逐词核对。前两项检验的是“模型是不是这么用的”，第三项检验的是“素材里是不是真有这个”，谁也替代不了谁。

2.4 求解思路

三问的整体流程如图1所示。

3. 模型假设

(1) 情感标签对应整个片段，片段内的 50 个位置共享同一个标签；位置级证据说明模型依赖哪里，不代表该词有单独的情感真值。



图 1　全文求解思路（中间的虚线箭头表示问题三直接使用问题二冻结的正式模型）

(2) 同一源视频切出的多个片段之间可能相关，比较模型差异时按源视频成组抽样。

(3) 人为遮蔽只改变观察到的特征，不改变标签；全部模态都不可用时，模型返回训练集的类别先验和强度中位数。

(4) 转写与声音不符、静音或无人脸时，保留样本及其可用模态，但不为它编造词时间或视频帧。

(5) 附件 3、4 的标签未知，其结果只能检查格式、内部一致性和人工可核对性，不能计算监督意义上的准确率。

说明。假设 (2) 直接影响区间估计：附件 2 验证集的 728 条来自 239 个源视频，同一视频的片段在说话人、场景上高度相似。如果按条独立重抽样，会把这种相关性当成独立信息，得到过窄的置信区间，所以我们按视频成组抽样。

假设 (3) 界定了缺失面板回答的是什么问题：在预先设定的遮蔽方式下模型

还剩多少能力。真实世界的缺失未必是这样发生的，因此 63 档结果代表的是这类可控干预下的鲁棒性，不能直接推广到任意缺失机制。

假设 (4) 在问题一和问题三中都用到了。宁可让一个位置“没有时间”，也不给它一个看起来合理却无法核对的时间，因为后者一旦被当作证据引用，比缺失更难发现。

4. 符号说明

表 2　主要符号说明

符号	含义
i，t（或 p），m	样本序号、50 个位置的序号、模态 $m \in \{T, A, V\}$（文本、声学、视觉）
D_i	问题一：第 i 段视频的时长
$[s_{ij}, e_{ij})$	问题一：第 j 个原词的起止时间
$\mathcal{I}_{ip}^{m}$，L_i^m	问题一：位置 p 的池化帧集合；模态 m 的有效位置数
ℓ_{imt}，o_{imt}，s_{imt}	布局掩码、原生可观测掩码、人为遮蔽掩码
a_{imt}	实际送入模型的可用掩码，$a = o(1-s)$
$\boldsymbol{\mu}_{im}$，$\boldsymbol{d}_{im}$	模态 m 可观测位置的均值池化与“均值 + 标准差”池化向量
$\boldsymbol{p}_i$，$\hat{c}_i$，$\hat{y}_i$	三类概率、预测类别、预测强度
y_i，c_i	真实强度（$[-3, 3]$）与真实类别
r，ρ_{im}	名义缺失比例；实际删除比例
$\mathcal{K}_{PM}$	局部遮蔽面板：在被选模态内删除连续窗口，共 63 档
$\mathcal{K}_{LH}$	整模态保留压力面板：只保留子集 S，其余模态整路关闭，共 63 档
$v_i^h(S)$，$\phi_{i,m}^h$	只保留模态子集 S 时的输出；模态 m 的 Shapley 贡献，$h \in \{\text{cls}, \text{reg}\}$
$c_i^\star$，R_k	完整输入下的预测类别；局部得分最高的前 k 个位置

注：此为本文的主要符号，其他符号在正文首次出现处说明。

5. 问题一：原始视频的三模态特征与时间对齐

问题一要从 100 段原始视频得到固定长度的三模态特征，并让每个位置都能回到原始的词、声学帧和视频帧。本章先给出词级时间的求法，再给出三路特征的构造和池化规则，最后用一条典型样本和全量台账检验结果。需要强调的是，本章的目标是构造可以逐条核对的原始数据映射，而不是去模仿附件 2 特征的数值；问题二的模型也不在这些特征上训练。

5.1 原始样本与处理流程

附件 1 的 100 段视频来自 37 个源视频，以二元组 $i = (\text{video_id}, \text{clip_id})$ 唯一标识。转写文本和情感标签一律取自题目给定的 label-100.xlsx，不用自动语音识别的结果替换原文。每段视频先用 ffprobe 读取时长 D_i，再用 ffmpeg 抽出 16 kHz 单声道音频。按 ffprobe 的读数，100 段时长在 2.257 ～ 29.288 秒之间，合计约 787 秒；这一范围与赛题说明中给出的 2.648 ～ 34.567 秒不完全一致，本文以实际文件的读数为准。

整条处理链分三步：先求词级时间（第5.2节），再把声学帧和视觉帧按词时间窗池化到子词位置（第5.3节），最后为每个位置记录能否观测以及失败原因（第5.4节）。三步完成后，每个有效位置都挂着一条“原文字符 $\rightarrow$ 词 $\rightarrow$ 子词位置 $\rightarrow$ 音视频帧”的反查链。

5.2 词级时间映射

以视频起点为零时刻，把原转写按非空白字符切成词 w_{ij}，同时保存每个词在原文中的字符区间 $[c_{ij}, d_{ij})$。WhisperX[2] 对给定转写做强制对齐，求出每个词的起止时间。首轮没有全部对齐成功时，程序会利用静音边界把句子切开后重新对齐；静音边界只用来辅助切句，不作为最终的词时间，我们也不用均匀切分去补造时间。规范化词串匹配以后，只对拿到有效数值区间的词记录 $[s_{ij}, e_{ij})$。

文本用冻结的 bert-base-uncased 取最后一层隐状态[8]。WordPiece 编码加上 `[CLS]` 和 `[SEP]` 后长度固定为 50，最多保留 48 个正文子词，不足的位置补齐。设位置 p 的子词在原文中的字符区间为 $[u_{ip}, v_{ip})$，按字符重叠最大的原则确定它属于哪个原词：

$$j_i(p) = \underset{j:\ [u_{ip},v_{ip})\cap[c_{ij},d_{ij})\neq\varnothing}{\arg\max} \Big|[u_{ip}, v_{ip}) \cap [c_{ij}, d_{ij})\Big|. \tag{1}$$

如果某个位置和任何原词都没有重叠，或者对应的词没有有效时间，就保留这个位置和原因，但不给它写入音视频时间。`[CLS]`、`[SEP]` 和补齐位也不冒充

任何词。文本矩阵 $X_i^T \in \mathbb{R}^{50\times 768}$ 的补齐行置零，同时保存词元编号、注意力掩码和分段编号。

5.3 声学与视觉特征及词窗池化

声学特征用 openSMILE[9] 的 eGeMAPSv02 低层描述量，共 25 维[10]，包括音高、响度、共振峰、频谱斜率等与情感表达关系密切的量。视觉特征用 OpenFace 2.0[11] 的人脸动作单元（AU），其中 17 维是强度、18 维是出现标志，共 35 维；动作单元直接对应皱眉、嘴角上扬这类面部动作，比笼统的人脸框统计量更贴近表情。

声学帧的时刻取其时间窗的中点 τ_{ik}^A，视频帧的时刻取 OpenFace 给出的时间戳 τ_{ik}^V。视觉帧必须同时满足三个条件才算有效：提取成功、置信度不低于 0.8、数值有限。设 $\boldsymbol{z}_{ik}^m$ 为模态 $m \in \{A, V\}$ 的第 k 帧向量，b_{ik}^m 为其有效标志，则位置 p 的池化帧集合与特征为

$$\mathcal{I}_{ip}^m = \big\{k:\ s_{i,j_i(p)} \le \tau_{ik}^m < e_{i,j_i(p)},\ b_{ik}^m = 1\big\}, \qquad \boldsymbol{x}_{ip}^m = \begin{cases} \dfrac{1}{|\mathcal{I}_{ip}^m|} \displaystyle\sum_{k\in\mathcal{I}_{ip}^m} \boldsymbol{z}_{ik}^m, & |\mathcal{I}_{ip}^m| > 0, \\ \mathbf{0}, & |\mathcal{I}_{ip}^m| = 0. \end{cases} \tag{2}$$

同一个词切出的几个子词继承同一个词时间窗，因此会引用同一批声学帧和视频帧。这是有意为之：它们本来就是同一个词，时间上不该被人为拆开；但也要注意，这几个位置并不是几次独立的观测。最终得到 $X_i^A \in \mathbb{R}^{50\times 25}$、$X_i^V \in \mathbb{R}^{50\times 35}$，并为每个有效位置保存声学帧数、视频起止帧号和原始秒数。

5.4 可观测状态与有效长度

零值本身说明不了“这里没有表情”还是“这里没提取到”，所以我们为每个位置单独记录可观测状态。令 ℓ_{ip} 为注意力掩码、h_{ip} 为特殊词元标志，则文本可观测位 $o_{ip}^T = \ell_{ip}(1 - h_{ip})$，声学、视觉可观测位 $o_{ip}^m = \mathbb{1}\{|\mathcal{I}_{ip}^m| > 0\}$。各模态的有效长度为

$$L_i^m = \sum_{p=0}^{49} o_{ip}^m, \qquad m \in \{T, A, V\}. \tag{3}$$

下游读取特征时必须同时读取掩码，不能把矩阵里的零解释为真实的静音或面无表情。如果某个模态在提取阶段就失败了，根本没有生成矩阵，文件里记为 None，与“矩阵存在但某些位置为零”区分开。三路特征的存储接口见表3。

表 3　问题一自提特征的存储接口（有效位置数均按可观测掩码计）

模态	原始依据与提取器	单样本矩阵	有效位置与反查字段
文本	给定转写；冻结 BERT，WordPiece	50×768	正文子词；字符区间、原词
声学	16 kHz 音频；eGeMAPSv02 低层描述量	50×25	词窗内帧；秒数、帧数
视觉	原视频；OpenFace 动作单元	50×35	达标动作单元帧；秒数、视频帧号

5.5 典型样本验证

我们从人工核验表中选了样本 `-3g5yACwYnA$_$13`。它的原句是 *They've been able to find solutions or at least bring some answers to the table.*，视频时长 5.514 秒，15 个词全部拿到了时间，18 个正文子词的文本、声学、视觉位置都可观测。表4列出了句首五个词在三路上的对应关系。

表 4　样本 `-3g5yACwYnA$_$13` 句首五词的“词—秒—帧—位置”对应（取自 q1_alignment.csv）

原词	视频时间 /s	文本位置	声学帧数	有效视频帧号
They've	1.445–1.586	1–3	14	45–48
been	1.606–1.726	4	12	50–52
able	1.746–1.927	5	18	54–58
to	1.967–2.067	6	10	60–62
find	2.148–2.409	7	26	66–73

这张表可以直接用来核对。以 They've 为例，它被 BERT 切成 3 个子词，占第 1 ～ 3 个位置，三个位置共用同一个词时间窗，因而共用同样的 14 个声学帧和第 45 ～ 48 号视频帧。声学帧数也和时长对得上：帧移 10 毫秒，0.141 秒的词窗恰好约 14 帧；其余四个词同样如此。表中所列 15 个词的核验结果都是通过。图2把这条样本的 50 个位置与三路特征并排画了出来。

图中能看出两个特点。一是三路的有效区间完全对齐，都在前 18 个正文位

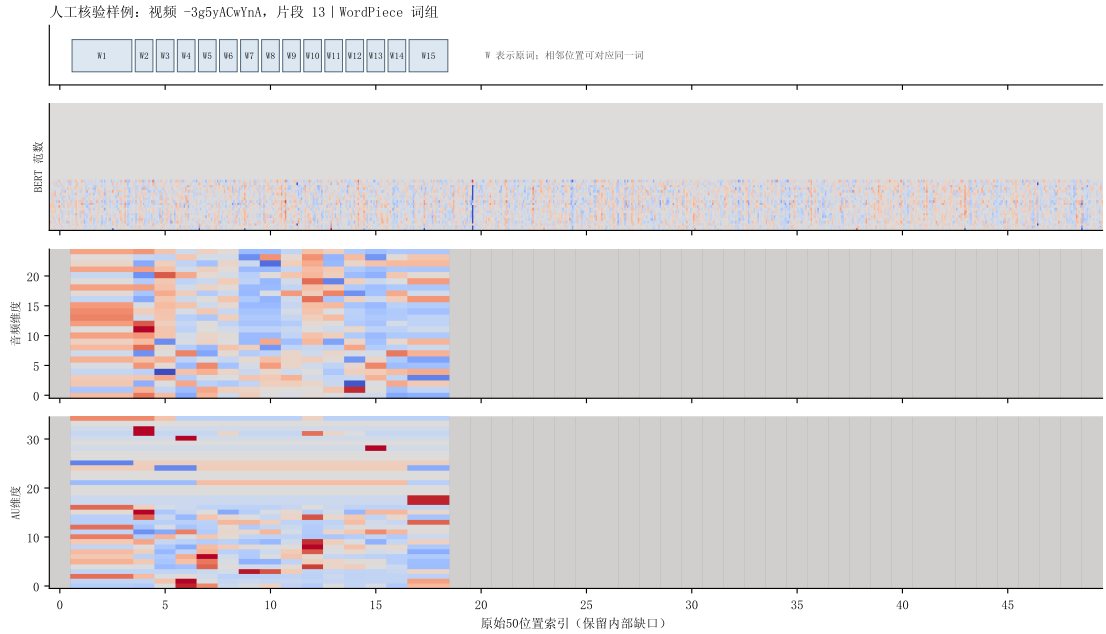


图 2　样本 `-3g5yACwYnA$_$13` 的位置—时间映射与三路观测。最上一行用 W 编号标出原词，相邻的几个子词可对应同一个词；灰色表示该模态在该位置没有有效观测。声学与动作单元热图按本样本的可观测位置逐维标准化并截断到 $[-3, 3]$，只用于展示结构

置上，之后是整齐的补齐区；二是声学和动作单元热图的第 1 ～ 3 列颜色完全相同，这就是 They’ve 的三个子词共享同一个词时间窗的直接体现。

5.6 全量结果与异常核验

100 条样本的逐条台账见附录附录 A的表18，包括时长 D_i、三个有效长度、词级对齐成功数 W_i（拿到时间的词数 / 原词总数）、处理状态和截断标志。图3给出了全量的处理状态、对齐分支和有效长度分布。

处理状态为：正常 77 条、需复核 19 条、失败 4 条。异常的几类情况彼此有重叠，不能简单相加，我们把它们分开列在表5里。

9 段没有全部对齐的样本里，2 段音频里没有语音，2 段音轨是静音，4 段转写与声音对不上，这 8 段完全拿不到词时间；另有 1 段只有 8 个词中的 4 个对上，即样本 `-HwX2H8Z4hY$_$2`。4 段失败样本都在这 8 段之中，而且都卡在 OpenFace 阶段。

这里有一处需要交代的修订。初版导出时，这 4 段失败样本因为流程在 OpenFace 阶段中断，已经算好的文本矩阵没有保存下来。修订时我们用题目给定的转写和同一版本的 BERT 重新生成了这 4 段的文本矩阵，而它们的声学、视觉矩阵仍为 None，失败状态也保持不变。另有 4 段需复核样本保留了文本矩

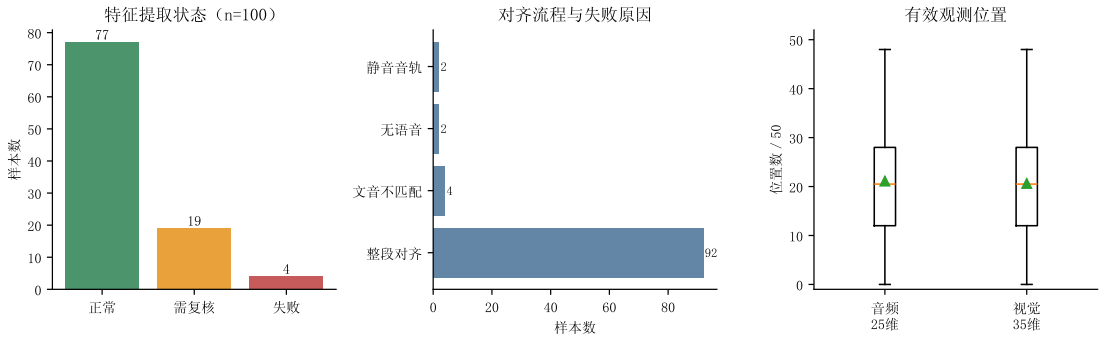


图 3　问题一全量结果（100 条）：左为处理状态，中为对齐分支与失败原因（“整段对齐”表示走了整段强制对齐流程，不代表每个词都有时间），右为声学、视觉有效位置数的分布

表 5　问题一的异常与核验（各类之间允许重叠）

检查项	数量	说明与处理
文本截断	6 段	正文子词超过 48 个，保留截断标志
未全部对齐	9 段	8 段完全没有词时间、1 段部分词缺失；不补造时间
无达标动作单元帧	4 段	OpenFace 阶段找不到满足门槛的帧，记为失败
人工核验	31 段、583 词	全部通过；核验结果不改写机器状态
带时间的位置	2111 个	均满足 $0 \le s \le e \le D_i$

阵，但声学、视觉的可观测位置为 0。这 4 段加上 4 段失败样本，正好就是那 8 段完全没有词时间的样本：没有词时间窗，声学和视觉帧也就无处可放。合起来，文本在 100 段上都有有效位置，声学和视觉各在 92 段上至少有一个可观测位置。

表5最后一行只能说明保存的时间没有越出视频边界，并不能说明每个词在语义上都对准了，这也是我们另做人工核验的原因。从全量看，1932 个原词中有 1820 个拿到了时间，占 94.2%。

5.7 小结

问题一用强制对齐给定转写的方法求出词级时间，再把声学帧和人脸动作帧按词时间窗池化到 BERT 子词位置上，得到 768、25、35 维的三路特征，每个有效位置都能反查到原词、秒数和帧号。100 条样本全部保留，失败和异常以显式状态记录；我们宁可让个别位置没有时间，也不为它编一个无法核对的时

间。

6. 问题二：局部模态缺失下的情感预测

问题二在附件 2 的 50 位置特征上，同时预测片段的三分类极性和连续强度，并衡量局部连续缺失对两类输出的影响。本章先说明三种掩码怎么分开，再给出正式模型 PM-B2 和评估面板，然后依次报告基线比较、缺失规律、测试集误差分析和我们做过的改进尝试，最后对附件 3 推理。

6.1 数据、标签与三种掩码

每条样本在同一条 50 位置轴上给出文本、声学、视觉矩阵，维度分别为 50×768、50×74、50×35。情感强度 $y_i\in[-3,3]$；类别由原标注固定为负向、中性、正向三类，编码为 0、1、2，其中 $y_i=0$ 只属于中性。训练只用训练集的标签，验证集用于选结构、超参数和检查点。

矩阵里的零可能来自补齐填充、原生不可观测或我们施加的遮蔽，因此对样本 i、模态 m、位置 t 分别记录布局掩码 ℓ_{imt}、原生可观测掩码 o_{imt} 和人为遮蔽掩码 s_{imt}。实际送入模型的是

$$a_{imt}=o_{imt}(1-s_{imt}),\qquad \tilde{\boldsymbol{x}}_{imt}=a_{imt}\,\frac{\boldsymbol{x}_{imt}-\boldsymbol{\mu}_m}{\boldsymbol{\sigma}_m}, \tag{4}$$

其中 $\boldsymbol{\mu}_m$、$\boldsymbol{\sigma}_m$ 只用训练集中可观测位置估计，标准化以后再把不可观测位置清零。文本掩码排除 `[CLS]`、`[SEP]` 和补齐位，声学、视觉掩码由非零行确定。布局掩码 ℓ 保留原来的位置范围：序列内部的缺口仍占着原来的序号，不会被挤到序列末尾。三种模态全部不可用时，模型直接返回训练集的类别频率和强度中位数，避免从一个空输入里得出针对具体样本的结论。

6.2 PM-B2 池化双头模型

模型的思路很朴素：先把每个模态的可观测位置汇总成固定长度的统计量，再用一个小网络同时预测类别和强度。对模态 m，在可用位置上求均值和标准差：

$$\boldsymbol{\mu}_{im}=\frac{\sum_t a_{imt}\tilde{\boldsymbol{x}}_{imt}}{\max\!\big(1,\sum_t a_{imt}\big)},\qquad \boldsymbol{d}_{im}=\left[\boldsymbol{\mu}_{im},\ \sqrt{\frac{\sum_t a_{imt}\big(\tilde{\boldsymbol{x}}_{imt}-\boldsymbol{\mu}_{im}\big)^{\odot 2}}{\max\!\big(1,\sum_t a_{imt}\big)}}\right], \tag{5}$$

可用位置为空时两项都取零向量。这种池化天然适应缺失：缺了一段，只是参与平均的位置少了，不会像序列模型那样在缺口处读到一串假的零。

三路拼接后的维度为 $2\times(768+74+35)=1754$。PM-B2 用 $1754\to128\to64$ 的两层 ReLU 网络融合，层间 dropout 为 0.2；64 维共享表示后面接两个独立的

线性头，一个输出三类 logits $\boldsymbol{z}_i$，一个输出强度原值 u_i：

$$\begin{aligned} \boldsymbol{p}_i &= \mathrm{softmax}(\boldsymbol{z}_i), \qquad \hat{c}_i = \operatorname*{arg\,max}_{c\in\{0,1,2\}} p_{ic}, \qquad \hat{y}_i = 3\tanh(u_i), \\ \mathcal{L} &= \frac{1}{B}\sum_{i=1}^{B}\Big[-\log p_{i,c_i} + \big|y_i - \hat{y}_i\big|\Big]. \end{aligned} \tag{6}$$

3 tanh 把强度限制在 $[-3,3]$ 内，回归用 L1 损失，与评价指标 MAE 一致。两个输出来自同一个检查点，但分类结果并不由强度的正负号决定，所以会出现“判为中性、强度略偏正”这样的组合，这是两个头各自判断的结果，并非拼接错误。训练设置见表6。

表 6　PM-B2 的训练设置

项目	设置
数据	附件 2 aligned_50：训练集 3395 条拟合，验证集 728 条选型
网络	均值 + 标准差池化 → 1754 → 128 → 64 （ReLU，dropout 0.2）→ 分类头 + 强度头
优化	AdamW，学习率 3×10^{-4}，批大小 64，最多 30 轮
随机种子	17、29、43 用于结构比较；专项推理部署 seed 17
检查点选择	验证集 63 档平均 macro-F1 优先，63 档平均 MAE 其次，同分取较早轮次
训练遮蔽	PM-B2 本身不做训练遮蔽；对照模型的缺失增广用固定种子 20260923 生成的双窗口库
复现	参数、代码与输入缓存的哈希写入冻结清单

6.3 局部缺失面板与评价指标

正式面板 $\mathcal{K}_{PM}$ 只在被选中的模态里删除一段连续窗口，其余模态保持原样。设某模态原可观测位置的首、尾序号为 f、l，跨度 $L = l - f + 1$。对名义缺失比例 $r \in \{0.1, 0.3, 0.5\}$，窗口宽度取 $\max(1, \lfloor rL \rfloor)$，起点取头、中、尾三者之一，截出的区间再与 o_{imt} 取交。可观测位置少于两个时不删除，并保证不会把原本可观测的模态整个删空。由于原生缺口、特殊词元和取整的存在，实际删除比例

$$\rho_{im} = \frac{\sum_t o_{imt} s_{imt}}{\max\big(1, \sum_t o_{imt}\big)} \tag{7}$$

未必等于名义比例，所以后文的 10%、30%、50% 指的是名义档位。文本的遮蔽不是简单地把缓存的 BERT 向量置零，而是从原始词元输入里移除相应位

置，再经同一个冻结的 BERT 重新编码，这样被删掉的词也不会通过上下文“泄漏”到其他位置。验证时统一使用确定的头、中、尾窗口。

被遮蔽模态的非空组合有 T、A、V、TA、TV、AV、TAV 七种，与 3 种比例、3 种位置组合成 $7 \times 3 \times 3 = 63$ 档。每一档都在同一批 728 条验证样本上计算指标，再对 63 档等权平均。评价指标为

$$\begin{aligned} \mathrm{Acc} &= \frac{1}{n}\sum_{i} \mathbb{1}(\hat{c}_i = c_i), \qquad F_{1,\mathrm{macro}} = \frac{1}{3}\sum_{c=0}^{2} \frac{2P_c R_c}{P_c + R_c}, \\ \mathrm{MAE} &= \frac{1}{n}\sum_{i} |\hat{y}_i - y_i|, \qquad \bar{F}_{1,63} = \frac{1}{63}\sum_{k=1}^{63} F_{1,k}, \end{aligned} \tag{8}$$

其中 P_c、R_c 为第 c 类的精确率和召回率，分母为零时该类 F1 记为 0；$\overline{\mathrm{MAE}}_{63}$ 同样先逐档再平均。皮尔逊相关系数在预测或真实强度为常数时记为未定义，而不是记为 0。

6.4 基线比较与缺失训练消融

表7列出了在同一正式面板上比较的 7 个基线：B0 直接输出训练集先验；B1-T、B1-A、B1-V 是单模态池化线性模型；B3 对三个单模态输出做固定权重的决策融合；B1-N 是文本双向 LSTM；B4 是低秩融合[4]。图4把它们画在同一张图上。

表 7　正式局部缺失面板上的结构比较（验证集 728 条、63 档；神经网络模型为 seed 17/29/43 的均值 ± 标准差）

模型	63 档平均 macro-F1	63 档平均 MAE
B0 训练集先验	0.2114	0.7690
B1-T 单文本	0.4979	0.9095
B1-A 单声学	0.3526	0.8263
B1-V 单视觉	0.3455	0.7818
B3 决策融合	0.4983	0.7277
B1-N 文本 BiLSTM	0.5520 ± 0.0090	0.6523 ± 0.0144
B4 低秩融合	0.5686 ± 0.0057	0.6248 ± 0.0079
PM-B2 池化双头	**0.5752 ± 0.0013**	**0.6213 ± 0.0123**

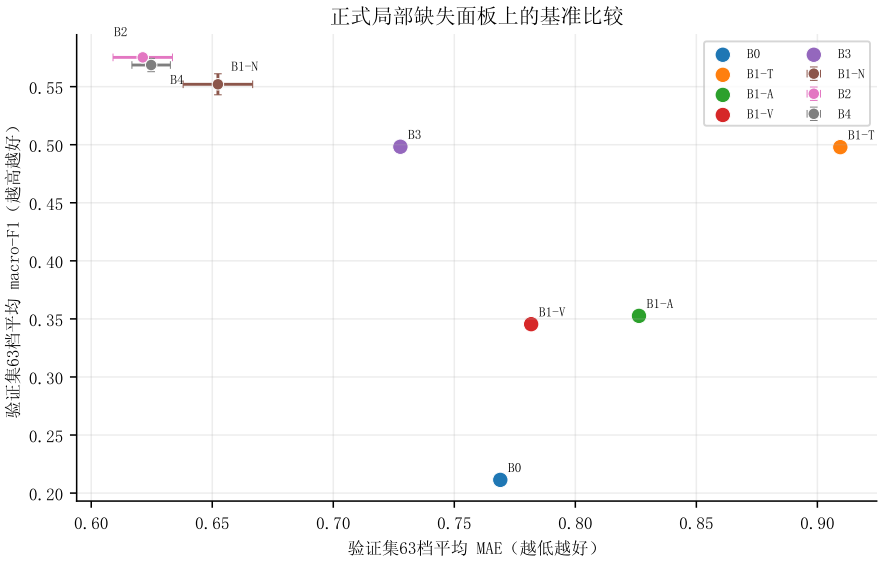


图 4　各基线在正式面板上的表现（横轴 63 档平均 MAE，越左越好；纵轴 63 档平均 macro-F1，越高越好；B1-N、B2、B4 的误差线为三个种子间的标准差，图中 B2 即 PM-B2）

PM-B2 在 F1 和 MAE 上都是 7 个模型里最好的，而且三个种子间的 F1 标准差只有 0.0013，远小于 B1-N 和 B4。几个单模态基线也很说明问题：只用文本的 B1-T 的 F1 接近 0.50，只用声学或视觉的都在 0.35 左右，只比先验好一截。B0 的 F1 只有 0.2114，比三分类随机的 1/3 还低，因为它永远预测多数类，另外两类的 F1 都是 0。

参数更多的时序模型是否值得？我们在同样的学习率和三个种子下做了一个 2×2 消融：M0 是不做缺失增广、也不显式使用可观测掩码的跨模态时序网络；M1 只加连续遮蔽训练；M2 只让注意力和池化显式使用可观测掩码；M3 两者都用。结果见表8。

两个因素各自都有一点帮助，合在一起的 M3 比 M0 的 F1 高 0.0127、MAE 低约 0.010；按源视频做配对重抽样，F1 差的 95% 区间为 $[0.0049, 0.0214]$，不跨零。但即便是 M3，F1 也还是比 PM-B2 低 0.007；M3 的 MAE （0.6195）比 PM-B2 略低 0.0018，这点差距远小于 PM-B2 自身 0.0123 的种子间波动。在本题的数据量下，更复杂的时序结构没有换来明显的收益，这也是我们最终选 PM-B2 作为正式模型的原因。

6.5 缺失类型、比例与位置的影响

表9按被遮蔽模态、名义比例和位置三个因素，把部署模型（seed 17）在验证集和测试集上的 63 档结果分组平均；图5是对应的图。每个模态组合跨 9 档平均，每个比例或位置跨 21 档平均。

表 8　跨模态时序模型的 2×2 消融（验证集 728 条、正式面板 63 档、三种子均值）

配置	训练遮蔽	显式可观测掩码	macro-F1	MAE
M0	否	否	0.5555	0.6295
M1	是	否	0.5630	0.6290
M2	否	是	0.5648	0.6273
M3	是	是	0.5682	0.6195

表 9　PM-B2 （seed 17）在正式面板上的分组结果

因素	档位	验证集 F1	验证集 MAE	测试集 F1	测试集 MAE
被遮蔽模态	T	0.5563	0.6487	0.5894	0.6979
	A	0.5975	0.6125	0.6144	0.6500
	V	0.5942	0.6126	0.6156	0.6494
	TA	0.5583	0.6494	0.5887	0.6985
	TV	0.5573	0.6488	0.5900	0.6988
	AV	0.5952	0.6131	0.6162	0.6507
	TAV	0.5582	0.6495	0.5908	0.6994
名义比例	10%	0.5905	0.6180	0.6141	0.6601
	30%	0.5716	0.6300	0.6001	0.6756
	50%	0.5595	0.6526	0.5879	0.6978
位置	头	0.5761	0.6397	0.6002	0.6778
	中	0.5734	0.6283	0.6072	0.6678
	尾	0.5720	0.6326	0.5948	0.6879

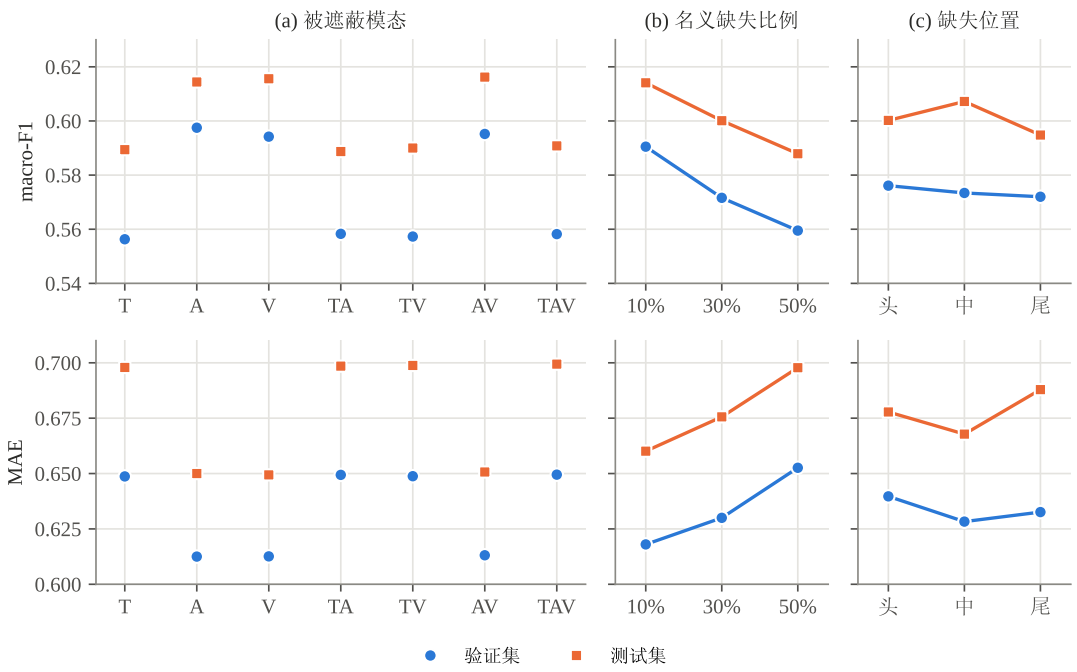


图 5　缺失类型、比例与位置对 macro-F1（上）和 MAE（下）的影响（数据同表9；模态组合是无序类别，不连线）

三个因素的作用大小差别很明显。

模态类型影响最大，而且只看“有没有遮文本”。七种组合清楚地分成两组：凡是遮蔽了文本的（T、TA、TV、TAV），验证集 F1 都在 0.556 ～ 0.558 之间；只遮蔽声学或视觉的（A、V、AV），都在 0.594 ～ 0.598 之间，两组相差约 0.04，MAE 相差约 0.036。组内几乎没有差别，比如在遮蔽文本的基础上再遮蔽声学和视觉（TAV），与只遮蔽文本（T）相比 F1 几乎不变。这说明当前模型的判断主要依赖文本，声学和视觉局部缺一段对它影响很小。但这不等于声学、视觉在所有样本上都没有用，第7章的逐样本归因会看到少数样本主要依靠它们。

缺失比例的影响是单调的。名义比例从 10% 增至 50%，验证集 F1 由 0.5905 降到 0.5595，MAE 由 0.6180 升到 0.6526；测试集的走势完全一致。

位置的影响最小，且不稳定。验证集上头、中、尾的 F1 最大相差 0.0041，测试集上相差 0.0124，而且两个集合上的排序不一样：验证集是头最好，测试集是中间最好。所以我们不认为存在某个“普遍最要紧”的时间位置。

6.6 完整输入的结果与错误归因

表10汇总了 PM-B2 在完整输入下的结果。三种子平均、单个部署权重、不同输入条件是三个不同的统计对象，表中分开列出。

表 10　PM-B2 的完整输入结果

对象	输入	Acc	macro-F1	MAE	Pearson
验证集三种子均值	完整	0.6264	0.5988±0.0033	0.5998±0.0128	–
验证集 seed 17	完整	0.6277	0.6002	0.6120	–
验证集 seed 17	63 档平均	–	0.5739	0.6335	–
测试集 seed 17	完整	0.6644	0.6147	0.6485	0.6691
测试集 seed 17	63 档平均	–	0.6007	0.6778	–

测试集完整输入的混淆矩阵（行为真实的负、中、正，列为预测的负、中、正）及由它算出的各类指标见表11。

表 11　测试集（727 条）完整输入的混淆矩阵与分类指标

真实 \ 预测	负	中	正	合计	精确率	召回率	F1
负	**156**	23	28	207	0.645	0.754	0.695
中	43	**57**	58	158	0.442	0.361	0.397
正	43	49	**270**	362	0.758	0.746	0.752
合计	242	129	356	727	macro-F1 $= 0.6147$		

我们按这张表和前面的结果，把错误归纳为以下几类。

（1）中性类是主要短板。负向和正向的召回都在 0.75 左右，中性只有 0.361，F1 只有 0.397，拉低了整体的 macro-F1。158 条真实中性里，58 条被判为正向、43 条被判为负向，判对的只有 57 条。反过来，模型判为中性的 129 条里也只有 57 条是对的。换句话说，模型并不是分不清任意两类，而是分不清“中性”和“轻微的正、负”。考虑到中性只对应 $y = 0$ 这一个值，而标注是多人评分的平均，“略偏正”和“中性”的边界本身就不清晰，这个问题并不意外。

（2）正、负之间也有互相误判。负向被判为正向的有 28 条，正向被判为负向的有 43 条，合计 71 条，比负、中之间的互相误判（66 条）还略多。这部

分可能与反讽、转折类句子有关，但仅凭预测与标签的统计，我们不能断定是哪一类语言现象造成的。

（3）测试集上强度误差偏大。测试集完整输入的 MAE （0.6485）高于验证集（0.6120），说明冻结的权重在测试集上的强度误差有所上升，而分类指标反而更好。两者方向不一致，提示强度尺度的校准可能需要单独处理。

（4）对文本的依赖过重。第6.5节的分组结果显示，遮蔽文本是性能下降的主要来源。转写一旦出错，模型很难靠声学和视觉补回来。

6.7 改进尝试：A–E 五阶段开发实验

PM-B2 冻结并完成附件 3 推理以后，我们又只用训练集和验证集、固定 seed 17，做了五个阶段共 15 种配置的改进尝试，想看看能否在完整输入和缺失两方面同时做得更好。这些实验没有读取测试集和附件 3、4。先说结论：完整输入的 F1 确实能提高，但换来的是在更严格的缺失条件下明显退化，没有一个配置在各项指标上全面超过 PM-B2 这条主线，所以正式结果仍以 PM-B2 为准。

6.7.1 更严格的整模态保留面板

为了检验这些模型在更极端条件下的表现，我们另设了一个压力面板 $\mathcal{K}_{LH}$：先选一个保留的模态子集 $S \in \{T, A, V, TA, TV, AV, TAV\}$，把 S 以外的模态整路关闭，再只在 S 内施加 10%、30%、50% 和头、中、尾的连续窗口。它同样是 $7 \times 3 \times 3 = 63$ 档，但含有整路缺失的压力，比正式面板苛刻得多。两个面板的输入分布不同，数值不能互相比较；例如 PM-B2 在正式面板上的 0.5752 和下面层次头模型在压力面板上的 0.4139，并不说明前者“好了 0.16”。

6.7.2 A–C 阶段：文本适配、中性判别与音视频补充

A 阶段在附件 2 训练集上用 LoRA[12]适配文本表示：在冻结的 BERT 权重 W_0 上学习低秩增量，即 $W = W_0 + (\alpha/r)BA$，取秩 8、$\alpha = 16$、适配器 dropout 0.05。由于要在线更新文本表示，这一阶段直接用原始 text_bert 的词元编号、注意力掩码和分段输入，而不用原来的 BERT 缓存。我们固定六个组合（冻结或 LoRA、文本单路或三模态、两种学习率），结果见表12。

LoRA 组整体好于冻结组，F1 最高的是三模态、学习率 3×10^{-4} 的 0.6203。不过这只是单种子的结果，而且冻结组和适配组的训练过程本身也不同，我们不把增益全部归功于 LoRA。表中标注“修复后重训”的三行，是在发现评估代码的问题（见第6.7.5节）后重新训练得到的。

B 阶段针对中性类，从 A 阶段的文本 LoRA 模型（学习率 10^{-4}）继续训

表 12　A 阶段完整输入的验证集结果（728 条，seed 17，各取 F1 最优检查点）

配置	Accuracy	macro-F1	MAE
冻结，文本	0.6415	0.6036	0.5984
冻结，三模态（修复后重训）	0.6346	0.5959	0.5953
LoRA，文本，10^{-4}	0.6538	0.6152	0.6008
LoRA，三模态，10^{-4}（修复后重训）	0.6442	0.6054	0.5854
LoRA，文本，3×10^{-4}	0.6525	0.6052	0.5592
LoRA，三模态，3×10^{-4}（修复后重训）	0.6442	0.6203	0.5945

练，试了两条路。B1 按训练集各类样本数 $(967, 758, 1670)$ 的平方根倒数给分类交叉熵加权。B2 改用层次输出：令 $q = P(\text{中性})$，$r = P(\text{正向} \mid \text{非中性})$，三类概率为

$$(p_{\text{neg}}, p_{\text{neu}}, p_{\text{pos}}) = \big((1-q)(1-r),\ q,\ (1-q)r\big), \tag{9}$$

分类损失为中性的二元交叉熵，加上非中性样本的正向二元交叉熵，推理时仍取概率最大的一类。我们把 B2 得到的模型记为 LH-B2，它和 PM-B2 不是同一个模型。两条路都提高了中性召回（由 0.337 分别升到 0.495 和 0.429），但中性精确率也由 0.508 降到 0.455 和 0.473，没能同时改善。LH-B2 的完整输入 F1 为 0.6244，是各阶段中最高的，因此作为后续 C、D、E 阶段的基础模型。

C 阶段尝试两种音视频补充方式：C1 在 BERT 中间层注入局部音视频残差，C2 在池化特征上分别为分类和回归学习门控。结果见表13：C1 的 F1 和 MAE 都不如基础模型；C2 的回归误差下降了，分类却退步。两者都没有形成全面优势，后续没有并入主线。

6.7.3 D–E 阶段：表征分解、缺失增广与蒸馏

D 阶段固定 LH-B2 的文本适配器。D1 只训练小型残差任务头和一个监督对比投影[13]，正例要求同类且来自不同源视频；D2 借鉴共享 / 私有表示的思路[14]，把三模态池化表示拆成共享和私有两支，加上共享对齐、共享与私有的协方差约束和输入重建三个辅助项。E 阶段以 D2 为学生、LH-B2 为固定教师：E0 继续训练但不做缺失增广；E1 在一半样本上按预定的模态组合、比例和窗口合成缺失；E2 在 E1 的基础上再加入对教师分类分布的温度 KL、强度 L1 和批内关系保持项。完整输入与压力面板的结果见表14和图6。

表 13　B、C 阶段完整输入的验证集结果（728 条，seed 17）

检查点	Accuracy	macro-F1	MAE	中性 F1
A 阶段文本模型（B 阶段起点）	0.6566	0.6143	0.5877	0.4052
B1 加权分类	0.6429	0.6217	0.5692	0.4740
B2 层次头（LH-B2）	0.6484	**0.6244**	0.5987	0.4501
C1 局部注入（修复后重训）	0.6374	0.5910	0.6225	0.3576
C2 两任务独立门控	0.6264	0.6069	0.5857	0.4309

表 14　D、E 阶段在完整输入与整模态保留压力面板上的结果（验证集 728 条，seed 17；压力面板为 63 档等权平均）

模型	完整 Acc	完整 F1	完整 MAE	压力 F1	压力 MAE
LH-B2 （基础）	0.6484	0.6244	0.5987	0.4139	0.6977
D1 对比头	0.6360	0.6005	0.5912	0.4110	0.6937
D2 共享 / 私有	0.6401	0.6176	0.5791	0.4286	0.7556
E0 无增广	0.6113	0.5739	0.5815	0.4500	0.7450
E1 缺失增广	0.6154	0.5578	0.5832	0.4512	0.7279
E2 增广 + 蒸馏	0.6223	0.5742	0.5891	0.4518	0.7423

图6里的每条线都从右下往左上走，而且完整输入越好的模型，压力面板上往往越差：LH-B2 的完整输入 F1 最高（0.6244），压力面板 F1 却排在倒数第二（0.4139）；E 阶段三个模型正好相反，压力面板 F1 都在 0.45 左右（连不做增广的 E0 也是如此），完整输入 F1 却降到了 0.56 ～ 0.57。再以 D2 为例，它的完整输入 MAE 比 LH-B2 低 0.0196，压力面板 F1 高 0.0147，可压力面板 MAE 却高了 0.0579。

为了判断这些差异是不是抽样波动，我们按验证集的 239 个源视频做了 1000 次配对有放回抽样：每次对比较双方用相同的视频组频数，重算各档指标再平均，区间取 2.5% 和 97.5% 分位数。结果见表15。

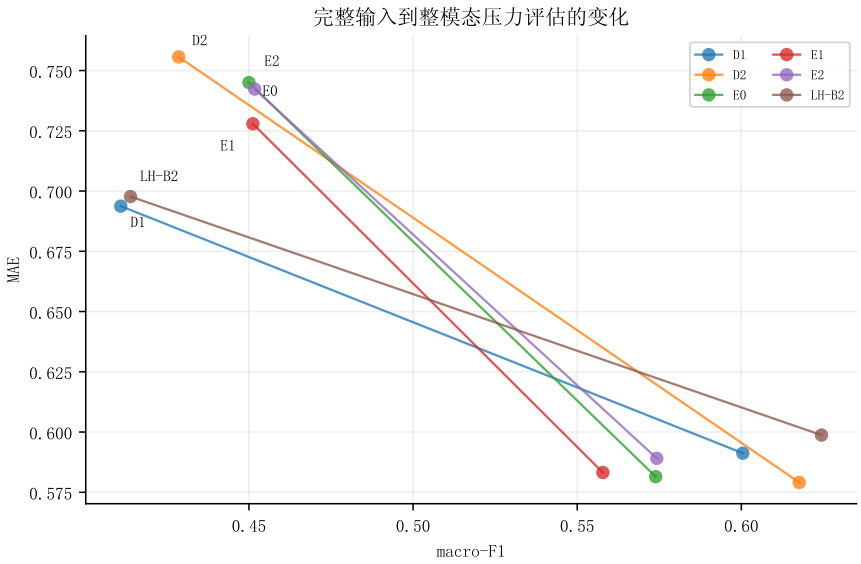


图 6　各检查点从完整输入（右下端点）到压力面板（左上端点）的变化；横轴 macro-F1 越大越好，纵轴 MAE 越小越好

表 15　按源视频配对重抽样的差值（候选减参照；95% 区间，1000 次）

比较	指标	点估计	95% 区间
D2 − LH-B2	完整 MAE	−0.01965	[−0.03470, −0.00379]
	压力 F1	+0.01469	[+0.00134, +0.02738]
	压力 MAE	+0.05793	[+0.03261, +0.08086]
E1 − E0	压力 F1	+0.00118	[−0.01013, +0.01259]
	压力 MAE	−0.01709	[−0.02677, −0.00651]
E2 − E1	压力 F1	+0.00056	[−0.00886, +0.01117]
	压力 MAE	+0.01440	[+0.00631, +0.02243]

D2 的三项差异区间都不跨零，说明它确实是用压力面板上的强度误差换来了完整输入的改善。E1 相对 E0 在压力面板上的 MAE 改善是可靠的，F1 的差异则跨零。E2 的蒸馏没有带来可靠的 F1 提升，MAE 反而变差。需要说明，验证集本身参与了检查点选择，这些实验也只有一个训练种子，所以上述区间描述的是已选模型在验证集视频抽样下的波动，不能当作独立测试集上的显著性结论。

6.7.4 压力面板下的缺失诊断

我们也在压力面板上看了 E2 的缺失规律。按保留的模态子集分组（表16），只保留声学或视觉时 F1 只有 0.34 和 0.33 左右，保留了文本的各组则在 0.518 ～ 0.547 之间。这再次说明，一旦文本整路不可用，模型就很脆弱。

表 16　E2 在压力面板上按保留模态分组的结果（每组 9 档，验证集 728 条）

保留模态	F1	MAE	保留模态	F1	MAE
T	0.5179	0.7079	TA	0.5259	0.6664
A	0.3408	0.8805	TV	0.5471	0.6377
V	0.3256	0.8304	AV	0.3623	0.8346
TAV	0.5428	0.6388			

按名义比例汇总，10%、30%、50% 的 F1 依次为 0.4623、0.4508、0.4421，MAE 依次为 0.7227、0.7383、0.7659；按位置汇总，头、中、尾的 F1 为 0.4509、0.4598、0.4446，MAE 为 0.7431、0.7362、0.7477。比例的影响单调，位置的影响仍然较小，这与正式面板上的结论一致。这里的“时长”是 50 个位置上的比例，不能直接换算成秒数。

图7把删除率加密扫描到 0 ～ 1。在 0 ～ 0.9 之间，F1 随删除率缓慢下降、MAE 缓慢上升，删除率超过 0.7 以后变化明显加快。删除率为 1.0 时，保留子集里的所有模态都被删空，模型按规则退回训练集先验，F1 与 MAE 回到表7中 B0 的水平（0.2114 和 0.7690）。这一点是规则回退的结果，不是局部缺失曲线的自然延伸，图中单独看待。

6.7.5 评估代码的两处问题与修正

开发过程中我们发现评估代码有两处问题：一是不可用模态的数值仍然进入了预测路径；二是压力面板没有真正关闭保留子集以外的模态。受影响的是 A 阶段的三个三模态配置和 C1，它们都已按修正后的输入重新训练，D 阶段的面板也重新评估过；表12～表14中的数值都是修正后的。

修正之后，我们给每次运行加了一道检查：对不可用模态施加任意数值扰动，预测变化必须小于 10^{-6}；全空输入必须返回训练集先验；重新加载权重后的预测必须一致。较早的 A、B、D 阶段是事后补做这项检查的，我们不把它们

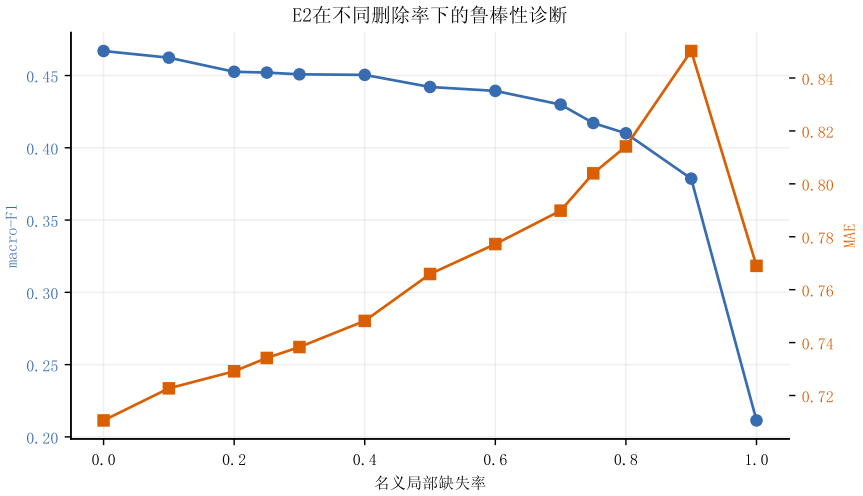


图 7　E2 在不同名义删除率下的 macro-F1 （蓝，左轴）与 MAE （橙，右轴），验证集 728 条，跨保留子集与位置平均

写成当时就已通过。这道检查本身不是新的预测算法，但它决定了上面这些数字能不能信。

6.7.6 为什么没有替换正式模型

15 种配置里，完整输入 F1 最高的 LH-B2 比 PM-B2 （三种子 0.5988）高出约 0.026，看起来值得替换。我们没有这样做，理由有三：第一，A–E 全部只跑了一个种子，胜出者还没有用 seed 29、43 复核；第二，这些模型在压力面板上普遍退化，说明完整输入的收益可能是以缺失下的稳健性为代价的，而问题二考的恰恰是缺失；第三，测试集已经看过一次，不能再用它来挑选模型。因此附件 3 的正式预测仍由 PM-B2 给出，A–E 的结果作为改进方向的依据写进论文。

6.8 附件 3 推理

冻结的 PM-B2 （seed 17）对附件 3 的 30 条样本全部完成了推理，逐条结果见附录附录 B的表19，分布见图8(a)。

30 条中正向 14 条、中性 10 条、负向 6 条，最大类别概率平均为 0.619，其中 8 条低于 0.5。极性与强度的正负号全部一致：判为正向的 14 条强度都为正（0.018 ～ 1.473），判为负向的 6 条都为负（-1.497～-0.071），判为中性的 10 条强度都落在 $[-0.130, 0.194]$ 这一窄区间内。三类中中性的平均置信度最低（0.548，正向 0.670、负向 0.616），这与测试集上中性最难判断的结论是一致的。附件 3 没有标签，这些统计只能说明模型输出的内部一致性，不代表真实的情感分布或准确率。

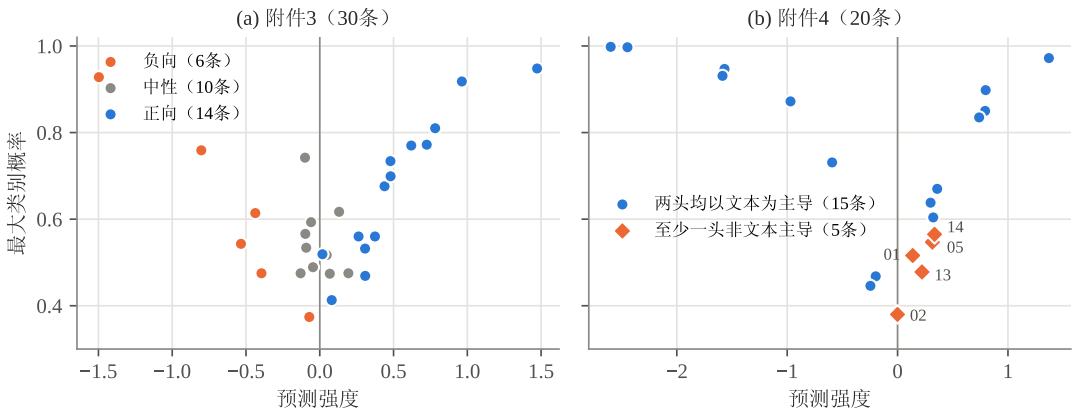


图 8　专项测试集的预测概览：(a) 附件 3，按预测极性着色；(b) 附件 4，按分类与强度两个输出的主导模态区分，橙色菱形为至少一个输出以非文本为主导的样本

6.9 小结

问题二的正式模型 PM-B2 结构很简单，却在 7 个基线和 4 个时序网络对照中取得了最高的缺失面板 F1，种子间波动也最小。缺失规律上，遮不遮文本是决定性因素，缺失比例的影响单调，位置的影响可以忽略。主要错误集中在中性类。A–E 改进尝试说明，完整输入的提升和缺失下的稳健性之间存在明显的取舍，在单种子证据下我们选择不替换正式模型。

7. 问题三：模态归因与可回溯的局部证据

问题三不再训练新模型，而是在问题二冻结的正式模型 PM-B2 上做解释，这样解释的就是实际做预测的那个模型。解释分三层：模态层用 Shapley 值给出三个模态各起了多大作用；位置层用删除检验找出模型最依赖的词或帧，并检验这些证据是否真的影响输出；素材层把证据位置回指到原词、秒数和帧号，由人工核对。

7.1 解释对象

问题三使用 PM-B2 为问题三保存的检查点**【待填：注明是否与问题二部署的 seed 17 检查点相同】**。完整输入下，模型同时输出三类概率 $\boldsymbol{p}_i$ 和强度 $\hat{y}_i$。令

$$c_i^{\star} = \arg\max_{c} \; p_i(c) \tag{10}$$

为完整输入下的预测类别。后面所有的分类归因都针对这个固定的 $c_i^{\star}$，删掉某个模态之后即使预测类别变了，我们看的仍是 $c_i^{\star}$ 这一类的概率。这样做是为了

回答一个确定的问题：“模型之所以判为这一类，各部分分别贡献了多少”，而不是每删一次就换一个问题。附件 4 没有真值，因此本章报告的是预测的结构和解释的一致性，而不是准确率。

7.2 模态层：八子集精确 Shapley 值

设模态集合 $N=\{T,A,V\}$。对任一子集 $S\subseteq N$，构造只保留 S 的输入：S 以外模态的数值和可观测掩码同时关闭。分类与强度的“价值函数”定义为

$$v_i^{\mathrm{cls}}(S)=p_i\big(c_i^{\star}\mid S\big),\qquad v_i^{\mathrm{reg}}(S)=\hat{y}_i(S). \tag{11}$$

空集 $\varnothing$ 返回训练集类别先验和强度中位数，与训练、验证、专项推理时的全空处理一致。按固定顺序枚举 $\varnothing,T,A,V,TA,TV,AV,TAV$ 这 8 个子集，模态 m 的 Shapley 贡献为

$$\phi_{i,m}^{h}=\sum_{S\subseteq N\setminus\{m\}}\frac{|S|!\,(2-|S|)!}{3!}\Big[v_i^{h}\big(S\cup\{m\}\big)-v_i^{h}(S)\Big],\qquad h\in\{\mathrm{cls},\mathrm{reg}\}. \tag{12}$$

它的含义是：把三个模态按所有可能的顺序依次加入，模态 m 加入时带来的输出变化的平均值[6]。三模态只有 8 个子集，因此可以精确计算，不需要采样近似。计算用 64 位浮点，并逐样本检查效率恒等式

$$\Big|\sum_{m\in N}\phi_{i,m}^{h}-\big[v_i^{h}(N)-v_i^{h}(\varnothing)\big]\Big|\le 10^{-6}. \tag{13}$$

728 条验证样本和 20 条附件 4 样本的两个输出都通过了这项检查。这只说明分摊的算术是对的，并不说明解释符合人对情绪的理解；后者要靠下一节的删除检验和人工核对。

单条样本的贡献可以为负：如果某一路输入反而降低了预测类别的概率，负值本身就是有意义的解释，我们不对它取绝对值后当成支持证据。每个样本的主导模态取贡献最大的模态，分类和强度分别给出；当 $v_i^{h}(N)-v_i^{h}(\varnothing)$ 接近零时，各模态的占比没有意义，我们留空而不强行归一化。此外，我们还在预先选定的 96 条解释样本上换了一种空集基准做敏感性检查，不同基准下的排序变化单独记录。

图9是验证集 728 条样本上三个模态的平均绝对贡献。

从图中读数，分类输出上文本的平均绝对贡献约为 0.31，语音和视觉只有约 0.04 和 0.05，文本是后两者的 6 ～ 7 倍；强度输出上文本约 0.57，语音、视觉约 0.12 和 0.13，差距缩小到 4 ～ 5 倍。也就是说，声学和视觉对“有多强烈”的贡献，比对“是正是负”的贡献相对更大。这和直觉一致：语气的轻重、表情的幅度更多反映情感的强弱，而正负方向主要由说了什么决定。这一模态层的结论，也与第6.5节“遮蔽文本是性能下降主因”的结果互相印证。

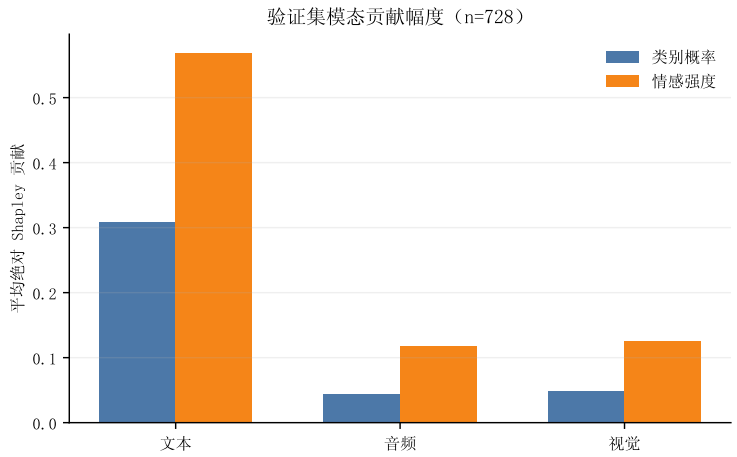


图 9　验证集 728 条样本的模态平均绝对 Shapley 贡献（蓝：分类，针对完整输入的预测类别概率；橙：强度输出）

7.3 位置层：局部证据与删除检验

先确定解释哪些样本。我们在验证集上按真实类别分层，再对“样本键加固定盐”做 SHA-256 排序，选出 96 条解释对象。选取过程完全不看模型的预测分数，以免只挑“解释得好看”的样本。

对每个可观测位置，分别删除它的文本、声学或视觉证据，记录目标类概率和强度的变化，作为该位置的局部得分。文本的删除沿用问题二的做法：保留原来的 50 个位置，把被删的词元换成 PAD 并更新注意力掩码，再经冻结的 BERT 重新编码，而不是把缓存的 BERT 向量置零；声学、视觉则在原位置关闭可观测掩码并重新标准化。令 R_k 为局部得分最高的前 k 个位置，定义

$$C_{i,k}^{\mathrm{cls}} = p_i\big(c_i^\star \mid N\big) - p_i\big(c_i^\star \mid N \setminus R_k\big), \qquad S_{i,k}^{\mathrm{cls}} = p_i\big(c_i^\star \mid N\big) - p_i\big(c_i^\star \mid R_k\big). \tag{14}$$

C 衡量删掉这些证据后目标类概率下降多少，越大说明证据越关键；S 衡量只保留这些证据时损失多少，越小说明这几处证据越“够用”[7]。强度输出同时保存有符号和绝对值的变化。作为对照，用同样的预算删除得分最低的位置和随机位置；随机位置重复 20 次，在每个样本内部取平均，这 20 次是同一样本内的对照，不算 20 个独立样本。附件 4 上的结果见图10。

左图中，三条线分得很开。删除得分最高的位置，目标类概率的下降随预算增加而增大，预算为 30% 时平均约 0.14；删除随机位置只下降约 0.03；删除得分最低的位置，概率反而略有上升（约 -0.05），说明这些位置本来是在“拉低”预测类别。右图中，只保留高分位置时概率损失最小（接近 0 甚至为负），只保留低分位置时损失最大。两张图的方向一致，说明局部得分确实抓住了模型所依赖的位置。不过误差线较宽，20 条样本之间的差异不小；而且这

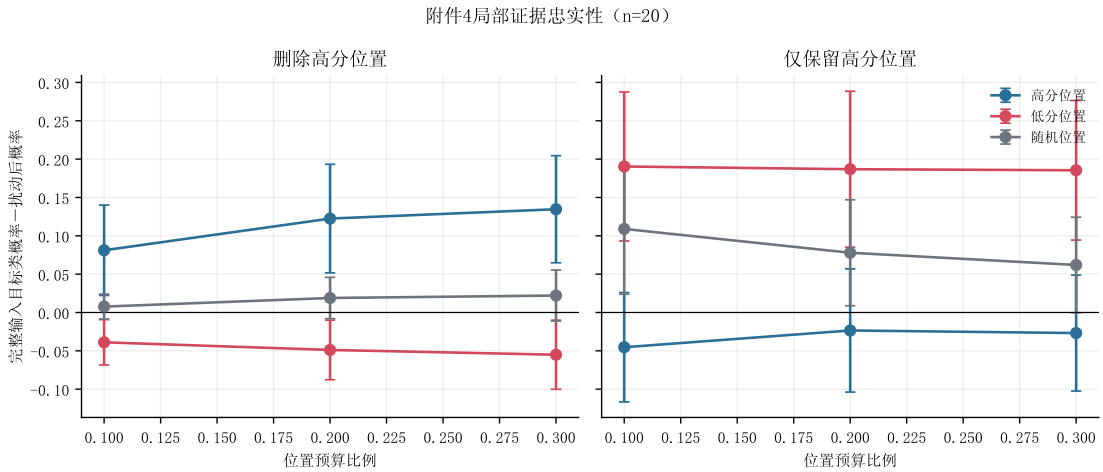


图 10　附件 4（20 条）分类证据的删除检验（左）与保留检验（右）。横轴为位置预算占可观测位置的比例；纵轴为完整输入的目标类概率减去扰动后的概率；误差线为 20 条样本之间的标准差

些差值说明的是“模型怎么用这些位置”，并不能直接当作这些词在情感上的因果证据。

7.4 素材层：人工时间核验

局部证据回指到原素材时，用的是问题一建立的“子词位置—词—秒数—帧号”反查链。附件 4 的人工核验表共有 1662 个“词—模态”映射行，其中 1599 行通过、63 行被拒绝，被拒绝的 63 行全部来自样本 15：人工核对后确认它的文字与声音对不上，强制对齐给出的时间不可信。另外，样本 02 从第 5 个位置起的 45 行时间整体偏移，按核验结果统一修正了 −0.55 秒。

对样本 15，我们保留模型预测和与时间无关的 Shapley 值、删除得分，但从最终展示的时间映射、证据表和解释卡中清除这 63 行的起止秒数和帧号，只在审计字段里保留工具的原始输出。因此，其余 19 条可以给出核验过的时间，样本 15 只给出位置级的解释。模型层面的忠实性检验和素材层面的人工核验是两件事：前者回答“模型是不是这么用的”，后者回答“视频里是不是真有这个”，谁也不能代替谁。

7.5 附件 4 的预测与解释

附件 4 的 20 条样本全部输出了三类概率、强度、两个输出的模态贡献和局部证据，逐条汇总见附录附录 C的表20，分布见图8(b)。

20 条中正向 10 条、负向 7 条、中性 3 条，平均类别概率为 0.717；其中 4 条（09、10、11、16）强度低于 −1.5，是比较强烈的负向，置信度都在 0.93

以上。分类的主导模态以文本为主（16 条），其余为视觉 3 条（02、05、14）和声学 1 条（13）；强度的主导模态文本 17 条、视觉 3 条（01、05、14）。把两个输出合起来看，有一个很清楚的规律：分类或强度任一输出以非文本为主导的 5 条样本（01、02、05、13、14），类别概率都不超过 0.565，平均只有 0.497；两个输出都以文本为主导的 15 条，平均为 0.790。也就是说，当模型主要靠声音或画面做判断时，它自己也没那么有把握。这些样本正是最值得人工回看的。

题目要求给出典型样本的解释卡。以样本 01 为例，解释卡见表17。

表 17　解释卡示例：附件 4 样本 01

项目	内容
预测极性与强度	中性；强度 +0.137（精确值 0.1368）
三类概率	负向 0.1154，中性 0.5162，正向 0.3684
主要参考模态	分类：文本；强度：视觉
模态作用程度	分类 $\phi_T^{\mathrm{cls}}, \phi_A^{\mathrm{cls}}, \phi_V^{\mathrm{cls}}$ = **【待填：从解释 CSV 抄录】**；强度 $\phi_T^{\mathrm{reg}}, \phi_A^{\mathrm{reg}}, \phi_V^{\mathrm{reg}}$ = **【待填：从解释 CSV 抄录】**
文本关键证据	Replacing （0.501–0.942 s），timing （2.726–3.007 s）等；对应子词位置 **【待填：位置号】**
声学、视觉证据	与上述词时间窗对应的声学帧与视频帧 **【待填：视频帧号】**
时间核验	人工核验通过
读法	分类主要依据文本，但文本没有把预测推向明确的正负（中性 0.52 对正向 0.37）；强度的主导模态是视觉，给出的是轻微的正值

这张卡说明了一个有代表性的情况：两个输出头的主导模态不同。分类主要看文本，而“Replacing”“timing”这类词本身没有明显的情感倾向，分类落在中性也就不奇怪；强度则主要由视觉决定，结果是一个轻微的正值。这里的词时间是原素材上的定位，不是这个词单独的情感标签。

题目还要求展示主导模态内局部片段的重要性分布。图11给出样本 01 在文本模态上逐位置的局部得分。

7.6 错误归因

（1）解释会如实暴露模型对文本的依赖。绝大多数样本以文本为主导，这是模型真实的行为，解释只是把它说了出来。反过来看，如果某条样本的转写

【待填：用解释 CSV 中样本 01 文本模态的逐位置局部得分画柱状图（横轴子词位置并标注原词），保存为 figures/fig_q3_local_importance.pdf 后重新编译】

图 11　附件 4 样本 01 文本模态的逐位置局部得分

有错，模型大概率会跟着错，而解释卡上会写着“文本主导”，读者据此就知道应该先核对转写。

（2）非文本主导的样本置信度偏低。第7.5节的 5 条样本类别概率都不超过 0.565，其中样本 02 只有 0.380，基本处在“猜”的状态。对这类样本，解释给出的主导模态本身也不太稳定，更适合作为“请人工复核”的提示，而不是结论。

（3）证据时间受强制对齐质量限制。样本 15 的文字与声音对不上，时间全部作废；样本 02 有整体 0.55 秒的偏移。1662 行中有 108 行（6.5%）需要拒绝或修正，说明自动对齐的时间不能不经核对就直接当证据用。

（4）删除检验的差异在样本间波动较大。图10的误差线较宽，低预算时高分位置曲线的下沿已接近随机位置，说明样本之间差异不小。20 条样本的结论在方向上是清楚的，但幅度还需要更多样本来确认。

7.7 小结

问题三在不改动模型的前提下，从模态、位置、素材三层给出了解释。精确 Shapley 值的效率恒等式在全部样本上成立；删除检验显示高分位置确实比随机位置更影响预测；人工核验拒绝了不可信的时间，而没有为它们编造秒数。附件 4 的 20 条中，以非文本为主导的样本置信度明显偏低，这为人工复核提供了一个简单实用的筛选依据。

8. 模型评价

8.1 模型的优点

1. **特征位置都能反查。**问题一用强制对齐给定转写得到词级时间，每个有效位置都挂着“原文字符—词—子词位置—音视频帧”的反查链；典型样本逐词对得上秒数和帧数，31 段 583 个词的人工核验全部通过。

2. **失败被如实保留。**100 条样本一条不删，拿不到时间的位置不补造时间，提取失败的模态记为 None 而不是零，8 段没有词时间的样本、4 段失败样本都在台账中可查。
3. **三种零值分开处理。**问题二把补齐填充、原生不可观测、人为遮蔽分成三个掩码，文本遮蔽走重新编码而不是置零，模型和评估都不会把“没有”误读成“为零”。
4. **简单模型胜在稳定。**PM-B2 在 7 个基线和 4 个时序网络对照中缺失面板 F1 最高，三个种子间的标准差只有 0.0013；比较时按源视频配对重抽样，没有把重复出现的样本当成独立样本。
5. **解释分层检验。**问题三的 Shapley 值精确计算且逐样本满足效率恒等式，局部证据有高分、低分、随机三组对照，时间证据再经人工核验，三层检验各管一件事。

8.2 模型的缺点

1. **问题一的特征与附件 2 不通用。**自提的声学特征是 25 维 eGeMAPS，附件 2 是 74 维；两套特征不能互换，问题一的特征质量也就没法用问题二的模型直接检验。
2. **中性类识别较差。**测试集中性召回只有 0.361、F1 只有 0.397；B 阶段的加权损失和层次头提高了召回，却降低了精确率，没有同时改善。
3. **改进实验只有一个种子。**A–E 的 15 种配置都只跑了 seed 17，胜出者没有复核，蒸馏中关系保持项的单独作用也没有做去除消融。
4. **专项测试集没有标签。**附件 3、4 的可信度只能借助附件 2 上的表现间接判断，附件 4 的删除检验只有 20 条样本。
5. **缺失面板是预设的干预。**63 档局部面板和压力面板都是我们设定的缺失方式，真实场景中的缺失未必如此，结论不能直接推广到任意缺失机制。

8.3 改进方向

第一，对 A–E 中真正可能改变结论的候选（如 LH-B2、D2）补跑 seed 29 和 43，并对 E2 的关系保持项做单独去除，再用按源视频划分的训练集内交叉验证检验选型是否稳定；在这之前，不用已经看过的测试集或无标签专项集反过来调参。第二，针对中性类，可以把分类阈值和强度预测联合校准，例如让强度接近 0 且分类置信度低的样本优先判为中性，并在验证集上确定阈值。第三，问题一可以把自提特征接到一个在附件 2 上训练、但输入维度与之匹配的模型上，才能真正比较不同对齐方式对下游预测的影响。第四，对非文本主导且置信度低的样本，可以设计自动转交人工复核的规则，把问题三的解释直接

用到实际流程里。

人工智能工具使用说明

本文的写作过程使用了大语言模型工具：原稿的论文框架、文字初稿及部分图表生成脚本借助 **【待填：按实际会话记录填写工具名称与型号，原稿写的是 OpenAI GPT 系列（Codex 会话）】**完成；本稿的结构调整、文字改写与 LaTeX 排版借助 Anthropic Claude 完成。文中所有指标、表格和图均来自队伍保存的实验结果文件、冻结清单和人工核验记录，改写过程中没有新增或改动任何实验数值；新增的两张图（图5、图8）只是把原有表格中的数字重新画成图。参赛队已对照原始记录逐项复核上述内容**【待填：复核完成后删去此提示】**。若竞赛系统要求提供提示词、模型输出及后续处理方式，另按要求提交。

参考文献

[1] Zadeh A B, Liang P P, Poria S, et al., Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph, Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Melbourne: Association for Computational Linguistics, 2236-2246, 2018.

[2] Bain M, Huh J, Han T, et al., WhisperX: Time-accurate speech transcription of long-form audio, Proceedings of Interspeech 2023, Dublin: ISCA, 4489-4493, 2023.

[3] Zadeh A, Chen M, Poria S, et al., Tensor fusion network for multimodal sentiment analysis, Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, Copenhagen: Association for Computational Linguistics, 1103-1114, 2017.

[4] Liu Z, Shen Y, Lakshminarasimhan V B, et al., Efficient low-rank multimodal fusion with modality-specific factors, Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Melbourne: Association for Computational Linguistics, 2247-2256, 2018.

[5] Tsai Y H H, Bai S, Liang P P, et al., Multimodal transformer for unaligned multimodal language sequences, Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, Florence: Association for Computational

Linguistics, 6558-6569, 2019.

[6] Lundberg S M, Lee S I, A unified approach to interpreting model predictions, Advances in Neural Information Processing Systems 30 (NIPS 2017), Long Beach: Curran Associates, 4765-4774, 2017.

[7] DeYoung J, Jain S, Rajani N F, et al., ERASER: A benchmark to evaluate rationalized NLP models, Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, Association for Computational Linguistics, 4443-4458, 2020.

[8] Devlin J, Chang M W, Lee K, et al., BERT: Pre-training of deep bidirectional transformers for language understanding, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Minneapolis: Association for Computational Linguistics, 4171-4186, 2019.

[9] Eyben F, Wöllmer M, Schuller B, openSMILE: The Munich versatile and fast open-source audio feature extractor, Proceedings of the 18th ACM International Conference on Multimedia, Firenze: ACM, 1459-1462, 2010.

[10] Eyben F, Scherer K R, Schuller B W, et al., The Geneva minimalistic acoustic parameter set (GeMAPS) for voice research and affective computing, IEEE Transactions on Affective Computing, 7(2):190-202, 2016.

[11] Baltrušaitis T, Zadeh A, Lim Y C, et al., OpenFace 2.0: Facial behavior analysis toolkit, 2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018), Xi'an: IEEE, 59-66, 2018.

[12] Hu E J, Shen Y, Wallis P, et al., LoRA: Low-rank adaptation of large language models, International Conference on Learning Representations (ICLR 2022), 2022.

[13] Khosla P, Teterwak P, Wang C, et al., Supervised contrastive learning, Advances in Neural Information Processing Systems 33 (NeurIPS 2020), Curran Associates, 18661-18673, 2020.

[14] Hazarika D, Zimmermann R, Poria S, MISA: Modality-invariant and -specific representations for multimodal sentiment analysis, Proceedings of the 28th ACM International Conference on Multimedia, Seattle: ACM, 1122-1131, 2020.

附录 A 附件 1 逐样本特征与对齐台账

表18逐条给出附件 1 全部 100 段视频的处理结果。所有样本的特征维度统一为文本 50×768、声学 50×25、视觉 50×35，对齐粒度为词级（子词位置继承所属原词的时间窗）。表头含义：D_i 为 ffprobe 读取的视频时长；L_i^T、L_i^A、L_i^V 为按可观测掩码计的有效位置数，“–”表示该模态没有生成矩阵，不等于长度为 0 的有效特征；W_i 为“拿到时间的词数 / 原词总数”；状态 O、R、F 分别表示正常、需复核、失败；$C_i=1$ 表示原文正文超过 48 个子词而被截断。

表 18　附件 1 全部 100 条样本的特征与对齐台账

样本键（video_id$_$clip_id）	D_i/s	L_i^T	L_i^A	L_i^V	W_i	状态	C_i
-3g5yACwYnA$_$13	5.514	18	18	18	15/15	O	0
-3g5yACwYnA$_$2	9.394	17	17	17	14/14	O	0
-3g5yACwYnA$_$3	14.389	40	40	40	29/29	O	0
-3g5yACwYnA$_$9	8.817	28	28	28	21/21	O	0
-3nNcZdcdvU$_$5	7.868	22	22	22	18/18	O	0
-571d8cVauQ$_$0	5.067	16	16	16	12/12	O	0
-571d8cVauQ$_$5	15.273	48	48	46	43/43	R	1
-6rXp3zJ3kc$_$8	12.805	38	38	37	34/34	R	0
-9y-fZ3swSY$_$0	6.833	28	28	28	22/22	O	0
-9y-fZ3swSY$_$4	2.821	11	11	11	9/9	O	0
-9y-fZ3swSY$_$8	4.989	14	14	13	12/12	R	0
-AUZQgSxyPQ$_$2	22.511	48	48	48	41/41	O	1
-HeZS2-Prhc$_$2	8.262	17	17	17	16/16	O	0
-HwX2H8Z4hY$_$2	3.982	12	5	3	4/8	R	0
-HwX2H8Z4hY$_$5	5.653	10	10	3	10/10	R	0
-HwX2H8Z4hY$_$6	3.358	9	9	7	7/7	R	0
-HwX2H8Z4hY$_$9	7.734	24	24	24	22/22	O	0
-I_e4mIh0yE$_$1	7.622	21	21	21	18/18	O	0
-I_e4mIh0yE$_$3	9.163	30	30	30	22/22	O	0
-MeTTeMJBNc$_$0	9.300	26	26	26	21/21	O	0
-MeTTeMJBNc$_$13	5.430	16	16	16	14/14	O	0
-MeTTeMJBNc$_$7	10.517	33	33	30	31/31	R	0
-NFrJFQijFE$_$1	5.746	16	–	–	0/16	F	0
-NFrJFQijFE$_$2	6.856	18	–	–	0/18	F	0
-RfYyzHpjk4$_$11	5.239	19	19	18	17/17	R	0
-RfYyzHpjk4$_$2	5.516	29	29	29	25/25	O	0
-RfYyzHpjk4$_$8	4.589	21	21	21	17/17	O	0

续下页

表18（续）

样本键	D_i/s	L_i^T	L_i^A	L_i^V	W_i	状态	C_i
-THoVjtIkeU$_$12	14.896	42	42	42	39/39	O	0
-THoVjtIkeU$_$2	4.292	11	11	11	10/10	O	0
-THoVjtIkeU$_$6	8.097	32	32	32	30/30	O	0
-UUCSKoHeMA$_$0	7.800	23	23	23	18/18	O	0
-UacrmKiTn4$_$10	7.362	22	22	22	18/18	O	0
-UacrmKiTn4$_$4	4.741	15	15	15	14/14	O	0
-UuX1xuaiiE$_$0	3.633	12	12	12	9/9	O	0
-UuX1xuaiiE$_$1	10.350	33	33	33	27/27	O	0
-UuX1xuaiiE$_$3	4.130	9	9	9	9/9	O	0
-UuX1xuaiiE$_$6	8.114	23	23	23	22/22	O	0
-a55Q6RWvTA$_$3	22.154	48	48	48	65/65	O	1
-aNfi7CP8vM$_$7	8.695	23	23	23	18/18	O	0
-aqamKhZ1Ec$_$0	10.967	16	16	16	14/14	O	0
-dxfTGcXJoc$_$0	20.500	48	48	35	41/41	R	1
-dxfTGcXJoc$_$1	16.161	42	42	42	36/36	O	0
-dxfTGcXJoc$_$2	16.698	40	40	40	34/34	O	0
-dxfTGcXJoc$_$6	12.735	32	32	32	27/27	O	0
-egA8-b7-3M$_$1	10.266	22	22	22	20/20	O	0
-egA8-b7-3M$_$13	4.184	16	16	16	11/11	O	0
-egA8-b7-3M$_$16	5.538	13	13	13	11/11	O	0
-egA8-b7-3M$_$17	7.271	19	19	19	16/16	O	0
-egA8-b7-3M$_$18	8.386	27	27	27	22/22	O	0
-egA8-b7-3M$_$20	6.645	24	24	24	20/20	O	0
-egA8-b7-3M$_$26	6.031	19	19	19	15/15	O	0
-egA8-b7-3M$_$6	6.265	13	13	12	12/12	R	0
-egA8-b7-3M$_$9	5.090	12	12	12	10/10	O	0
-hnBHBN8p5A$_$6	6.401	14	0	0	0/13	R	0
-hnBHBN8p5A$_$7	7.372	17	0	0	0/13	R	0
-iRBcNs9oI8$_$3	5.621	9	9	9	8/8	O	0
-iRBcNs9oI8$_$6	2.903	5	5	5	5/5	O	0
-iRBcNs9oI8$_$7	4.104	15	15	15	9/9	O	0
-iRBcNs9oI8$_$8	8.093	26	26	26	21/21	O	0
-iRBcNs9oI8$_$9	3.416	5	5	5	5/5	O	0
-lzEya4AM_4$_$5	7.675	21	21	21	19/19	O	0
-lzEya4AM_4$_$6	14.792	48	48	48	43/43	O	0
-mJ2ud6oKI8$_$1	6.103	13	–	–	0/13	F	0
-mJ2ud6oKI8$_$2	5.731	17	0	0	0/11	R	0

续下页

表18（续）

样本键	D_i/s	L_i^T	L_i^A	L_i^V	W_i	状态	C_i
-mJ2ud6oKI8$_$6	2.257	5	5	5	5/5	O	0
-mJ2ud6oKI8$_$8	4.192	11	11	11	11/11	O	0
-mJ2ud6oKI8$_$9	7.033	29	29	29	22/22	O	0
-mqbVkbCndg$_$0	6.467	17	17	17	12/12	O	0
-qDkUB0GgYY$_$6	4.678	18	18	18	16/16	O	0
-ri04Z7vwnc$_$0	2.807	8	–	–	0/8	F	0
-ri04Z7vwnc$_$2	6.027	26	0	0	0/16	R	0
-ri04Z7vwnc$_$5	3.545	11	11	11	9/9	O	0
-s9qJ7ATP7w$_$0	6.800	28	28	28	24/24	O	0
-s9qJ7ATP7w$_$1	4.792	12	12	12	11/11	O	0
-s9qJ7ATP7w$_$4	4.427	10	10	10	9/9	O	0
-s9qJ7ATP7w$_$5	8.561	20	20	20	19/19	O	0
-s9qJ7ATP7w$_$6	2.475	5	5	5	5/5	O	0
-s9qJ7ATP7w$_$7	6.966	38	38	28	28/28	R	0
-s9qJ7ATP7w$_$8	3.295	17	17	17	13/13	O	0
-t217m2on-s$_$2	5.686	16	16	16	12/12	O	0
-t217m2on-s$_$7	17.183	48	48	48	45/45	O	1
-tANM6ETl_M$_$3	6.758	29	29	27	22/22	R	0
-tPCytz4rww$_$10	4.789	15	15	15	12/12	O	0
-tPCytz4rww$_$11	5.467	20	20	20	17/17	O	0
-tPCytz4rww$_$12	11.864	28	28	28	26/26	O	0
-tPCytz4rww$_$16	7.206	17	17	17	16/16	O	0
-tPCytz4rww$_$18	6.645	22	22	22	16/16	O	0
-uywlfIYOS8$_$4	6.045	22	22	21	18/18	R	0
-vxjVxOeScU$_$4	9.127	27	27	27	21/21	O	0
-wMB_hJL-3o$_$7	6.044	23	23	23	22/22	O	0
-wny0OAz3g8$_$0	3.333	11	11	11	9/9	O	0
-wny0OAz3g8$_$1	6.844	28	28	27	23/23	R	0
-wny0OAz3g8$_$2	6.687	28	28	28	23/23	O	0
-wny0OAz3g8$_$3	6.146	20	20	20	20/20	O	0
-wny0OAz3g8$_$5	6.912	27	27	27	20/20	O	0
-wny0OAz3g8$_$7	8.068	31	31	30	29/29	R	0
-wny0OAz3g8$_$9	6.213	22	22	22	20/20	O	0
-yRb-Jum7EQ$_$1	29.288	48	48	48	49/49	O	1
-yRb-Jum7EQ$_$5	13.169	31	31	31	25/25	O	0
-yRb-Jum7EQ$_$6	11.242	24	24	24	19/19	O	0

附录 B 附件 3 全量预测

表 19　附件 3 的 30 条全量预测（强度为 $[-3,3]$ 尺度，$p_{\max}$ 为三类概率的最大值）

编号	极性	强度	$p_{\max}$	编号	极性	强度	$p_{\max}$
01	负	-0.803	0.759	16	正	1.473	0.948
02	中	-0.098	0.566	17	负	-0.534	0.543
03	中	-0.046	0.489	18	中	0.194	0.475
04	正	0.439	0.676	19	负	-0.395	0.475
05	负	-1.497	0.928	20	中	-0.092	0.534
06	正	0.782	0.810	21	正	0.374	0.560
07	中	0.068	0.474	22	正	0.263	0.560
08	正	0.018	0.519	23	中	0.131	0.617
09	正	0.963	0.918	24	负	-0.071	0.374
10	中	-0.100	0.742	25	中	-0.059	0.593
11	中	0.047	0.517	26	正	0.480	0.699
12	正	0.620	0.770	27	正	0.725	0.772
13	正	0.081	0.413	28	正	0.307	0.532
14	负	-0.437	0.614	29	正	0.308	0.469
15	正	0.479	0.734	30	中	-0.130	0.475

附录 C 附件 4 全量预测与时间核验状态

附件 4 没有真值，表中类别概率指预测类别的概率。样本 15 的文字与声音不符，其词时间被人工核验拒绝，只提供位置级解释。

表 20　附件 4 全部 20 条的预测与时间核验状态（T、A、V 分别为文本、语音、视觉）

样本	预测类别	强度	类别概率	分类主导	强度主导	时间状态
01	中	+0.137	0.516	T	V	人工核验
02	中	−0.001	0.380	V	T	人工核验
03	负	−0.198	0.468	T	T	人工核验
04	正	+0.299	0.638	T	T	人工核验
05	正	+0.315	0.547	V	V	人工核验
06	正	+0.359	0.670	T	T	人工核验
07	正	+0.793	0.850	T	T	人工核验
08	正	+0.323	0.604	T	T	人工核验
09	负	−2.447	0.997	T	T	人工核验
10	负	−1.568	0.947	T	T	人工核验
11	负	−1.586	0.931	T	T	人工核验
12	负	−0.970	0.872	T	T	人工核验
13	正	+0.221	0.478	A	T	人工核验
14	正	+0.335	0.565	V	V	人工核验
15	正	+0.739	0.835	T	T	拒绝词时间
16	负	−2.599	0.998	T	T	人工核验
17	正	+1.371	0.972	T	T	人工核验
18	中	−0.246	0.446	T	T	人工核验
19	负	−0.593	0.731	T	T	人工核验
20	正	+0.798	0.898	T	T	人工核验

附录 D 文件、工具版本与运行环境

表 21　主要复现文件与工具版本

类别	文件、固定值与用途
逐样本特征	q1_features.pkl：100 条特征、掩码、词级时间映射与提取状态；SHA-256：`000a842110539f9e ce45e6cedd666a60 d02994728c9e4bd8 0037f261356fe798`
核验台账	q1_summary.csv、q1_alignment.csv、q1_review.csv：逐样本状态、子词—时间映射及人工复核记录
运行清单	manifest.json、tool_status.json、python_versions.json：完成状态、模型与可执行文件哈希、环境版本
文本模型	bert-base-uncased，revision `86b5e0934494bd15c9632b12f734a8a67f723594`；冻结，取最后一层隐状态
强制对齐	WhisperX 3.8.6；对齐模型 jonatasgrosman/wav2vec2-large-xlsr-53-english
声学工具	openSMILE 2.5.1；eGeMAPSv02 低层描述量，25 维
视觉工具	OpenFace 2.2.0；17 维动作单元强度 + 18 维出现标志
运行环境	Transformers 4.52.4；PyTorch 2.8.0
问题二、三	模型参数、代码与输入缓存的哈希见冻结清单；训练设置见表6

环境版本用于复现，不同版本的输出不一定完全一致。