





中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生数学建模竞赛

学　　校	XX大学
参赛队号	26XXXXXXXXX
队员姓名	1. XXX
	2. XXX
	3. XXX

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题　　目　多模态情感特征对齐与鲁棒可解释预测

摘　　要：

真实场景中，文本、语音、视觉三路信号时间尺度不一，还常常局部缺失，而多数情感模型只给结论、不给依据。本文围绕特征对齐、缺失下的鲁棒预测和可解释预测三项任务，建立了从原始视频到可核验结论的完整流程。

针对问题一，本文用 bert-base-uncased、librosa 和 YuNet 从附件 1 的 100 条视频中提取 768、74、35 维的文本、语音、视觉特征，再用三角核重采样对齐到统一的 50 个位置，给出按词位置（口径 H，与附件 2 一致）、全程 50 等分、说话者有效时段 50 等分三种方案。第三种是本文的改进：以“说话者的脸是否可见”划定有效时段，既剔除无人时段，又保留不说话时的表情。100 条样本平均保留 93% 的时长，语音、视觉非零位置分别为 48.0 和 47.5，而按声音判定只有 32% 的时长在说话。

针对问题二，核查发现附件 2 的零帧绝大多数是尾部填充（语音 96.28%、视觉 89.18%），没有句中连续缺失，与附件 3 的形态不符。以语言主导融合与自蒸馏模型（LDSD）为基线（完整模态 Acc-3 68.78%、F1 60.48%），从 5 个候选模块中筛出连续段缺失增强与超模态补洞，得到 LDSD-Seg：段缺失 F1 由 47.26% 升至 61.70%，MAE 由 0.7112 降至 0.6639，验证集上完整与段缺失的 F1 落差由 15.6 个点缩小到 0.1 个点。108 个单元的三因子扫描表明缺失时长是主因：语言缺失 90% 以内 MAE 仅增 0.060，全缺时增 0.789；语音、视觉的影响低于 0.006，位置的影响不到 0.003。附件 3 预测为正向 14 条、负向 11 条、中性 5 条。

针对问题三，利用附件 2 中序列位置与 BERT 词元一一对应的关系，在不改网络的前提下构建帧—词元回指、干预式模态归因、滑动窗口片段扫描和证据呈现四层解释。忠实性比值为 2.88，加噪稳定性 Spearman 系数为 0.9973；验证集中 92% 的样本以文本为主导，与模态消融结果一致。附件 4 的 20 条样本主导模态均为文本，可找回真值的 5 条极性全对、强度 MAE 为 0.3334，但预测强度普遍偏大。

关键字： 多模态情感分析　时序对齐　说话者人脸跟踪　模态局部缺失　自蒸馏　干预式归因

目　录

1. 问题重述 **5**
1.1 问题背景 5
1.2 数据说明 5
1.3 需要解决的问题 6
2. 问题分析 **6**
2.1 问题一的分析 6
2.2 问题二的分析 7
2.3 问题三的分析 7
2.4 求解思路 8
3. 模型假设 **8**
4. 符号说明 **9**
5. 问题一：多模态情感特征提取与时序对齐 **9**
5.1 原始样本与总体处理流程 11
5.2 三模态情感特征的定义与提取 11
5.3 跨模态时序对齐的规则与实现 12
5.4 特征文件规范 15
5.5 全量结果汇总 16
5.6 对齐质量评估 17
5.7 典型样本验证 19
5.8 可复现性说明 19
5.9 小结 19
6. 附件 2—4 的数据核查与预处理 **20**
6.1 三个附件的概况 20
6.2 零帧结构：题目说的缺失，附件 2 里几乎没有 21
6.3 50 个序列位置到底是什么 22
6.4 预处理 23
7. 基础模型：语言主导融合与自蒸馏 **24**
7.1 为什么选 LDSD 24
7.2 网络结构 24

7.3 两处适配 27
7.4 评价指标 27
8. 问题二：模态局部缺失下的鲁棒情感预测 27
8.1 基线的基础性能 27
8.2 基线在整模态缺失下的鲁棒性 28
8.3 三组消融：语言是不是主导，各组件有没有用 29
8.4 面向局部连续缺失的改进 31
8.5 候选模块的逐级筛选 33
8.6 训练方案与关键参数 35
8.7 LDSD-Seg 的全量确认 35
8.8 缺失类型、位置与时长的影响规律 37
8.9 附件 3 的推理结果 40
8.10 验证集上的错误归因 41
8.11 小结 41
9. 问题三：可解释性情感预测 41
9.1 把“可解释”落实成可检验的输出 42
9.2 L0：帧与词元的回指 42
9.3 L1：干预式模态归因 42
9.4 L2：片段重要性扫描 43
9.5 为什么不用注意力，以及融合层的等价重写 44
9.6 解释质量的量化检验 44
9.7 三模态作用差异 45
9.8 典型样本的解释 46
9.9 附件 4 的预测与解释结果 46
9.10 错误归因 48
9.11 小结 49
10. 模型评价 49
10.1 模型的优点 49
10.2 模型的缺点 50
10.3 改进方向 50
参考文献 51
附录 A 支撑材料与运行环境 54
A.1 支撑材料清单 54

A.2 运行环境与运行说明 54
附录 B 核心算法伪代码 56
附录 C 附件 1 全量特征提取结果 57
附录 D 附件 3 全量预测结果 57
附录 E 附件 4 全量预测与解释结果 58

1. 问题重述

1.1 问题背景

人在表达情绪时很少只靠一种信号：说了什么（文本）、怎么说的（语调、停顿）、说话时的表情，三者共同决定了一句话的情感色彩。多模态情感分析就是把这几路信号放在一起建模，它是具身智能、人机对话等应用绕不开的环节。

落到实际数据上，首先要解决的是“对齐”：文本以词为单位、没有时间戳，语音按毫秒分帧，视频按固定帧率抽帧，三路信号的时间尺度各不相同，必须先统一到同一套序列位置上，下游模型才能使用。在此基础上，还有两个问题特别常见。第一个是缺失：镜头被挡住几秒、背景噪声盖过了人声、语音转写漏掉了半句，都会让某一路信号在一段时间里“空掉”。很多融合模型默认三路输入都在，一旦某路局部为空，性能会掉得很厉害。第二个是可信度：模型给出“负向、强度−1.1”之后，使用者往往想知道它凭的是哪句话、哪一段声音或哪几帧表情，而大多数模型给不出可核对的依据。

赛题以 CMU-MOSEI 英文多模态情感数据集[1]为基础，要求依次完成特征提取与时序对齐、模态局部缺失下的鲁棒预测、可解释预测三项任务，本文依次完成这三项任务。已有的经典融合方法，如张量融合网络 TFN[2]、低秩融合 LMF[3] 和跨模态 Transformer MulT[4]，都以组织好时序的三模态特征为输入[5]，因此问题一所做的特征提取与对齐是后两问的前置环节。

1.2 数据说明

赛题共提供四个附件。附件 1 是从 CMU-MOSEI 中选出的 100 条原始英文视频，按原始视频编号 video_id 分为 37 个子文件夹，每个片段以 clip_id.mp4 保存，时长 2.648 ～ 34.567 秒；配套的标注表给出每条片段的转写文本、连续情感强度和极性标签，用于问题一。附件 2 是整理好的 CMU-MOSEI 特征文件，含对齐版（aligned_50.pkl）与非对齐版两套，每套 4850 条样本，按训练、验证、测试划分，带有情感极性（负向、中性、正向）和连续强度（$[-3,3]$）两种标签。附件 3 是 30 条无标签的“模态局部缺失专项测试集”，缺失表现为某些模态中特征值全为零的连续区间。附件 4 是 20 条无标签的“可解释性专项测试集”，三模态完整，另附原始视频。赛题规定问题二、问题三的模型只能在附件 2 的训练集上学习参数、在验证集上选择结构和阈值，附件 3、4 只用于最终推理；分类任务用准确率和 F1 值评价，回归任务用平均绝对误差（MAE）和皮尔逊相关系数评价。

1.3 需要解决的问题

问题一：基于附件 1 的原始视频，建立文本、语音、视觉三模态情感特征提取与时序对齐的数学模型，明确原始样本的处理流程、各模态特征的定义与提取方法、跨模态时序对齐的规则与实现逻辑；生成的特征文件要做到样本覆盖完整、时序组织可核验、方法可复现，并以典型样本展示对齐效果。

问题二：针对文本、语音或视觉中部分连续时间段不可用的情形，构建鲁棒的多模态情感预测模型，在局部信息不完整时稳定输出情感极性与强度；分析缺失模态类型、缺失位置、缺失时长对预测性能的影响；用该模型对附件 3 完成推理。

问题三：针对三模态完整但决策依据难以追溯的情形，构建可解释的多模态情感预测模型，在输出极性与强度的同时，以可量化、可复核的方式给出主要参考模态、各模态作用程度，以及能对应到原始文本片段、语音时段或视觉关键帧的关键证据；用该模型对附件 4 完成推理。

2. 问题分析

2.1 问题一的分析

问题一的难点在对齐，具体有三层。

第一层是三路信号的时间尺度和时间轴都不一样。文本是一串词，没有任何时间信息；语音以 10 毫秒为一帧，一条片段有几百到几千帧；视觉以 0.1 秒为一帧。要把它们放进同一套 50 个位置，首先得回答“位置代表什么”：代表一个词，还是代表一小段时间。

第二层是对齐结果要可核验。题目要求记录每个序列位置与原始素材的对应关系，这意味着每个位置都要能说清楚对应哪个词、哪段语音、哪几帧画面，不能只输出一堆对不上号的数字。

第三层是空白时段。片段里常有说话前后的静音、人转身或走出画面的时刻，把这些时段和有效内容一视同仁地铺进 50 个位置，会稀释有用的信息。

据此，问题一的路线是：三路特征分别用成熟的开源工具提取（BERT、librosa、YuNet），对齐部分设计一个公共的三角核重采样算子，再给出三种时间轴定义。按词位置对齐（口径 H）复刻附件 2 的做法，便于与后两问的数据接口对接；全程 50 等分作为最直接的时间对齐基准；说话者人脸跟踪方案用“说话者的脸是否可见”划定有效时段，是本文针对空白时段提出的改进。最后用非零位置数、有效时长占比等指标比较三种方案，并用典型样本展示对齐效果。

2.2 问题二的分析

与问题一不同，问题二、三直接使用附件 2 提供的现成特征，重点从“特征怎么来”转到“模型怎么用”。问题二要的是“局部缺失下也能稳”。难点有三层。

第一层是训练数据里没有这种缺失。第6章会看到，附件 2 中的零帧几乎全是尾部填充，真正落在句子中间的连续缺失只有视觉模态零星几段；附件 3 却是 30 条全部带句中连续缺失。换句话说，题目考的失效模式在训练集里基本不存在，必须自己构造。

第二层是连续段缺失不好补。散点式的缺失可以靠相邻帧插值填回来，连续缺二三十帧就没有邻居可借了，模型得真正“推断”出洞里应有的表征。

第三层是规律分析。题目要求说清楚缺失的类型、位置、时长各自有多大影响，而附件 3 没有标签，只能在附件 2 上设计可控实验。三个因素交织在一起，需要把它们拆开单独扫描。

据此，问题二的路线是：先复现一个本身就考虑了缺失的基线模型。本文选用文献[6]的语言主导融合与自蒸馏模型（LDSD），它以语言为主模态、用自蒸馏重建缺失信息，思路上与题意吻合；然后用整模态缺失下的鲁棒性曲线和消融实验诊断它的短板；再围绕“连续段缺失”设计候选改进模块，用统一掩码逐个筛选；最后用三因子扫描回答缺失规律问题，并对附件 3 推理。

2.3 问题三的分析

与问题二相比，问题三的输入是完整的，难点从“预测得稳”转到了“说得清”。

“说得清”在这里有三个具体要求。一是可量化：每个模态起了多大作用，要给出数，而不是一句“主要依据文本”。二是可复核：给出的证据要能让人回到原始材料里核对。三是对得上：解释报告描述的必须就是实际做预测的那个模型，而不是另起一个近似模型。

这里有两个现实障碍。附件只提供了特征和原始视频，没有逐词的时间戳，所以“证据对应到语音时段、视觉关键帧”无法直接换算成秒；另外，注意力权重虽然现成，但已有研究[7]指出注意力分布与预测的因果贡献并不一定一致，拿它直接当解释并不稳妥。

因此问题三不改网络，而是在训练好的网络外部做“干预”：遮掉某个模态或某一段，看输出变了多少，变得越多说明越重要。证据定位则借助第6章发现的帧—词元一一对应关系，把重要的帧翻译回原文的词；语音和视觉只给出词级锚点，不去凑一个没有依据的秒数。

2.4 求解思路

问题一处理附件 1 的原始视频，问题二、三基于附件 2 的特征并共用同一个预测网络，整体流程如图1所示。



图 1　全文求解思路（问题二、三共用基线网络，问题三直接作用于训练好的网络）

3. 模型假设

(1) 附件 2、3、4 的特征由同一流程提取，同一序列位置上的三模态特征对应原句中的同一个词。

(2) 附件 3 中特征全为零的连续区间就是题目所说的局部缺失；有效长度之外的零帧属于补齐填充，不算缺失。

(3) 附件 3、附件 4 的样本除缺失形态外与附件 2 同分布，在附件 2 上选定的结

构和超参数可以直接用于两个专项测试集。

(4) 对单个样本，遮蔽某一模态或某一片段后模型输出的变化量，可以衡量该部分对本次判断的贡献。

(5) 附件 2 的连续强度标签是多名标注者评分的平均值，视为无偏真值；极性由强度的符号决定，0 只属于中性。

(6) 附件 1 的转写文本与语音内容一致；在缺少逐词时间戳时，词在语音时段内近似匀速分布。

(7) 附件 1 的片段以单人讲话为主，说话者是离镜头最近、人脸面积最大的人。

说明。假设 (1) 是后面证据回指的前提，我们没有只凭文件说明就接受它，而是在第6.3节用数据做了验证：语音有效长度与 BERT 词元数的相关系数为 1.0000，训练、验证、测试三个划分逐条成立。

假设 (4) 是问题三干预式解释的基础。它常被质疑的一点是：遮蔽后的输入可能偏离训练分布，输出变化里混进了“模型没见过这种输入”的成分。对本文的模型来说这个问题要轻得多，因为训练时本来就注入了整模态和连续段缺失（第8章），被遮蔽的输入正是模型见过的形态。

假设 (5) 有一个旁证：附件 4 中能在附件 2 里找回真值的 5 条样本，强度分别为-0.333、0.667、0.333、-0.667、1.000，都是$1/3$的整数倍，与“三名标注者取平均”的做法一致。

假设 (6) 只在问题一的方法一、二中用来给词元分配时刻。真实语速有快有慢，这个近似会带来词级的时间误差；更精确的做法是用语音识别的强制对齐得到逐词时间戳，我们把它列为改进方向。假设 (7) 是方法三锁定说话者的依据，对单人独白为主的 CMU-MOSEI 片段基本成立，同一画面出现两张大小相近的人脸时可能误判。

4. 符号说明

注：此为本文的主要符号，其他符号在正文首次出现处说明。

5. 问题一：多模态情感特征提取与时序对齐

问题一要求从附件 1 的原始视频出发，说清楚三件事：原始样本怎么处理，各模态的情感特征如何定义和提取，跨模态时序对齐按什么规则、怎样实现。三件事里真正难的是对齐。文本以“词”为单位，没有时间戳；语音按 10 毫秒一帧，一条几秒的片段就有几百帧；视觉按每秒 10 帧抽取。三者的时间尺度和时间轴都不一样，不统一到同一套序列位置上，下游模型就没法用。

表 1　主要符号说明

符号	含义
$m \in \{l, a, v\}$	模态：语言（文本）、语音、视觉
$T = 50$	对齐后的序列位置数（词级对齐）
$U_m^0 \in \mathbb{R}^{T \times d_m}$	模态 m 的原始特征，$d_l = 768$，$d_a = 74$，$d_v = 35$
U_m^1	注入缺失后的特征
L_m	模态 m 的有效长度（最后一个非零帧的位置加 1）
$M_m \in \{0, 1\}^T$	模态 m 的缺失掩码，1 表示该帧缺失
$d = 128$	统一隐层维度（8 头，每头 $d_k = 16$）
H_m^1，H_l^i	模态嵌入；语言第 i 个尺度的表示
H_{Hyp}^j	第 j 层超模态表示
E_{rec}，H^{rec}	重建器及其输出
θ^{tea}，θ^{stu}，η	教师、学生参数与 EMA 系数（$\eta = 0.99$）
$\hat{y}_{reg}$，$\hat{y}_{cls}$	强度预测值与极性预测分布
λ，γ	损失权重（$\lambda = 0.5$，$\gamma = 1.0$）
r	缺失率，含义随缺失模式而定（见第8.4.1节）
ρ	因子扫描中的缺失时长（占该模态自身内容跨度的比例）
s_m，μ	模态作用程度；主导模态的判定裕度
$\mathrm{Imp}_m(t)$，w	片段重要性；遮蔽窗口宽度
D，D_{sp}，D_{eff}	问题一：片段时长、语音时长、有效时长
L_{txt}	问题一：有效词元数（含 [CLS]、[SEP]）
τ_i，a_k，b	问题一：帧时间戳、对齐锚点、三角核带宽
A_s，κ	问题一：说话者典型脸面积；可见判定的面积比（$\kappa = 0.4$）

本章先给出三路特征的提取方法，再给出三种对齐方案。三种方案共用同一个重采样算子，输出的形状完全一致，区别只在“时间轴怎么定义”：按词位置、按视频全程、按说话者可见的有效时段。第三种是本文提出的改进。

5.1 原始样本与总体处理流程

附件 1 共 100 条英文视频，分布在 37 个以 video_id 命名的子文件夹中，每个片段以 clip_id.mp4 保存，时长在 2.648 ～ 34.567 秒之间，合计约 777 秒。标注表 label-100.xlsx 给出每条片段的转写文本 text、连续强度 label （$[-3,3]$）和极性 annotation。我们以“video_id + clip_id”作为样本编号，100 条样本全部保留并逐条输出特征，没有替换、删除或修改任何样本和标签；若某条片段检测不到说话者的脸，按第5.3.4节的退化规则处理，而不是把它剔除。

处理流程分两段。第一段是逐模态提取：文本经 BERT 编码成词元级向量，语音从视频中抽出后分帧提取声学描述子，视觉按固定帧率抽帧并做人脸检测后提取面部描述子。第二段是对齐：用三角核把三路长短不一的序列重采样到统一的 50 个序列位置，得到 text $(50, 768)$、audio $(50, 74)$、vision $(50, 35)$ 三个矩阵，与附件 2 的 aligned_50.pkl 形状一致。

5.2 三模态情感特征的定义与提取

三路特征的定义见表2。三路都使用开源工具或预训练模型，模型参数全部冻结，不做任何微调。

文本。BERT 的输出是上下文表示，同一个词在“not good”和“very good”里的向量不同，否定、程度这些对情感很关键的信息因此能保留下来。有效词元数 L_{txt} 包含 `[CLS]` 和 `[SEP]`，100 条样本平均为 24.5，最长的样本恰好占满 50 个位置。

语音。MFCC 刻画音色，能量和过零率反映响度与清浊变化，谱质心、带宽、滚降反映声音的明暗与尖锐程度，色度则与音高有关。这些量合在一起，承载语气、语调、语速这类“怎么说”的情感线索。

视觉。YuNet 是一个轻量的人脸检测器，在 CPU 上逐帧运行也足够快。我们没有用表情识别模型，而是用人脸框的几何量和框内像素统计量描述头部姿态、运动幅度和面部可见性。这样做的好处是不依赖额外的表情标注，代价是对细微表情的刻画比较粗，这一点在第10章的缺点里还会提到。

需要说明的是，74 和 35 这两个维数是按赛题统一的输入接口选定的。附件 2 的语音、视觉特征来自 CMU-MOSEI 官方提取流程，语音部分为 COVAREP[12] 声学特征，与本文 librosa 特征的每一维含义并不相同。因此本章保证的是**形状和时序组织**与附件 2 一致，并不声称两套特征在数值上可以互

表 2　三模态情感特征的定义

模态	工具 / 模型	特征定义	维数	原始粒度
文本	bert-base-uncased[8]	WordPiece 分词，加 `[CLS]`、`[SEP]`，截断或补齐到 50 个词元，取最后一层 last_hidden_state	768	词元
语音	ffmpeg + librosa[9]	16 kHz 单声道，25 ms 窗、10 ms 帧移；MFCC[10] 及其统计量、过零率、谱质心、谱带宽、谱滚降、色度、能量等声学描述子	74	10 ms 帧
视觉	OpenCV + YuNet[11]	10 fps 抽帧，取面积最大的人脸；人脸框的位置、尺寸、相对运动等几何量，加框内像素的亮度、对比度等统计量；无脸帧置零	35	0.1 s 帧

换；问题二、三的模型也是在附件 2 自带的特征上训练的。

5.3 跨模态时序对齐的规则与实现

5.3.1 公共算子：三角核重采样

设某一模态的帧序列为 $\{(\tau_i, \mathbf{f}_i)\}$，$\tau_i$ 为第 i 帧的时间戳，$\mathbf{f}_i$ 为特征向量。给定锚点时刻 a，用三角核加权平均得到该锚点上的特征：

$$w_i(a) = \max\!\Big(0,\ 1 - \frac{|a - \tau_i|}{b}\Big), \qquad \hat{\mathbf{f}}(a) = \frac{\sum_i w_i(a)\,\mathbf{f}_i}{\sum_i w_i(a)}, \tag{1}$$

其中 b 为核带宽，取相邻帧的间隔。离锚点越近的帧权重越大，超出带宽的帧权重为 0，最后做归一化。这个算子把“不等长、不等帧率”的序列统一到任意给定的一组锚点上，三种对齐方案都用它，差别只在锚点放在哪里。

5.3.2 方法一：按词位置对齐（口径 H）

以文本为锚，序列位置就是词元序号。文本天然是词元级的，直接占据第 0 到第 $L_{txt} - 1$ 行（第 0 行为 `[CLS]`，第 $L_{txt} - 1$ 行为 `[SEP]`）。语音、视觉按

“词在语音时段内均匀分布”的近似，把 $L_{txt}-2$ 个内容词对应到时间锚点上：

$$a_t=\frac{t-1}{L_{txt}-3}\,D_{sp},\qquad \mathbf{x}_m[t]=\begin{cases}\hat{\mathbf{f}}_m(a_t), & 1\le t\le L_{txt}-2,\\ \mathbf{0}, & \text{其他},\end{cases}\qquad m\in\{a,v\},\tag{2}$$

其中 D_{sp} 为语音时长，即 linspace$(0,D_{sp},L_{txt}-2)$。`[CLS]`、`[SEP]` 和尾部补齐位置上的语音、视觉特征恒为零。

这样构造出来的零帧结构是：第 0 帧为零，有效长度 $L_a=L_{txt}-1$，其后全为零。这与第6.3节在附件 2 上实测到的 $L_a=\text{nnz}(\texttt{input_ids})-1$ 完全一致，也就是说口径 H 复刻了附件 2 的对齐方式。它的信息密度最高，每个位置都对应一个词；缺点是有效位置数随句子长短变化，而且“词匀速发音”只是近似。

5.3.3 方法二：全程 50 等分

抛开“词”这个锚，直接在视频全程 $[0,D]$ 上均匀放 50 个锚点：

$$a_k=\frac{k}{49}\,D,\qquad k=0,1,\dots,49.\tag{3}$$

语音、视觉按式 (1) 重采样到这 50 个锚点。文本没有时间戳，仍按均匀发音的近似把 L_{txt} 个词元铺在 $[0,D]$ 上，第 j 个词元的时刻取 $\tau_j=jD/(L_{txt}-1)$，再用同一个算子重采样。

这种做法最简单，三路都落在固定的 50 个时间位置上。问题在于片段开头结尾的静音、人转身或低头的时段，也被平均铺进了这 50 个位置，混入了与情感无关的内容。

5.3.4 方法三：说话者人脸跟踪与有效时段 50 等分（本文改进）

一段视频里，人并不是从头到尾都在说话或做表情：开头结尾常有静音，中间可能转身、低头、走出画面。方法二把这些空白也塞进 50 个位置，既浪费位置，又稀释了有效信息。

那么该用什么判据划定“有效时段”？只看有没有声音（语音活动检测，VAD）不够，因为人不说话时仍然可能在做表情；只看画面里有没有人脸也不够，背景里的路人也会被检测到。我们最终采用的判据是：**说话者本人的脸在不在画面里**。三种典型情况的处理见表3。

具体分三步实现。

第一步，锁定说话者。先用短时能量做 VAD：第 j 帧的短时能量为 e_j，满足 $e_j\ge 0.05\max_j e_j$ 的帧判为语音帧；短于 0.15 秒的语音段视为噪声剔除，短于 0.25 秒的静音间隙予以填补。在“正在说话且检测到人脸”的帧里取面积最

表 3　方法三的采集判据

情况	说话者的脸在画面中	是否采集
正在说话	在	是
不说话但在做表情	在	是
转身、低头或走出画面	不在	否

大的人脸作为说话者，记其典型面积为 A_s。之所以取最大，是因为单人讲话的视频里说话者离镜头最近、脸最大，这样可以排除背景中的其他人。

第二步，判定可见性。对全片每一帧，只有检测到人脸且面积不小于 κA_s 时，才认为说话者可见：

$$v(\tau) = \mathbb{1}\big[\text{检测到人脸} \ \wedge \ A(\tau) \geq \kappa A_s\big], \qquad \kappa = 0.4, \tag{4}$$

其中 $A(\tau)$ 为 τ 时刻最大人脸的面积。

第三步，在有效时间轴上等分。把所有可见时段首尾拼接，得到有效时间轴。形式上可以写成累积可见时长的映射

$$\varphi(\tau) = \int_0^{\tau} v(u)\,\mathrm{d}u, \qquad D_{eff} = \varphi(D), \qquad a_k = \frac{k}{49}\,D_{eff}, \quad k = 0, \ldots, 49. \tag{5}$$

三路特征只保留落在可见时段内的帧（文本词元按均匀发音近似取时刻），时间戳经 φ 映射到 $[0, D_{eff}]$ 后，再用式 (1) 重采样到 50 个锚点。

退化保护。如果某条片段全程都检测不到说话者的脸，即 $D_{eff} = 0$，则退化为方法二的全程等分，保证不会输出全零特征。

图2用一条示意片段对比了三种方案的锚点位置。

从图2可以看出方法三的两个特点。第一，片段开头说话前的一小段，人没出声但脸在画面里，方法三照样采集，纯 VAD 会把它丢掉。第二，中间说话者转头的那一段，虽然还在出声，但脸不可见，方法三把它剔除了；这时视觉特征本来就缺失，剔除反而让保留下来的每个位置三路都是完整的。

5.3.5 三种方案的对比

三种方案的差异汇总在表4中。

三种方案各有用处。方法一与附件 2 口径一致，适合需要与附件 2 接口对接的场合；方法二、三把位置固定为 50 个时间桶，便于做时间维度上的分析，其中方法三的信息密度更高。

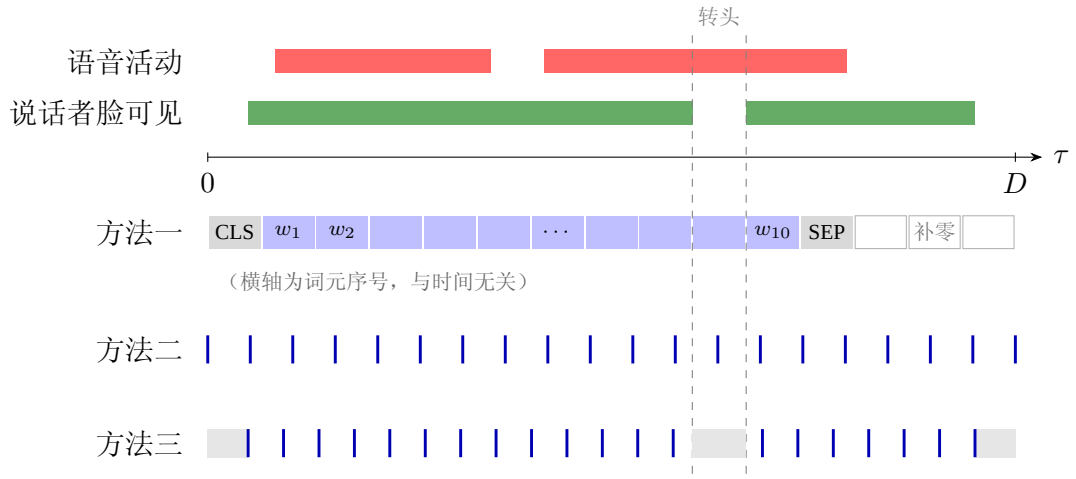


图 2　三种对齐方案的锚点示意。方法一按词位置，方法二在全程等分，方法三只在说话者可见的时段内等分（蓝色竖线为锚点，只画出 20 个，实际为 50 个；灰色为说话者不可见、被剔除的时段）

表 4　三种对齐方案对比

	方法一（口径 H）	方法二（全程 50 等分）	方法三（说话者有效时段）
时间轴	词元序号	视频全程 $[0, D]$	有效时段 $[0, D_{eff}]$
有效位置数	$L_{txt} - 2$（随句长变化）	固定 50	固定 50
剔除静音、无人时段	不涉及	否	是
采集判据	无	无	说话者脸可见
与附件 2 口径	一致	不同	不同
输出形状	text $(50, 768)$，audio $(50, 74)$，vision $(50, 35)$		

5.4 特征文件规范

每条样本输出一个 NumPy 压缩文件（.npz），文件名为样本编号，三种方案分别存放在各自的结果目录中：

- 方法一：step1_extract/results/q1_features/
- 方法二：step1_time50/results/q1_time50_features/
- 方法三：step1_vad50/results/q1_vad50_features/

每个文件包含的字段见表5，读取方式如下（sample_id 为样本编号）：

```
import numpy as np
f = "step1_vad50/results/q1_vad50_features/<sample_id>.npz"
d = np.load(f)
text = d["text"]   # (50, 768)
audio = d["audio"] # (50, 74)
vision = d["vision"] # (50, 35)
L_txt = int(d["L_txt"]) # tokens incl. [CLS]/[SEP]
```

表 5　特征文件字段

字段	形状	含义
text	$(50, 768)$	文本特征，BERT last_hidden_state
audio	$(50, 74)$	对齐后的语音特征
vision	$(50, 35)$	对齐后的视觉特征
text_bert	—	BERT 的整数输入（词元编号等），用于回指原文
L_txt	标量	有效词元数（含 [CLS]、[SEP]）
effective_secs 等	标量	仅方法三：有效时长、说话段数 n_segments、说话者脸可见帧数 face_frames、语音帧数 voice_frames、既有语音又见到脸的帧数 voice_face_frames

时序组织的可核验性。每个序列位置都能按规则还原到原始素材上。方法一中，第 t 个位置对应第 t 个词元，经 text_bert 解码即得原文的词，对应的语音时刻为式 (2) 中的 a_t，视频帧号为 $\lfloor 10a_t \rfloor$。方法二中，第 k 个位置对应原视频的 a_k 时刻。方法三中，第 k 个位置对应有效时间轴上的 a_k，还原到原视频为 $\varphi^{-1}(a_k)$，可见时段由固定参数下的检测结果唯一确定，可以重算。填充规则统一为：有效位置之外全部补零，有效长度由 L_txt （方法一）或非零位置（方法二、三）给出。

5.5 全量结果汇总

100 条样本都输出了三种方案的特征文件。逐条的汇总表（样本编号、原始时长、有效词元数、有效时长、说话段数、各方案的非零位置数，以及统一的特征维度与对齐粒度）见附录附录 C，整体统计见表6。

表 6　附件 1 特征提取结果的整体统计（100 条样本）

项目	结果
样本数	100 条，来自 37 个原始视频
片段时长	2.648 ～ 34.567 s，合计约 777 s
有效词元数 L_{txt}	平均 24.5，最大 50
能量 VAD 判为说话的时长	约 249 s，占总时长的 32%
方法三平均有效时长占比 D_{eff}/D	0.93
方法三说话者脸可见帧占比	0.88
特征维度	text $(50, 768)$，audio $(50, 74)$，vision $(50, 35)$
对齐粒度	方法一为词级；方法二、三为 50 个时间桶

5.6 对齐质量评估

附件 1 虽然带有情感标签，但只有 100 条，而且本章的语音、视觉特征与附件 2 不在同一个特征空间，没法直接拿问题二的模型去比较三种对齐的下游效果。因此我们从“每个位置能否被解释为原始素材的一段”这个角度评价对齐质量，用三个指标：

- **非零位置数** $N_m = \#\{t : \|\mathbf{x}_m[t]\|_2 > 10^{-8}\}$：50 个位置里有多少真正有内容；
- **有效时长占比** D_{eff}/D（方法三）：剔除空白后保留的时长比例；
- **说话者脸可见帧占比**（方法三）：可见帧数与视觉总帧数之比，反映视觉采集的有效性。

100 条样本的平均结果见表7和图3。

方法一的语音非零位置为 22.5，正好等于平均词元数减去 `[CLS]` 和 `[SEP]`（$24.5 - 2$），与式 (2) 的构造吻合：每个有内容的位置都对应一个词，最“干净”，信息密度最高。视觉只有 21.1，比语音少 1.4 个，差额来自说话时恰好没检测到脸的那些词。

方法二的语音 50 个位置全部非零。这并不是好事：静音时段的声学特征也不是零，它被平均铺进了各个位置，混入了与情感无关的内容。

方法三剔除空白后，语音、视觉仍有 48.0 和 47.5 个非零位置，视觉还比方法二多了 1.4 个，说明它在保留几乎全部有效内容的同时，把位置让给了说话者

表 7　三种对齐方案的评估结果（100 条平均）

指标	方法一	方法二	方法三
平均词元数 L_{txt}	24.5	24.5	24.5
语音非零位置数（/50）	22.5	50.0	48.0
视觉非零位置数（/50）	21.1	46.1	47.5
有效时长占比	—	—	0.93
说话者脸可见帧占比	—	—	0.88

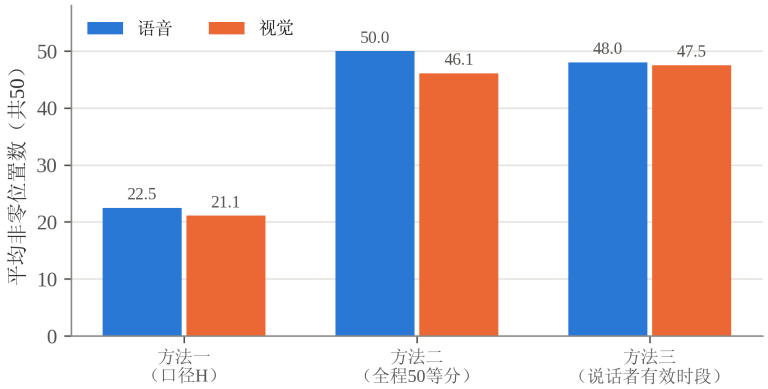


图 3　三种对齐方案下语音、视觉的平均非零位置数

可见的时段。

还有一组数字能说明为什么判据要选“说话者的脸”而不是“有没有声音”：按能量 VAD，100 条片段总共 777 秒里只有约 249 秒在说话，占 32%。如果只按声音划定有效时段，三分之二的时长会被丢掉，其中包括大量不说话、但表情仍在变化的片段。按说话者脸可见来判定，平均只剪掉约 7% 的时长；被剪掉的部分里，真正属于说话的只占全部语音帧的约 8%，而这些时刻视觉特征本来就缺失，剔除后反而保证了每个保留位置上三路特征都是完整的。

也要实事求是地说，在附件 1 上方法二和方法三的差别并不大。CMU-MOSEI 的片段大多是正对镜头的独白，说话者的脸 88% 的时间都在画面里，可剔除的空白本来就少。方法三的优势在镜头切换多、人物频繁出画的视频上会更明显，这一点我们没有条件在本题数据上验证。

5.7 典型样本验证

我们选取了一条有代表性的样本：有效时长占比 0.92，共 30 个词，含两段说话，样本编号为 **【待填：样本编号】**，文本为 **【待填：文本片段】**。图4最上方是音频能量包络，红色标出 VAD 判定的两段说话；下面三行依次是三种方案下 text、audio、vision 在 50 个位置上的非零填充模式。

【待填：把 eval/visualize_sample.py 输出的图片重命名为 q1_typical_sample.png 放入 figures/ 后重新编译】

图 4　典型样本的音频能量与三种方案的特征填充模式

从图中可以直接读出三种方案的差别：方法一只有词所在的位置非零，后面是整齐的补零；方法二把 50 个位置全部铺满，两段说话之间的静音也占了位置；方法三剔除了说话者不可见的时段，两段说话和其间仍在画面里的表情都得到保留。结合第5.4节的对应规则，任意一个位置都能还原到原文的词（方法一）或原视频的时刻与帧号（方法二、三），再回到视频中核对。

5.8 可复现性说明

全部代码按方案分目录组织，每个目录内含 text_feat.py、audio_feat.py、vision_feat.py、align.py 和入口 main.py，方法三另有 vad.py 与 face_track.py；评估与可视化脚本在 eval 目录中。BERT 与 YuNet 的权重随代码包一并提供，无需另行下载。关键参数见表8，运行环境与命令见附录附录 A。

5.9 小结

问题一用 BERT、librosa 和 YuNet 提取了 768、74、35 维的三路特征，并用同一个三角核算子给出了三种对齐方案。按词位置对齐的口径 H 与附件 2 的构造完全一致，每个位置对应一个词，可逐位回指原文；本文提出的说话者人脸跟踪方案，以“说话者的脸是否可见”划定有效时段，在 100 条样本上平均保留了 93% 的时长，语音、视觉分别有 48.0 和 47.5 个非零位置，既剔除了无人时段，又没有丢掉不说话时的表情。

表 8　问题一的关键参数

参数	取值	说明
MAX_POS	50	统一的序列位置上限
TEXT / AUDIO / VISION_DIM	768 / 74 / 35	三模态特征维度
文本模型	bert-base-uncased	取最后一层隐状态，参数冻结
音频	16 kHz，25 ms 窗 / 10 ms 帧移	librosa 声学描述子
视觉	YuNet （2023mar 版 onnx），10 fps	取面积最大的人脸
对齐核	三角核	式 (1)
VAD_ENERGY_RATIO	0.05	语音帧阈值为峰值短时能量的 5%
VAD_MIN_SPEECH / MAX_GAP	0.15 s / 0.25 s	剔除短语音段 / 填补短静音
FACE_AREA_RATIO（κ）	0.4	说话者脸可见的面积比阈值
SEED	2026	随机种子

6. 附件 2—4 的数据核查与预处理

从这一章起转入问题二、三。与问题一自己提取特征不同，这两问直接使用附件 2—4 提供的现成特征。这一章的工作看起来是准备性质的，但后来证明是整个建模过程里最关键的一步：两个问题的技术路线，都是被这里的发现改写的。

6.1 三个附件的概况

表9汇总了三个附件的内容。附件 2 是唯一带标签的数据，模型只能在它上面训练和选型；附件 3 只有 BERT 的三路整数输入（词元编号、注意力掩码、分段编号），没有现成的文本特征；附件 4 的 20 条样本中有 5 条能按编号在附件 2 里精确找回，可以当作一个很小的带标签检验集。

本文采用对齐版特征 aligned_50.pkl，训练、验证和两个专项测试集全程使用同一版本和同一输入接口。训练集共 3395 条样本。

表 9　附件 2—附件 4 概况

附件	内容	规模	标签
附件 2	aligned_50.pkl：text $(50, 768)$、audio $(50, 74)$、vision $(50, 35)$	4850 条	极性三分类 + 强度
附件 3	text_bert $(3, 50)$、audio、vision	30 条	无
附件 4	三模态特征 + 原始 mp4 视频	20 条	无（5 条可从附件 2 找回）

6.2 零帧结构：题目说的缺失，附件 2 里几乎没有

我们把每一帧的特征向量求 L_2 范数，小于 10^{-8} 的记为“全零帧”，再按零帧所在位置把它们分成四类：整条全零、尾部连续零段、起始零段、句中零段。图5(a) 把训练集 3395 条样本逐行画出来（按语音有效长度排序，深色为零帧），(b) 是有效长度的累积分布。

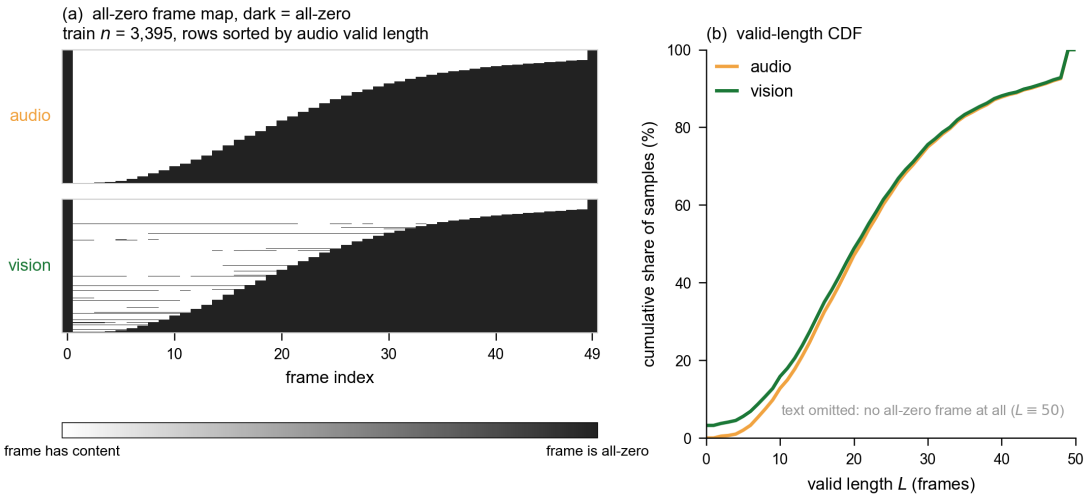


图 5　附件 2 训练集的零帧分布（a）与有效长度累积分布（b）

语音和视觉两张图的阶梯右边界几乎重合，说明两者共用同一段时间轴；文本一行深色都没有，所以没有画出来。有效长度的中位数只有 21 帧，也就是说一半以上的样本，后面二十多帧全是补齐用的零。表10给出了具体统计。

结论很直接：题目定义的“部分连续时间段不可用”，在附件 2 的语音和文本上一段都不存在，视觉上也只有 4.3% 的样本零星出现。附件 2 里所谓的连续零段，绝大多数是“这句话本来就这么长”留下的填充。附件 3 恰好相反，30 条样本全部含句中连续缺失（语音 30/30，视觉 30/30），显然是人为构造的专项测试集。

这个发现改变了问题二的技术路线。如果照搬文献中的缺失设定去训练

表 10　附件 2 训练集（$N = 3395$）零帧统计

现象	统计结果	性质
尾部连续零段	占零帧比例：语音 96.28%，视觉 89.18%；中位长度约 29 帧	变长序列补齐
第 0 帧全零	语音 100% 的样本，视觉 94% 的样本	对齐产物
句中连续零段	语音 0 段，文本 0 段；视觉 210 段（146 条，4.3%）	零星
文本零帧比例	0.0%（50 帧全部有值）	无缺失

（整条模态丢弃，或者逐帧独立随机丢弃），模型面对的失效模式和附件 3 根本不是一回事，训练出来的“鲁棒性”是假的。图6把几种形态放在一起对比：(a) 是附件 2 的真实结构，(b)(c) 是基线代码中的两种缺失模拟方式，(d) 才是题目要求的连续段缺失。四种形态的总体缺失率在 42.6% 到 58.2% 之间，相差不大，但 (b)(c) 根本造不出句中的连续段。

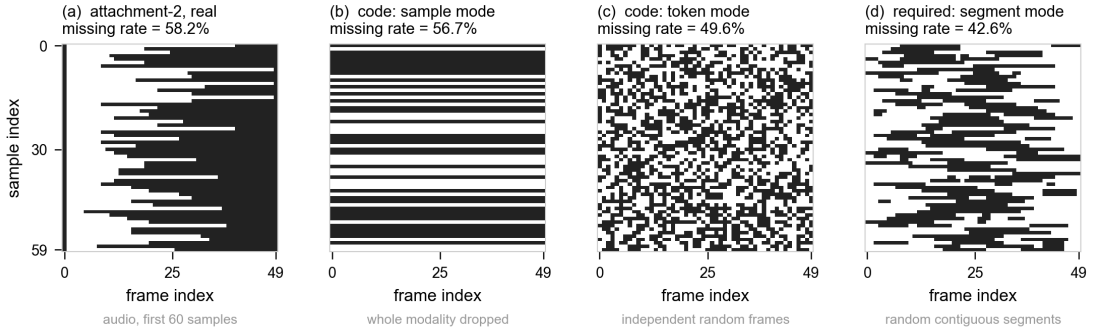


图 6　缺失形态对比：(a) 附件 2 真实结构；(b) 整模态丢弃；(c) 逐帧独立丢弃；(d) 连续段缺失

6.3 50 个序列位置到底是什么

问题三要求证据“能对应至原始文本片段、语音时段或视觉关键帧”，这逼着我们先弄清楚 50 个序列位置的物理含义。如果不知道一帧代表什么，所谓的“关键帧”就无从谈起。

如果 50 帧是按时间等间隔采样的，有效长度应该和片段时长相关。实测结果却是：语音有效长度与文本词元数完全线性相关，

$$L_a = \mathrm{nnz}(\texttt{input_ids}) - 1, \qquad \mathrm{corr}\big(L_a,\ \#\mathrm{tokens}\big) = 1.0000, \tag{6}$$

其中 $\mathrm{nnz}(\cdot)$ 表示非零元素个数。该关系在训练、验证、测试三个划分上逐条成

立，没有例外。结合 `input_ids` $= [\,$`[CLS]`$, w_1, \ldots, w_K,$ `[SEP]`$, 0, \ldots]$ 的结构可知，第 t 帧对应第 t 个词元：第 0 帧对应 `[CLS]`（这也解释了为什么第 0 帧几乎总是全零），第 1 到第 K 帧依次对应句中的词元。所以这 50 帧不是时间采样，而是词级对齐。这与问题一中口径 H 的构造（式 (2)）完全一致：第 0 帧为零，有效长度等于词元数减 1，其后全部补零。问题一选择复刻这一口径，依据就在这里。

由此得到两条后面直接用到的结论：

(1) 文本证据可以精确回指：帧号 $\rightarrow$ 词元 $\rightarrow$ `tokenizer.decode` $\rightarrow$ 原文的词，任何一条证据都能当场人工核对。

(2) 语音、视觉只能给“词级锚点”：数据里没有逐词时间戳，只能说“说第 t 个词时的那段语音或表情”，给不出绝对秒数。

对于第二条，我们也考虑过用“平均词长 $\times$ 总时长”估一个秒数，但这样得到的数字误差没法控制，恰恰违背了“可复核”的要求，所以最终只给能给准的东西。

6.4 预处理

预处理共三步，做法和理由见表11。

表 11　预处理步骤

步骤	做法	原因
有效长度提取	在标准化**之前**，从原始特征计算 L_m，见式 (7)	标准化后填充位置的零会变成常数向量，边界就检测不出来了
标准化	语音、视觉用训练集统计量做 z-score，见式 (8)；文本保持 BERT 原值	避免信息泄漏；COVAREP[12] 语音特征原始值可达 500，量纲差异很大
文本重建	附件 3 只有词元编号，用 bert-base-uncased[8] 现场编码	已验证附件 2 的 text 字段就是该模型的 last_hidden_state

有效长度和标准化分别为

$$L_m = 1 + \max\left\{\, t : \ \|U_m^0[t]\|_2 > 10^{-8} \,\right\}, \tag{7}$$

$$\tilde{U}_m[t,k] = \frac{U_m^0[t,k] - \mu_{m,k}}{\sigma_{m,k}}, \qquad m \in \{a, v\}, \tag{8}$$

其中 $\mu_{m,k}$、$\sigma_{m,k}$ 是训练集第 k 维特征的均值和标准差。

表11第一行的顺序问题是我们实际踩过的坑。最初我们先做标准化，再用标准化后的数据去算有效长度，结果零帧率从 55% 一下变成了 0%，所有填充帧都“消失”了。原因就是 z-score 把全零向量变成了常数向量 $(0-\mu)/\sigma$，按范数判断就再也找不到它们。

文本重建一步也做了核对：在附件 2 上，用同一个 bert-base-uncased 模型对 text_bert 字段重新编码，得到的结果与现成的 text 字段相关系数为 1.0000，平均绝对差为 0.0000 （保留四位小数）。因此附件 3 重建出的文本特征与训练数据处在同一个空间里。

7. 基础模型：语言主导融合与自蒸馏

问题二和问题三用的是同一个预测网络。这一章先把它建好：以文献[6]提出的 LDSD 为骨架，做两处必要的适配。问题二在此基础上改造缺失处理，问题三在它外面加解释层。

7.1 为什么选 LDSD

多模态情感分析的主流做法大致有两类：一类是跨模态注意力融合，如 MulT[4]；另一类是先学模态不变与模态特有的表示再融合，如 MISA[13]、Self-MM[14]。它们大多默认三路输入完整。面向缺失的工作则多采用重建或蒸馏的思路，如 TFR-Net[15]、LNLN[16]。

LDSD 有两个设计正好对应本题的需要。第一是语言主导：把语言作为主模态，语音和视觉作为辅助，用语言去“查询”辅助模态中有用的部分，这一思路来自 ALMT[17]。第6.2节已经看到，附件 2 的文本 50 帧全部有值，语音、视觉则大量是填充，让信息最稠密的模态当主导是合理的。第二是自蒸馏重建：教师网络看完整输入，学生网络看缺失输入，用教师的重建结果指导学生，恰好对应“缺失下重建信息”的需求。当然，“语言主导”在本题数据上是否真的成立，不能只凭直觉，第8.3节会用两组消融专门检验。

7.2 网络结构

网络结构如图7所示，下面按数据流向逐层写出。

（1）模态嵌入。三路输入维度各不相同，先各自拼接一个随机初始化、可学习的模态嵌入张量 H_m^0，再经线性投影和一层 8 头 Transformer 统一到 d 维：

$$H_m^1 = E_m^1\big(\text{concat}(H_m^0,\, U_m^1)\big) \in \mathbb{R}^{T\times d}, \qquad m \in \{l,a,v\}. \tag{9}$$

缺失在这一步注入：语音、视觉的缺失帧置零；语言的缺失帧替换为一个可学

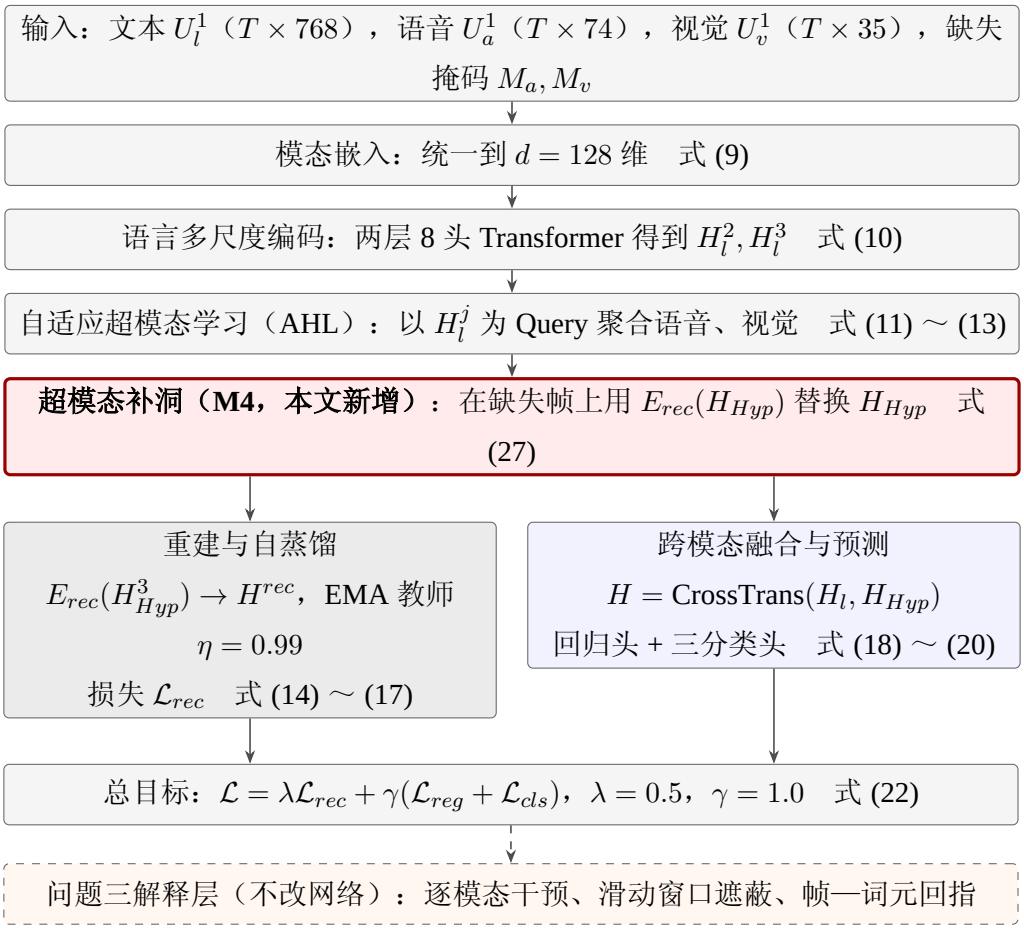


图 7　预测网络结构（红框为问题二新增的补洞模块，它与左下方的重建器共用 E_{rec}；虚线框为问题三的解释层）

习的 [UNK] 向量（文献[6]用的是 BERT 的 [UNK] 词元，这里取它在特征空间里的等价物）。

（2）语言多尺度编码。语言是主模态，在 H_l^1 之上再叠两层编码器，得到三个尺度：

$$H_l^i = E\big(H_l^{i-1};\, \theta_{E_l}^i\big) \in \mathbb{R}^{T \times d}, \qquad i \in \{2, 3\}. \tag{10}$$

与式 (9) 中把输入写进初始化张量的嵌入层不同，这两层直接对语言特征本身建模。

（3）自适应超模态学习。第 j 层以语言第 j 个尺度作 Query，从语音、视

觉中聚合信息：

$$\alpha = \text{softmax}\left(\frac{H_l^j W_{Q_l} W_{K_a}^\top H_a^{1\top}}{\sqrt{d_k}}\right), \tag{11}$$

$$\beta = \text{softmax}\left(\frac{H_l^j W_{Q_l} W_{K_v}^\top H_v^{1\top}}{\sqrt{d_k}}\right), \tag{12}$$

$$H_{Hyp}^j = H_{Hyp}^{j-1} + \alpha H_a^1 W_{V_a} + \beta H_v^1 W_{V_v}, \qquad j \in \{1,2,3\}, \tag{13}$$

其中 $d_k = 16$，共 8 头。$\alpha_{t,t'}$ 的含义是“语言第 t 个词在多大程度上关注语音第 t' 帧”，这本身就是一条可解释线索，第9章会用到。

（4）重建与自蒸馏。重建器由两层 8 头 Transformer 加线性输出层构成，从超模态表示中重建三个模态：

$$H_m^{rec} = E_{rec}\big(H_{Hyp}^3\big), \qquad m \in \{v,a,l\}, \tag{14}$$

$$H^{rec} = \text{concat}\big(H_v^{rec}, H_a^{rec}, H_l^{rec}\big). \tag{15}$$

教师网络接收完整输入，学生网络接收缺失输入，重建损失约束两者的重建结果一致；教师不参与梯度更新，参数由学生的指数滑动平均（EMA）得到[18]：

$$\mathcal{L}_{rec} = \frac{1}{N_b}\sum_{n=1}^{N_b} \big\| H_{tea,n}^{rec} - H_{stu,n}^{rec} \big\|_2^2, \tag{16}$$

$$\theta_t^{tea} = \eta\,\theta_{t-1}^{tea} + (1-\eta)\,\theta_t^{stu}, \qquad \eta = 0.99. \tag{17}$$

因为教师看到的是完整输入，它的重建结果代表“信息无损时应有的样子”，比单纯的自监督重建目标更强[19]。

（5）跨模态融合。在语言和超模态序列前各拼接一个可学习的汇聚向量 H^0，由主导模态提供 Query、超模态提供 Key 和 Value：

$$H_l = \text{concat}\big(H^0, H_l^3\big), \qquad H_{Hyp} = \text{concat}\big(H^0, H_{Hyp}^3\big), \tag{18}$$

$$H = \text{CrossTrans}\big(H_l, H_{Hyp}\big) \in \mathbb{R}^{1\times d}. \tag{19}$$

（6）预测与损失。

$$\hat{y}_{reg} = \text{regressor}(H), \qquad \hat{y}_{cls} = \text{classifier}(H), \tag{20}$$

$$\mathcal{L}_{reg} = \big\| y - \hat{y}_{reg} \big\|_2^2, \qquad \mathcal{L}_{cls} = \text{CE}\big(c, \hat{y}_{cls}\big), \tag{21}$$

$$\mathcal{L} = \lambda\,\mathcal{L}_{rec} + \gamma\,\mathcal{L}_{sp}, \qquad \mathcal{L}_{sp} = \mathcal{L}_{reg} + \mathcal{L}_{cls}, \qquad \lambda = 0.5,\ \gamma = 1.0, \tag{22}$$

其中 y 为强度标签，c 为三分类极性标签，CE 为交叉熵。

7.3 两处适配

复现时我们只做了两处改动，都有明确理由，没有随意调整结构。

一是增加了三分类头。原文的预测损失只有回归的均方误差，分类指标由回归输出分箱得到。但本题明确要求用准确率和 F1 评价极性，附件 2 又自带三分类标签，所以我们在融合表示 H 之后并联了一个三分类头，见式 (20) 和式 (21)。

二是没有实现原文实验表格中出现的“对抗学习”一项。原文第 3 节正文中找不到它的公式和训练细节，我们不愿意凭猜测补一个进去，因此这一项没有实现。

7.4 评价指标

极性分类用三分类准确率 Acc-3 和宏平均 F1 （F1-macro），强度回归用 MAE 和皮尔逊相关系数：

$$\text{Acc} = \frac{1}{N}\sum_{n=1}^{N} \mathbb{1}\big[\hat{c}_n = c_n\big], \qquad \text{F1}_{\text{macro}} = \frac{1}{3}\sum_{k=1}^{3} \frac{2P_k R_k}{P_k + R_k}, \tag{23}$$

$$\text{MAE} = \frac{1}{N}\sum_{n=1}^{N} \big|y_n - \hat{y}_n\big|, \qquad \text{Corr} = \frac{\sum_n (y_n - \bar{y})(\hat{y}_n - \bar{\hat{y}})}{\sqrt{\sum_n (y_n - \bar{y})^2}\sqrt{\sum_n (\hat{y}_n - \bar{\hat{y}})^2}}, \tag{24}$$

其中 P_k、R_k 为第 k 类的查准率和查全率。为了便于和文献对照，另外报告按 CMU-MOSEI 常用做法由强度值换算得到的 Acc-2、Acc-5、Acc-7。需要说明的是，F1-macro 对三类一视同仁，任何一类识别得差都会明显拉低它，比 Acc-3 更能暴露类别之间的不均衡，所以本文在比较模型时更看重 F1-macro。

8. 问题二：模态局部缺失下的鲁棒情感预测

这一章的顺序和我们实际推进的顺序一致：先看基线在附件 2 上的表现，再用鲁棒性曲线和消融找它的短板，然后针对局部连续缺失做改造，最后分析缺失规律并对附件 3 推理。除特别注明“验证集”的结果外，本章表格中的数值均在附件 2 测试集上计算，且都是全量训练（3395 条训练样本、200 轮）后的结果。

8.1 基线的基础性能

表12给出了复现后的基线在完整模态和整模态缺失（$r = 0.5$）两种条件下的结果。

作为参照，三分类随机猜测的准确率是 33.3%，二分类约 50%。完整模态下 Acc-2 为 74.00%，文献[6]报告的 Acc-2 为 73.48%，两者数据集不完全相同，

表 12　基线 LDSD 的基础性能（准确率与 F1 单位为 %）

条件	Acc-3	F1-macro	MAE	Corr	Acc-2	Acc-5	Acc-7
完整模态	68.78	60.48	0.6628	0.6722	74.00	52.41	44.57
整模态缺失 $r = 0.5$	58.32	45.80	0.7646	0.4959	64.10	46.91	41.54

不能直接比高低，但处在同一量级，说明复现是可信的。MAE 为 0.6628、皮尔逊相关系数为 0.6722，也都明显好于随机水平。

图8是训练过程中验证集（$r = 0.5$）上的指标变化。验证集 MAE 在第 10 轮左右最低（约 0.72），之后逐渐上升，到第 110 轮前后达到约 0.88，最后回落到 0.80 附近；Acc-3 的走势与之对应，早期约 53%，后期大致在 44% ∼ 51% 之间波动。这说明在 3395 条训练样本上，模型训练到中后期出现了过拟合，训练轮数还有调整空间，第8.10节会再回到这一点。

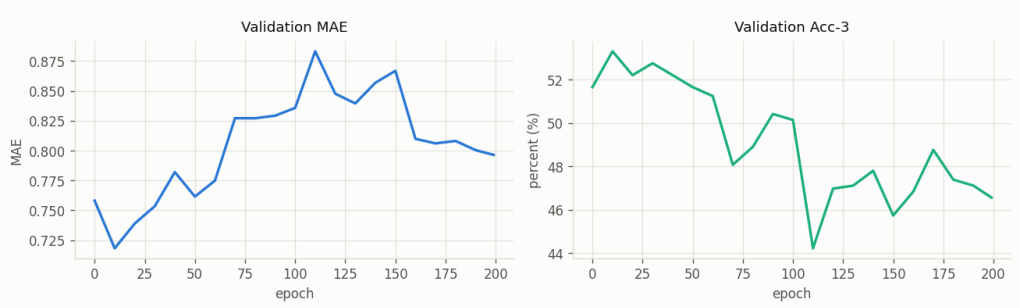


图 8　训练过程中验证集（$r = 0.5$）的 MAE （左）与 Acc-3 （右）

8.2 基线在整模态缺失下的鲁棒性

我们在整模态缺失模式下把缺失率 r 从 0 逐步加到 0.9，结果见表13和图9。

整体看，性能随缺失率平滑下降，没有出现突然崩溃的拐点；即使 $r = 0.9$，Acc-3 仍有 50.76%，高于随机水平。但两类指标掉得并不一样快：从 $r = 0$ 到 $r = 0.9$，Acc-3 下降了 18.02 个点，F1-macro 却下降了 31.77 个点，在 $r = 0.9$ 时只剩 28.71%，已经低于 33.3% 的随机水平。准确率还说得过去而宏平均 F1 低于随机，说明缺失严重时模型的预测集中到了少数类别上，某一类几乎不再被预测出来。这是第8.10节错误归因的第一条线索。

表 13　不同缺失率下基线的性能（整模态缺失）

r	0.0	0.2	0.4	0.5	0.6	0.8	0.9
Acc-3/%	68.78	65.47	62.04	59.56	56.40	54.33	50.76
F1-macro/%	60.48	56.04	51.43	47.03	42.13	35.88	28.71
MAE	0.6628	0.6927	0.7527	0.7693	0.7750	0.8178	0.8619
Corr	0.6722	0.6164	0.5240	0.4883	0.4467	0.3440	0.2283

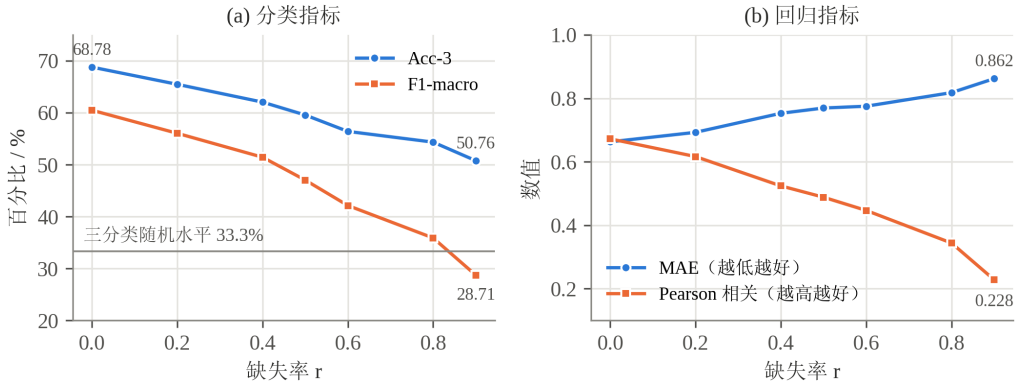


图 9　基线性能随缺失率的变化

8.3 三组消融：语言是不是主导，各组件有没有用

LDSD 的核心主张有三条：语言不可或缺、以语言为主导模态最优、自蒸馏与重建有益。我们按这三条分别做了三组消融，每组回答一个问题，统一在 $r = 0.5$ 的整模态缺失下评测。

（1）模态消融：语言是不是不可或缺。把某个模态的输入永久置为全缺失，并去掉它在 AHL 中的贡献，其余不变，结果见表14。

去掉语言是断崖式的：F1-macro 从 45.80% 跌到 22.16%，皮尔逊相关从 0.4959 掉到 0.1620，模型几乎失去了与人工标注的相关性。去掉语音或视觉的影响则温和得多，去掉视觉后 F1 甚至略有上升，不过幅度在正常波动范围内。

这组结果不是可有可无的对比。整个网络建立在“语言主导”的前提上，式 (11) ∼ (13) 和式 (19) 都让语言当 Query。如果去掉语言影响不大，那就说明前提是错的，后面所有围绕语言设计的模块都失去了依据。

（2）主导模态消融：让语言当主导是不是最好的选择。上一组只说明了语言“不能少”，没有说明“让它当主导最好”。万一让语音主导效果更好呢？

表 14　模态消融结果

设置	Acc-3/%	F1-macro/%	MAE	Corr	F1 相对完整模型
完整模型	58.32	45.80	0.7646	0.4959	—
去掉语言	49.79	22.16	0.8772	0.1620	−23.6
去掉语音	57.63	42.74	0.7643	0.5076	−3.1
去掉视觉	58.60	48.32	0.7578	0.5086	+2.5

所以我们把主导模态分别换成语音和视觉，即让该模态走三尺度编码、充当融合层的 Query，另外两个模态充当超模态，结果见表15。

表 15　主导模态消融结果

主导模态	Acc-3/%	F1-macro/%	MAE	Corr
语言	**58.32**	**45.80**	**0.7646**	**0.4959**
语音	57.08	43.40	0.7736	0.4673
视觉	56.67	45.04	0.7697	0.4744

语言主导在四项指标上全部最优。语音主导时 F1 低 2.4 个点、相关系数低 0.029；视觉主导时 Acc-3 低 1.7 个点。两组合起来，才完整支撑了“语言主导”这个设计：第一组说明语言必要，第二组说明把主导权交给语言是最好的安排。

（3）组件消融：自蒸馏和重建到底有没有用。逐个去掉四个组件，保持其余结构不变，结果见表16。

结果要分两层看。正面的一层：去掉自蒸馏后 F1 下降 8.3 个点、MAE 上升 0.044，是四个组件里影响最大的；去掉超模态融合也明显退化。这说明 EMA 教师提供的重建目标确实比单纯的自监督目标更有用，跨模态融合也是有效的。

反直觉的一层：去掉重建（MAE 0.7538）和去掉 AHL （MAE 0.7441）之后，MAE 和相关系数反而比完整模型略好。也就是说，原文“重建有益”的结论在本题数据上只得到了部分复现。我们如实报告这个结果，因为它本身有信息量。我们的理解是：在整模态缺失的设定下，一整路信号都没了，重建目标

表 16　组件消融结果

设置	Acc-3/%	F1-macro/%	MAE	Corr	判断
完整模型	58.32	45.80	0.7646	0.4959	基准
去掉自蒸馏	56.26	37.48	0.8085	0.4639	明显退化
去掉超模态融合	57.91	43.34	0.7772	0.4695	退化
去掉重建	56.95	47.16	0.7538	0.5058	F1、MAE 反而略好
去掉 AHL	58.32	46.69	0.7441	0.5098	MAE、Corr 反而略好

高度不确定，重建头学到的更像是一种“均值式”的补偿，反而冲淡了判别信号；去掉 AHL 后 MAE 更好，则说明样本级缺失时，AHL 学到的注意力权重可能引入了噪声。

这组结果直接推动了我们后面的两个决定。一是把训练时的缺失模拟改成连续段形态：整模态缺失下这两个模块表现不稳，恰恰说明“缺失的形态”很关键。二是让重建结果真正进入推理路径：如果重建只是算一个损失就被丢掉，它学不到有用的东西也就不奇怪了。第8.4.3节的 M4 就是这样来的。

8.4 面向局部连续缺失的改进

8.4.1 缺失的形式化

用掩码 $M_m \in \{0,1\}^T$ 描述模态 m 的缺失，$M_m[t]=1$ 表示第 t 帧不可用。注入缺失后，语音和视觉按 $U_m^1 = U_m^0 \odot (1-M_m)$ 置零，语言的缺失帧替换为可学习的 `[UNK]` 向量。按掩码的生成方式，可以区分三种缺失模式：

$$M_m[t] = \begin{cases} b_m, \quad b_m \sim \text{Bernoulli}(r), & \text{整模态丢弃（sample），} \\ b_{m,t}, \quad b_{m,t} \overset{\text{i.i.d.}}{\sim} \text{Bernoulli}(r), & \text{逐帧独立丢弃（token），} \\ \mathbb{1}\big[t \in \mathcal{M}_m\big], \quad \mathcal{M}_m \text{ 为若干连续区间之并}, & \text{连续段缺失（segment）.} \end{cases} \tag{25}$$

前两种是基线代码实际使用的模式，第三种才是附件 3 中的形态。三种模式下 r 的含义不同：整模态模式中是一个模态被整条丢弃的概率，后两种模式中是缺失帧所占的比例。

8.4.2 M1：连续段缺失增强

文献[6]第 3.2 节的文字描述是“随机遮蔽片段”（randomly masking segments），但我们阅读其公开代码后发现，实际实现是逐帧独立的伯努利采样，与“连续段”并不是一回事。这个差别在散点缺失下看不出来，换成连续段就会暴露（见第8.5节，相差 9.4 个点）。因此我们显式构造连续段：

$$
\begin{aligned}
(\rho_1, \ldots, \rho_k) \sim \mathrm{Dirichlet}(0.6 \cdot \mathbf{1}_k), \qquad \ell_j = \max\big(1,\ \lfloor \rho_j\, rT \rfloor\big), \\
\mathcal{M}_m = \bigcup_{j=1}^{k} \big[a_j,\ a_j + \ell_j\big),
\end{aligned}
\tag{26}
$$

其中段数 $k \sim \mathcal{U}\{1,2,3\}$，$\ell_j$ 为第 j 段的长度，各段在互不相交的区块内选取起点 a_j。

用 Dirichlet 分布分配段长，是为了让段长有足够的区分度：短段可以借邻域插值补回来，长段不行；如果生成的段长都差不多，评测时按段长分桶就看不出差异。这一点我们在调试阶段实际吃过亏：第一版的段长分布没有调好，93% 的样本都落进了“长段”桶，分桶结果什么也说明不了。最终浓度参数取 0.6：浓度小于 1 时，各段分到的长度差异更大，更容易同时产生很短和很长的缺失段。

8.4.3 M4：超模态补洞

文献[6]第 3.1 节的概述中说重建出的模态特征被用于语言主导的预测，但从其式 (6) ∼ (8) 看，重建结果只参与了 $\mathcal{L}_{rec}$ 的计算，并没有进入推理路径。对连续段缺失来说，这个区别是决定性的：模型必须在洞里显式地填入推断出的表征，而不能指望下游模块自己学会忽略这个洞。因此我们补上这条通路：

$$
H_{Hyp} \leftarrow H_{Hyp} \odot (1 - m) + E_{rec}\big(H_{Hyp}\big) \odot m, \qquad m = \max\big(M_a, M_v\big), \tag{27}
$$

即在语音或视觉任一模态缺失的帧上，用重建器的输出替换超模态表示，其余帧保持不变。这样重建器一方面仍受式 (16) 的自蒸馏监督，另一方面它的输出直接影响预测，梯度会把“补得像不像”和“预测得准不准”绑在一起。

8.4.4 其余三个候选模块

除 M1 和 M4 外，我们还准备了另外三个候选，思路都是“让模型知道哪里缺了”：

- **M2 有效性 token**：为“缺失”和“填充”两种状态各设一个可学习向量，叠加到对应帧上，让模型能区分“本来没有”和“丢了”。
- **M3 掩码加权损失**：把式 (16) 的重建损失限制在缺失位置上计算，想让重建头把力气用在洞上。

• **M5 掩码注意力**：在 AHL 的式 (11)(12) 中屏蔽缺失帧对应的 Key/Value。

这五个模块哪个有用，我们事先并没有把握，所以决定全部实现，用数据决定去留。

8.5 候选模块的逐级筛选

筛选规则。把模块逐个叠加上去，每加一个就与当前最好的配置比较一次边际增益；没有增益或者有损就淘汰，下一个模块仍然叠加在最后一个有效配置上。

评测掩码。所有配置统一用一套固定的分层连续段掩码评测：短段（最长缺失段 ≤ 5 帧）占 40%、中段（6 ～ 15 帧）占 35%、长段（$>$ 15帧）占 25%。所有配置共用同一套掩码，并按样本中最长缺失段的长度分桶统计，这样不同配置之间才可比。评价时同时看三个量：段缺失下的 F1-macro、长段缺失下的 MAE，以及完整模态下的 F1-macro （用来确认改进没有伤害完整输入时的表现）。

先看 M1 单独的作用（表17）。这组实验只改训练时的缺失模拟方式，把逐帧散点换成连续段，其余完全不变。

表 17　连续段缺失增强（M1）的作用

配置	段缺失 F1-macro/%	长段 MAE	完整模态 F1-macro/%
基线（逐帧散点训练）	47.63	0.7168	56.65
+M1 （连续段训练）	**57.03**	**0.6666**	**57.65**

仅仅改变训练时的缺失模拟方式，段缺失 F1 就提升了 9.4 个点，长段 MAE 下降 0.050，完整模态下的 F1 也没有退化（56.65%→57.65%）。这证实了我们一开始的判断：连续段缺失和散点缺失是两种不同的失效模式，模型必须专门见过才会应对。而且 M1 不改网络结构，只改训练数据的构造方式，是性价比最高的一项。

接着在 M1 之上逐个叠加其余四个模块，结果见表18和图10。

只有 M4 带来了实质增益：段缺失 F1 提升 3.2 个点，完整模态 F1 同步提升 3.2 个点，长段 MAE 下降 0.009。其余三个都没有通过：

M2 的 F1 只比参照高 0.22 个点，长段 MAE 反而从 0.6666 变差到 0.6702，这点增益在噪声范围内，不足以成为保留的理由。

M3 明确有害。事后分析原因：把重建损失限制到缺失位置后，监督信号

表 18　候选模块逐级筛选结果

配置	段缺失 F1/%	长段 MAE	完整模态 F1/%	结论
M1 （参照）	57.03	0.6666	57.65	基准
M1+M2	57.25	0.6702	57.92	增益在噪声内，淘汰
M1+M3	56.37	0.6865	56.92	有害，淘汰
M1+M4	**60.21**	**0.6572**	**60.86**	保留
M1+M4+M5	58.02	0.6708	56.81	有害，淘汰

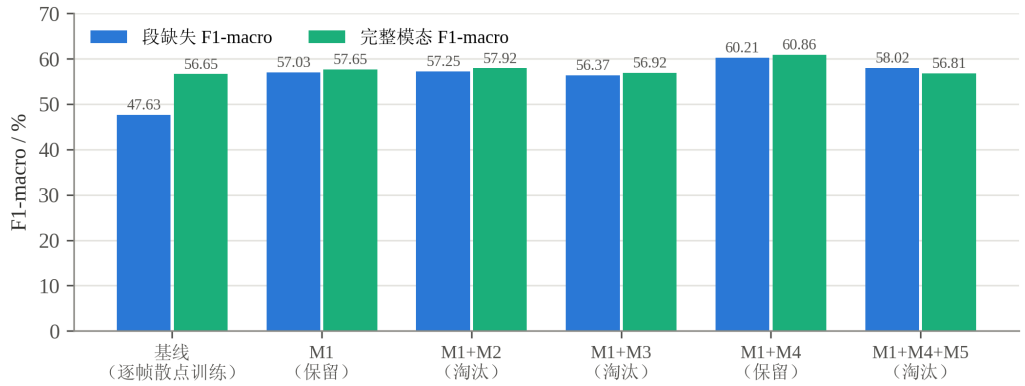


图 10　候选模块筛选过程中段缺失与完整模态下的 F1-macro

变得很稀疏，重建头在观测帧上失去了约束，开始“漂移”。本想让损失更聚焦，结果削弱了整体约束。

M5 同样有害。屏蔽掉大量 Key/Value 之后，注意力可用的上下文反而变少了，完整模态 F1 和长段 MAE 都比 M1+M4 差。

这里有一个流程上的教训值得单独记下。M3 判定失败时，我们原先已经把 M4、M5 叠在“M1+M3”这个坏配置上跑了一轮，那一轮结果完全不可用，只好回到最后一个有效配置 M1 上重跑，才判定出 M4 有效。如果省掉这次重跑，M4 的增益会被 M3 的损害掩盖掉，很可能被误判为无效。

回头看这组筛选，M2 和 M5 都是在给模型提供“哪里缺了”的额外信息，但都没用；真正起作用的 M4 不只是告诉模型洞在哪，而是直接把洞填上。最终保留 M1 与 M4，记为 LDSD-Seg。

8.6 训练方案与关键参数

表19列出了 LDSD-Seg 的主要配置。结构参数与文献[6]保持一致，缺失相关的参数由第8.5节的筛选确定。

表 19　LDSD-Seg 的训练方案与关键参数

项目	设置
训练数据	附件 2 aligned_50.pkl 训练集 3395 条；验证集用于选择结构与阈值
序列与维度	$T = 50$，$d = 128$，8 头注意力，$d_k = 16$
语言多尺度编码	在 H_l^1 上叠加两层 8 头 Transformer
重建器 E_{rec}	两层 8 头 Transformer + 线性输出层
自蒸馏	教师为学生参数的 EMA，$\eta = 0.99$
损失权重	$\lambda = 0.5$，$\gamma = 1.0$，$\mathcal{L}_{sp} = \mathcal{L}_{reg} + \mathcal{L}_{cls}$
缺失增强（M1）	段数 $k \sim \mathcal{U}\{1, 2, 3\}$，段长按 Dirichlet$(0.6)$ 分配
补洞（M4）	$m = \max(M_a, M_v)$，见式 (27)
训练轮数	200 轮
优化器、学习率、批大小	【待填：从配置文件抄录】
运行环境与耗时	Kaggle GPU；全部实验总耗时 7772.6 s （约 2.16 h）

8.7 LDSD-Seg 的全量确认

筛选阶段的结论要在最终配置上再确认一次。我们把基线（整模态缺失增强，无补洞）与 LDSD-Seg 放在同一套固定分层连续段掩码下评测。用同一套掩码是关键，否则两者面对的缺失样本不同，数字没法比。结果见表20和图11。

段缺失 F1 从 47.26% 提升到 61.70%，MAE 从 0.7112 降到 0.6639。分桶看，长段 MAE 的降幅（0.066）大于整体（0.047），说明改进确实作用在最难的情

表 20　局部连续缺失下基线与 LDSD-Seg 的对比

配置	段缺失（整体）			按最长缺失段分桶的 MAE		
	MAE	F1/%	Acc-3/%	短段	中段	长段
基线 LDSD	0.7112	47.26	63.82	0.6780	0.7034	0.7205
LDSD-Seg	**0.6639**	**61.70**	**67.81**	**0.6175**	**0.6849**	**0.6548**
变化量	−0.047	+14.4	+4.0	−0.061	−0.019	−0.066

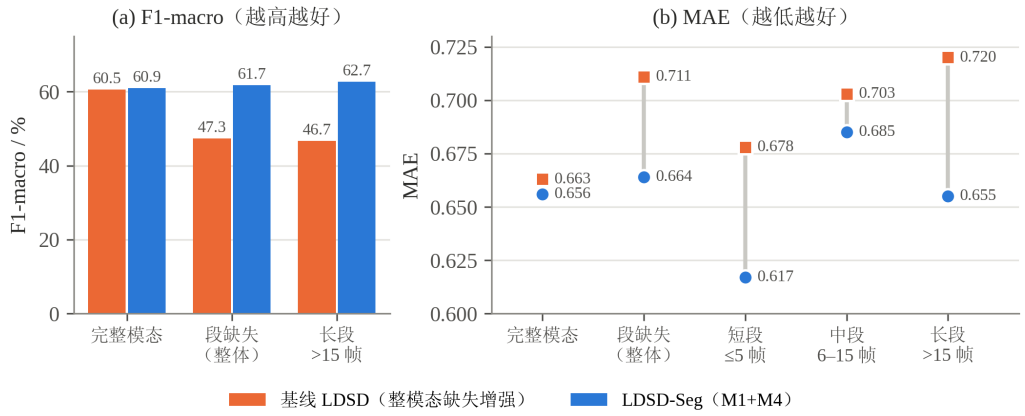


图 11　同一套分层连续段掩码下，基线与 LDSD-Seg 的 F1-macro（a）和 MAE（b）

形上，而不是靠容易的样本刷分。不过中段的改善最小，只有 0.019，这一点我们目前还没有找到令人满意的解释，只能如实列出。

比起绝对性能，“缺失让性能掉了多少”更能说明鲁棒性。表21是验证集上完整模态与段缺失之间的落差。

表 21　验证集上完整模态与段缺失之间的 F1-macro 落差

模型	完整模态 F1/%	段缺失 F1/%	落差
基线 LDSD	55.56	39.93	−15.6
LDSD-Seg	59.36	**59.47**	+0.1

基线一遇到连续段缺失就掉 15.6 个点，LDSD-Seg 在同样条件下几乎不掉

（+0.1，在波动范围内）。我们最初的动机只是“题目要求处理局部缺失”，但真正让我们决定保留这两个模块的依据是这个落差：它比绝对性能更直接地反映了鲁棒性有没有真的改善。

还要说明一点：同一个 M1+M4 配置，在筛选实验中段缺失 F1 为 60.21%，在这里为 61.70%，两次运行相差约 1.5 个点。这提示单次运行的结果存在一定波动，表中小于 1 个点左右的差异不宜过度解读。

8.8 缺失类型、位置与时长的影响规律

8.8.1 实验设计

题目要求分析缺失模态类型、缺失位置、缺失时长对性能的影响。我们做了三因子扫描：

- 模态类型：$\{l, a, v\}$ 的 6 个非空真子集，即 l、a、v、l+a、l+v、a+v；
- 位置：缺失段位于内容的前部（head）、中部（mid）、尾部（tail）；
- 时长：$\rho \in \{0.10, 0.25, 0.50, 0.75, 0.90, 1.00\}$，$\rho$ 为缺失段占该模态自身内容跨度的比例。

共 $6 \times 3 \times 6 = 108$ 个单元。模型固定为训练好的 LDSD-Seg，只训练一次，所有因子组合都只在评测时构造掩码、重新跑前向，因此 108 个单元不需要训练 108 次，扫描本身只占全部耗时的 1 ～ 2 分钟。指标为相对完整模态的 MAE 增量 ΔMAE。

8.8.2 设计中修正的两处错误

这两处错误都是靠事先设置的校验项抓出来的，这里单独交代一下。

位置不能用绝对帧号。我们最初统一用语音的有效长度 L_a 来划分所有模态的前、中、尾部。结果对文本来说只遮蔽了前 21 帧左右，剩下的帧照样能读出情感，实测文本缺失的 ΔMAE 竟然是负的，差点得出“语言缺失无害”这个完全错误的结论。正确做法是每个模态按自身的内容跨度取相对坐标。

ρ 必须铺到 1.0。各模态的冗余度不同，同一个 ρ 下的绝对损失量不可比。第一版的时长只取到 0.75，什么规律都看不出来；把范围扩展到 0.90 和 1.00 后，规律才显现出来。

8.8.3 校验：语言全缺时必须最差

在进入正式分析之前，先在 $\rho = 1.0$（整模态全部遮蔽）上做一次校验，记为 H1：既然第8.3节已经证明语言不可或缺，那么语言全缺时的损失理应最大。结果见表22。

语言缺失的 ΔMAE 约为语音、视觉的 200 倍（0.789 对 0.004），校验成

表 22　校验 H1：$\rho = 1.0$ 时各模态组合缺失的 ΔMAE

缺失模态	l	$l{+}a$	$l{+}v$	a	v	$a{+}v$
ΔMAE	$+0.789$	$+0.764$	$+0.752$	$+0.003$	$+0.004$	$+0.006$

立。这组数不算新发现，它和模态消融的结论一致，本就在预料之中。它的作用是检查扫描代码有没有写对：如果这里语言不是最差的，就说明坐标定义或掩码构造有 bug。事实证明这个担心不多余，上一小节的两处错误，都是因为这项校验不成立才被发现的。因子扫描是新写的代码，一旦实现有误，错误的结论就会被当成“发现”写进报告，所以我们先设了一个已知答案的检查项。

8.8.4 时长的影响

表23给出了时长的主效应及其在各模态上的分解，图12是对应的曲线。

表 23　不同缺失时长下的 ΔMAE

ρ	0.10	0.25	0.50	0.75	0.90	1.00
全部模态平均	$+0.003$	$+0.005$	$+0.008$	$+0.016$	$+0.033$	$+0.386$
语言 l	$+0.005$	$+0.008$	$+0.012$	$+0.027$	$+0.060$	$+0.789$
语音 a	$+0.001$	$+0.001$	$+0.002$	$+0.003$	$+0.003$	$+0.003$
视觉 v	$+0.000$	$+0.001$	$+0.000$	$+0.000$	$+0.000$	$+0.004$

拆到各模态看，规律完全不同。语言呈现“全有或全无”的形态：缺失 90% 以内几乎无感（$\rho = 0.9$ 时 ΔMAE 仅 0.060），一旦接近全缺就断崖式崩溃（$\rho = 1.0$ 时为 0.789，是前者的 13 倍）。语音、视觉则全程平缓，始终低于 0.006。

我们对语言这种形态的理解是：文本特征是 BERT 的上下文表示，每一帧都编码了整句的信息，即使在补齐位置上也不为零（表10中文本零帧比例为 0）。所以只要还剩一部分文本帧，模型就能从中读出整句的情感；也正因为冗余度高，剩余信息一旦不足，就再没有冗余可退，崩溃是断崖式的。语音、视觉的有效帧少（中位 21 帧）、冗余度低，信息随缺失线性流失，贡献也小，所以曲线平缓。

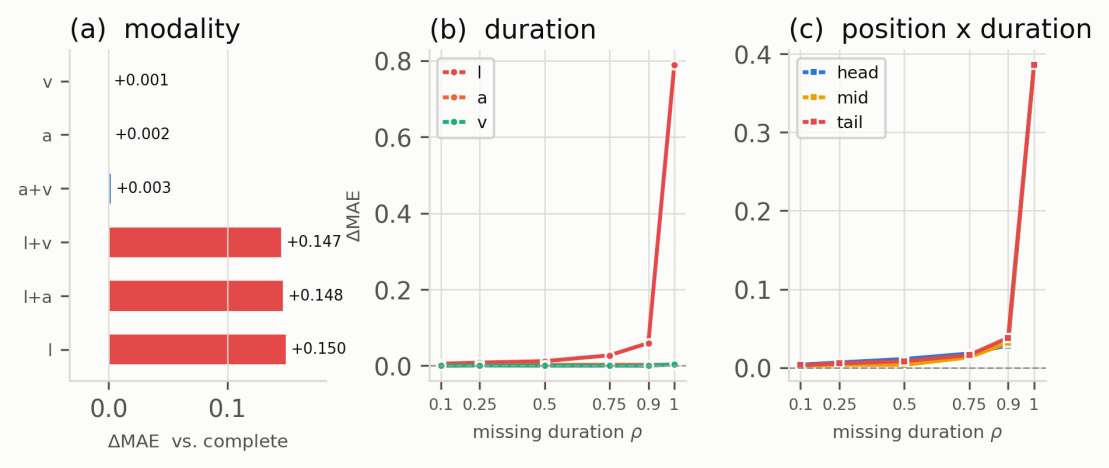


图 12　三因子扫描结果：(a) 各模态组合的平均 ΔMAE；(b) 各模态 ΔMAE 随时长的变化；(c) 不同位置下 ΔMAE 随时长的变化

8.8.5 位置的影响

表24按缺失位置分组（每组 36 个单元）给出了平均 MAE。

表 24　不同缺失位置下的平均 MAE

位置	前部 head	中部 mid	尾部 tail
MAE	0.7319	0.7296	0.7324

三者相差不到 0.003，远小于时长效应（0.386）。我们原本猜测“句子中部的缺失最要命”，这个假设被数据否定了。这可能与数据的词级对齐有关：序列不是按时间等距采样的，每一帧就是一个词，而情感线索在句中的分布并没有明显的位置偏好；再加上文本帧都是上下文表示，缺了哪一段，其余帧里多少都还留着这段的信息。

8.8.6 规律小结

三因子扫描的结论可以归纳为三句话：时长是主因，而不是位置，也不单是“哪个模态”；语言缺失 90% 以内几乎无感，接近全缺时 ΔMAE 陡增 13 倍；位置的影响可以忽略。落到应用上，在 90% 以内的缺失预算下，应优先保证语言不被整段丢掉，而不必纠结缺失发生在句子的哪个位置。换句话说，“丢了多少”比“丢在哪里”重要得多。

8.9 附件 3 的推理结果

附件 3 的推理流程与训练时的预处理完全一致：先用 bert-base-uncased 把 text_bert 重建为文本特征，在标准化之前计算各模态有效长度，再用训练集统计量对语音、视觉做 z-score，最后送入 LDSD-Seg。每条样本输出极性、极性置信度（三分类概率的最大值）、强度和主导模态。30 条样本的汇总见表25，逐条结果见附录附录 D，分布见图13。

表 25　附件 3 推理结果汇总

项目	结果
极性分布	正向 14 条，负向 11 条，中性 5 条
极性置信度均值	0.703
预测强度均值	−0.077
主导模态	文本 28 条；例外为附件 3_14 （视觉主导）和附件 3_17 （语音主导）

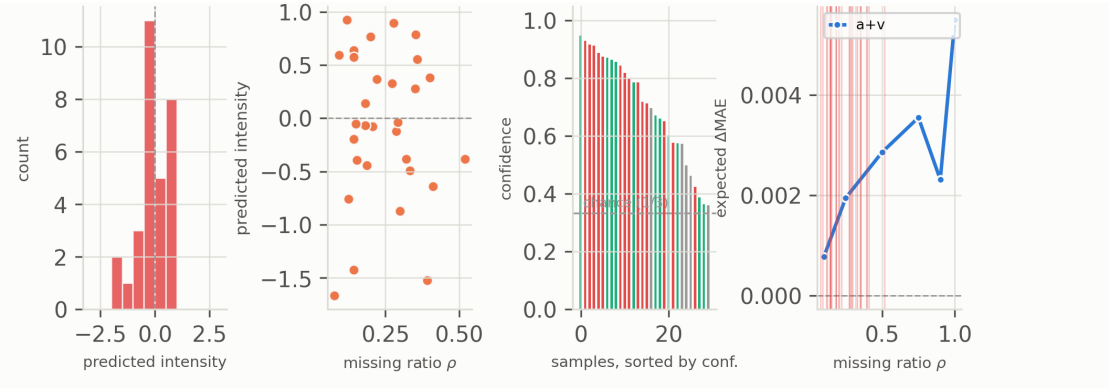


图 13　附件 3 推理结果：(a) 预测强度分布；(b) 缺失比例与预测强度；(c) 按置信度排序的极性置信度（红、绿、灰分别为正向、负向、中性）；(d) 各样本缺失比例（竖线）与因子扫描中 $a{+}v$ 缺失的预期 ΔMAE 曲线

有几点观察。第一，附件 3 的缺失全部落在语音和视觉上，缺失比例 ρ 都不超过 0.55。对照因子扫描中 $a{+}v$ 缺失的曲线（图13(d)），这个范围内预期的 ΔMAE 不超过 0.003，远没有到语言的断崖区，所以附件 3 的缺失对预测的影响应当很小；图13(b) 中预测强度与缺失比例之间也看不出明显的趋势。第二，5 条中性预测里有 4 条排在置信度最低的 7 条之内，中性样本最不“确定”，这与第8.2节 F1 掉得比准确率快的现象是吻合的。第三，附件 3_14 和附件 3_17 两条的主导模态不是文本，这在 30 条里比较特殊，建议人工回看。

需要强调的是，附件 3 没有标签，上面这些只能说明模型输出是否“合理”，不能说明它是否“正确”。附件 3 预测结果的可信度，主要取决于模型在附件 2 上的表现。

8.10 验证集上的错误归因

综合前面几节的结果，模型的错误主要来自以下几个方面。

（1）类别之间不均衡，缺失越重越明显。各种条件下 F1-macro 都明显低于 Acc-3；缺失率升高时 F1 掉得更快，$r = 0.9$ 时低于随机水平而 Acc-3 仍有 50.76%，说明预测向少数类别集中。附件 3 中中性预测的置信度普遍偏低，也指向同一个问题：中性与弱正、弱负之间的边界是模型最拿不准的地方。

（2）语言接近全缺时误差陡增。三因子扫描显示，误差几乎全部集中在语言缺失比例接近 1 的情形，ρ 从 0.9 到 1.0，ΔMAE 由 0.060 跳到 0.789。对于只丢语音、视觉的样本，模型几乎不受影响。

（3）训练后期过拟合。图8中验证集 MAE 在第 10 轮左右最低，之后整体上升，Acc-3 同步下降。3395 条训练样本对这样规模的网络来说偏少，固定训练 200 轮并不是最优的选择。

（4）整模态缺失下重建模块的补偿偏“平均”。组件消融中去掉重建、去掉 AHL 反而略好，说明在一整路信号都缺失时，重建出的内容更接近均值，稀释了判别信息。这也是我们改用连续段训练、并让重建结果进入推理路径的原因。

8.11 小结

问题二的核心发现是：题目要求的局部连续缺失在训练数据中基本不存在，照搬文献的缺失设定训练出的鲁棒性并不可靠。围绕这一点，我们从 5 个候选中筛出了连续段缺失增强（M1）与超模态补洞（M4）两个模块，在同一套分层连续段掩码下把段缺失 F1 从 47.26% 提升到 61.70%，验证集上完整模态与段缺失之间的落差从 15.6 个点缩小到 0.1 个点。三因子扫描进一步说明，缺失时长是影响性能的主因，语言缺失呈“全有或全无”的形态，位置的影响可以忽略。

9. 问题三：可解释性情感预测

问题三不再训练新的网络。解释层直接挂在第7章的预测网络外面，网络结构和参数都不改动，这样才能保证“解释的”就是“预测用的”那个模型。

9.1 把“可解释”落实成可检验的输出

题目对可解释性的要求是：说明本次判断主要依据了哪些输入，包括模态间的作用差异、主要参考模态，以及各模态中与判断密切相关的局部片段，并且证据能对应到原始材料。我们把它拆成四层，见表26。

表 26　解释框架的四个层次

层次	内容	主口径	输出
L0	回指	帧 $\leftrightarrow$ 词元，式 (6)	帧号对应的原文词
L1	模态作用程度	干预式归因	s_l, s_a, s_v，主导模态，裕度 μ
L2	片段级定位	滑动窗口遮蔽扫描	各模态逐帧重要性 $\mathrm{Imp}_m(t)$
L3	证据呈现	回指 + 相对位置	文本词组；语音、视觉的词级锚点

这里有一个关键的取舍：结论一律由扰动实验给出，注意力权重只用来生成候选和做交叉检验。理由在第9.5节展开。

9.2 L0：帧与词元的回指

第6.3节已经证明 50 个序列位置是词级对齐的：第 t 帧对应 `input_ids` 的第 t 个词元。因此任何一帧都可以经 `tokenizer.decode` 还原成原文的词，不需要任何估计。

回指时有一条必须遵守的约束：证据只能从有效帧里选。文本限于实词区间 $[1, L)$，排除 `[CLS]`、`[SEP]` 和 `[PAD]`；语音、视觉限于帧号小于 L_m 的帧。否则填充帧会被当成“关键证据”。这个坑我们实际踩过：第一版解释卡里出现过“`[PAD] [PAD] [PAD]`”这样的“证据”。原因前面也提到过，文本特征是上下文表示，补齐位置上的向量并不为零，遮蔽它们同样会让输出变化。

对语音和视觉，由于缺少逐词时间戳，我们给出“第 t 个词元处”的词级锚点，同时给出相对位置 t/L_m，方便回到原始视频中按说话进度大致定位。

9.3 L1：干预式模态归因

对样本 $\mathbf{x}$，把模态 m 按训练时的缺失注入方式整条遮蔽，记为 $\mathbf{x}_{\setminus m}$，比较遮蔽前后的输出：

$$\Delta_m^{reg} = \left|\hat{y}_{reg}(\mathbf{x}) - \hat{y}_{reg}(\mathbf{x}_{\setminus m})\right|, \tag{28}$$

$$\Delta_m^{cls} = \mathrm{KL}\Big(p(c\,|\,\mathbf{x}) \,\Big\|\, p(c\,|\,\mathbf{x}_{\setminus m})\Big), \tag{29}$$

前者衡量强度预测的偏移，后者衡量极性分布的变化。模态作用程度取分类口径归一化：

$$s_m = \frac{\Delta_m^{cls}}{\sum_{m'} \Delta_{m'}^{cls}}, \qquad \sum_m s_m = 1, \qquad m^* = \arg\max_m s_m, \qquad \mu = s_{(1)} - s_{(2)}, \tag{30}$$

其中 m^* 为主要参考模态，$s_{(1)}$、$s_{(2)}$ 为从大到小排列的前两个作用程度，μ 称为判定裕度。回归口径 Δ_m^{reg} 同时输出，作为辅助参考。

之所以额外报告裕度 μ，是因为“主导模态是文本”这句话本身信息量有限：$s_l = 0.95$ 和 $s_l = 0.40$ 都会得出同一个结论，但含义差别很大。μ 小说明两个模态的作用接近，这时读者就不应把“主导模态”看得太重。

这里用遮蔽而不用梯度类方法（如积分梯度[20]），还有一个本题特有的原因。积分梯度需要一个“基线输入”，而缺失场景下什么样的输入算“没有信息”本身就不好定义；遮蔽后的输入则正是模型训练时见过的缺失形态（假设 (4) 的说明），输出变化更可信。

9.4 L2：片段重要性扫描

用宽度为 w 的窗口在模态 m 的有效帧上滑动，只遮蔽窗口 $[t, t+w)$ 内的帧，记为 $\mathbf{x}_{\setminus m}^{[t,t+w)}$，定义第 t 帧的片段重要性为

$$\mathrm{Imp}_m(t) = \left| \hat{y}_{reg}(\mathbf{x}) - \hat{y}_{reg}\left(\mathbf{x}_{\setminus m}^{[t,t+w)}\right) \right| + \left| p_{(1)}(\mathbf{x}) - p_{(1)}\left(\mathbf{x}_{\setminus m}^{[t,t+w)}\right) \right|, \tag{31}$$

其中 $p_{(1)}$ 为遮蔽前预测类别的概率。第一项反映强度的变化，第二项反映对原判断的动摇程度。对主导模态取 $\mathrm{Imp}_m(t)$ 最大的若干帧作为关键证据帧，再经 L0 回指到原文词组或词级锚点。解释层的参数见表27。

表 27　解释层的主要参数

参数	设置
模态遮蔽方式	与训练时的缺失注入一致：语音、视觉置零，语言替换为 `[UNK]` 向量
候选帧范围	文本 $[1, L)$；语音、视觉 $t < L_m$
窗口宽度 w、证据帧数 k、稳定性检验噪声强度	【待填：从配置文件抄录】

9.5 为什么不用注意力，以及融合层的等价重写

式 (11)(12) 中的 α、β 看上去就是现成的“解释”：它告诉我们语言的每个词关注了语音、视觉的哪些帧。但文献[7]的实验表明，注意力权重与预测的因果贡献并不必然一致，换一组差别很大的注意力分布，预测可以几乎不变。所以本文的结论全部来自扰动实验，注意力只做两件事：为片段扫描提供候选，以及与扰动结果做交叉检验。

即便只用来交叉检验，也得先把注意力取出来，这里遇到了一个工程问题。融合层使用的是 PyTorch 的 `TransformerDecoderLayer`，它内部调用注意力时设置了 `need_weights=False`，即使挂上前向钩子，拿到的也只是 `None`。我们用显式的解码层重写了 `CrossModalFusion`，子模块命名与官方实现完全一致，因此可以直接加载原来训练好的参数。为了证明重写后的层与原层等价，做了三项检查，见表28。

表 28　重写融合层的等价性检查

检查项	结果
与原层的输出差异	最大绝对差 4.77×10^{-7}（float32 舍入量级）
`state_dict` 键名	完全不变，原检查点可直接加载
开启注意力输出对预测的影响	逐元素相等，$\max \lvert\Delta \hat{y}_{reg}\rvert = 0$

做这三项检查的原因很简单：可解释性分析报告的必须是真正在用的那个模型，而不是一个行为略有不同的近似副本，否则“解释”和“预测”就对不上了。

9.6 解释质量的量化检验

解释本身也需要被检验。我们用三个指标衡量解释的质量，结果见表29。

- **忠实性比值**：遮蔽重要性最高的 k 个证据帧所引起的预测变化，除以遮蔽 k 个随机有效帧所引起的预测变化。比值越大，说明挑出来的证据确实比随便挑的帧更重要。
- **稳定性**：对输入加入微小噪声后重新计算重要性曲线，与原曲线的 Spearman 秩相关系数。越接近 1，说明解释不会因为微小扰动而大幅改变。
- **充分性偏移**：只保留重要性最高的 3 帧、遮蔽其余帧时，预测相对原预测的偏移量。越小说明少数证据帧就足以支撑原判断。

表 29　解释质量指标

指标	数值	含义
忠实性比值	2.88	遮蔽 top-k 证据造成的预测变化是随机帧的 2.88 倍
稳定性（Spearman）	0.9973	输入加噪后重要性曲线几乎不变
充分性偏移	0.7068	只保留 top-3 帧时预测的偏移量

前两项的结果比较理想：挑出的证据明显比随机帧重要，而且解释很稳定。第三项则提醒我们，只留 3 帧时预测偏移了 0.7068，说明少数几帧并不足以单独支撑判断，模型依赖的信息是分散在整句中的。这与第8.8节看到的语言高冗余是一致的。所以对文本证据更准确的读法是“模型最依赖的区域”，而不是“决定情感的那几个词”。

9.7 三模态作用差异

在验证集的 192 条样本上统计模态作用程度，结果见表30。

表 30　验证集（$n = 192$）上的三模态作用程度

	文本	语音	视觉
平均作用程度 $\bar{s}_m$	**0.871**	0.049	0.080
作为主导模态的样本占比	**92%**	4%	5%

注：占比经四舍五入，合计略超 100%。

这是我们最看重的一次交叉验证。干预式归因是在单个样本上做的，第8.3节的模态消融是在整个数据集上重新评测的，两条技术路线完全不同，却给出了同一个答案：语言是主导。这说明归因的口径是可信的。

表中还有一个值得注意的细节：视觉的平均作用程度（0.080）高于语音（0.049），可模态消融里去掉语音的损失（F1 -3.1）反而比去掉视觉（$+2.5$）大。两者并不矛盾。作用程度衡量的是“遮掉之后输出变了多少”，并不区分变得更准还是更差；视觉让输出变动较多，但这种变动未必朝着正确的方向，去掉视觉后 F1 略升也说明它带来的一部分是噪声。

9.8 典型样本的解释

图14展示了测试集中的几条样本。左图是第 0 号样本三个模态的片段重要性曲线，横轴是帧号（即词元序号），竖线标出了各模态的关键证据帧；中图是第 0 ～ 5 号样本的模态作用程度；右图是这 6 条样本各模态的 Δ^{cls}。

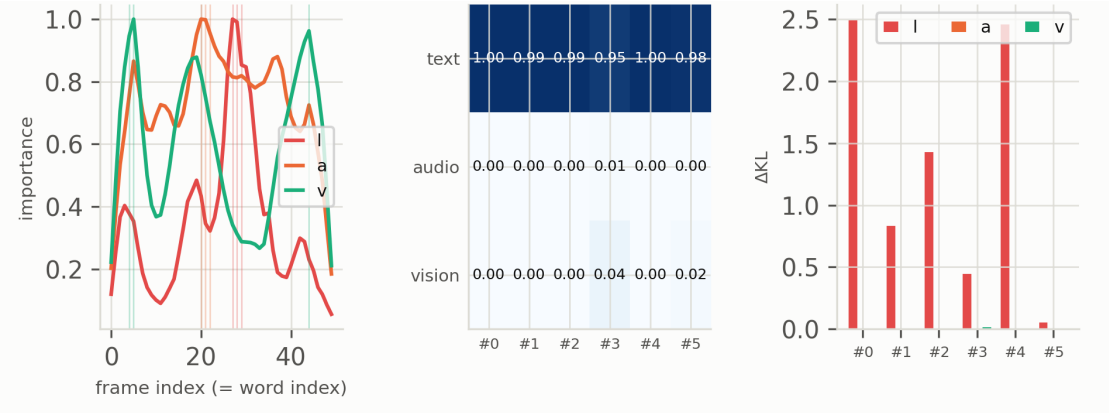


图 14　测试样本的解释结果。左：第 0 号样本的片段重要性（l、a、v 分别为文本、语音、视觉）；中：第 0 ～ 5 号样本的模态作用程度 s_m；右：各模态遮蔽后的 Δ^{cls}

从中图看，6 条样本的文本作用程度都在 0.95 以上；语音、视觉只在第 3 号（视觉 0.04、语音 0.01）和第 5 号（视觉 0.02）样本上有一点份额。右图说明文本主导的强弱在样本之间差别很大：第 0 号和第 4 号遮掉文本后 Δ^{cls} 接近 2.5，第 5 号只有 0.05 左右，尽管后者的文本作用程度也有 0.98。这正是需要同时看作用程度和绝对效应量的原因：作用程度是相对值，只说明“谁更重要”，而 Δ^{cls} 说明“整体有多重要”。

左图中文本的重要性在第 27 ～ 29 帧附近出现尖峰，这几帧就是该样本的文本关键证据，回指后即为对应位置的原文词组。

题目要求的解释卡包含预测结果、三模态作用程度、主要参考模态和关键证据定位。以附件 4 中可在附件 2 找回真值的第 12 号样本为例，解释卡如表31所示。

9.9 附件 4 的预测与解释结果

附件 4 的 20 条样本三模态完整，按与附件 2 相同的预处理送入网络，每条输出极性、强度、三模态作用程度、主导模态及裕度、关键证据帧和回指词组。结果分布见图15，逐条结果见附录附录 E，完整解释卡存于 attachment4_explanations.json。

20 条样本的主导模态全部是文本，判定裕度均大于 0.15，也就是说模型对

表 31　解释卡示例：附件 4 第 12 号样本

字段	内容
预测极性	Negative （负向）；附件 2 中的真值同为 Negative
预测强度	-1.114；真值 -0.667
主要参考模态	文本；判定裕度 $\mu =$ **【待填：见 json】**
三模态作用程度	$s_l =$ **【待填：见 json】**，$s_a =$ **【待填：见 json】**，$s_v =$ **【待填：见 json】**
文本关键证据	“an individual previously”（词元位置 **【待填：见 json】**）
语音、视觉锚点	与文本证据同位置的帧，相对位置 $t/L_m =$ **【待填：见 json】**
复核方法	按帧号取 `input_ids`，用 `tokenizer.decode` 还原原文；在原始视频中找到说出该词组的时刻，回看对应的语音与表情

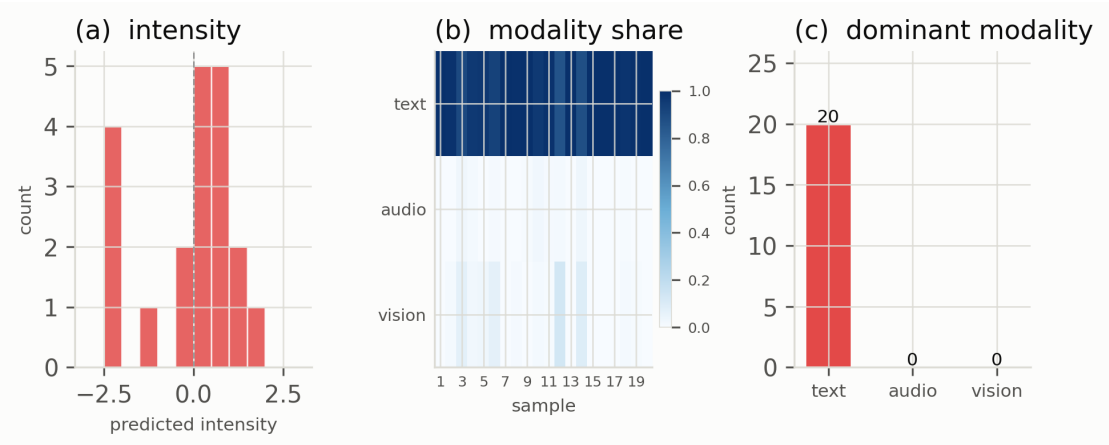


图 15　附件 4 推理结果：(a) 预测强度分布；(b) 各样本的模态作用程度；(c) 主导模态统计

每条样本都有明确的模态偏好。视觉在个别样本上占到了一定比例（图15(b) 中的浅色格），但都没有达到主导。预测强度的分布偏向两端，有 4 条落在−2以下的强负向区间。

附件 4 没有标签，但其中 5 条可以按编号在附件 2 里精确找回真值，可以当作一个很小的检验集，结果见表32。

表 32　附件 4 中可找回真值的 5 条样本

样本	预测极性	真值极性	预测强度	真值强度	文本关键证据
03	Negative	Negative	−0.402	−0.333	“justwest don”
07	Positive	Positive	+0.946	+0.667	“topics growing hobby”
08	Positive	Positive	+0.827	+0.333	“to tonight ,”
12	Negative	Negative	−1.114	−0.667	“an individual previously”
15	Positive	Positive	+1.379	+1.000	“their , transform”

5 条样本的极性全部判对，强度 MAE 为 0.3334。

9.10 错误归因

（1）强度被系统性放大。表32中 5 条样本的预测强度，绝对值全部大于真值，平均高出约 0.33，强度 MAE 几乎全部来自这种同方向的偏差，例如 08 号预测+0.827，真值只有+0.333。样本只有 5 条，还不能下定论，但方向一致这一点值得重视。一种可能的解释是：真值是多名标注者的平均，标注者意见不一时平均值会被拉向 0，而模型学到的是“这类说法通常有多强”。如果这个偏差在验证集上也成立，可以在验证集上拟合一个斜率小于 1 的线性校准来修正。

（2）文本证据不一定是“情感词”。表32的证据里有标点和虚词（“to tonight ,”、“their , transform”），也有不完整的词形（“justwest don”，BERT 按子词切分，回指出来的可能是半个词）。这和上文充分性偏移的结论一致：文本帧是上下文表示，遮掉一个窗口去掉的不只是这几个词本身，还有它们承载的上下文信息。因此文本证据应当理解为“模型最依赖的位置”，阅读时最好结合前后文。

（3）语音、视觉的证据只能到词级。数据中没有逐词时间戳，我们给出的是词级锚点和相对位置，不是绝对秒数。这是数据本身的限制，我们没有用

“平均词长乘总时长”去凑一个秒数，因为那样得到的数字无法复核。

（4）解释暴露了模型对文本的高度依赖。92% 的样本以文本为主导，这是模型的真实行为，解释如实反映了它。反过来说，如果某条样本的转写文本有错，模型很可能跟着出错，而这类样本的解释卡会显示“文本主导”，读者据此就能意识到应当先核对转写。这也是可解释性在实际使用中的价值所在。

9.11 小结

问题三在不改动网络的前提下，用“干预 + 回指”的方式给出了可量化、可复核的解释：模态作用程度由遮蔽后的输出变化归一化得到，关键证据由滑动窗口扫描定位，再借助帧—词元对应还原到原文。忠实性比值 2.88、稳定性 0.9973 说明解释是可靠的；单样本归因与整体消融两条独立路线得到同一个结论，互相印证了口径的可信度。主要的不足在于语音、视觉只能定位到词级，以及模型存在放大情感强度的倾向。

10. 模型评价

10.1 模型的优点

1. **三种对齐共用一个算子、一个接口。**问题一的三种方案只在“时间轴怎么定义”上不同，输出形状完全一致，下游可以直接切换；其中口径 H 复刻了附件 2 的词级对齐，每个位置都能回指到原文的词。
2. **有效时段的判据更贴合情感表达。**说话者人脸跟踪方案以“说话者的脸是否可见”划定有效时段，既剔除了无人时段，又保留了不说话时的表情；按声音判定只剩 32% 的时长，而该判据平均保留 93%，语音、视觉非零位置分别为 48.0 和 47.5。
3. **先查数据，再定方法。**建模前逐帧核查了附件 2—附件 4，发现训练数据与专项测试集的缺失形态根本不同，并据此改写了缺失模拟方式。仅这一项（M1）不改网络结构，就让段缺失 F1 提升了 9.4 个点。同一轮核查还确认了帧与词元的一一对应，为问题三的精确回指打下了基础。
4. **模块去留由数据决定。**我们为局部连续缺失准备了 5 个候选模块，按统一掩码逐级叠加筛选，最终只保留 2 个。被淘汰模块的结果和筛选过程中走过的弯路（在坏配置上叠加导致一轮结果作废）都完整保留在正文中。
5. **改进落在最难的情形上。**LDSD-Seg 在长段缺失上的 MAE 降幅（0.066）大于整体（0.047），验证集上完整模态与段缺失之间的 F1 落差由 15.6 个点缩小到 0.1 个点，鲁棒性的提升不是靠容易样本刷出来的。
6. **规律分析有自检。**三因子扫描前设置了“语言全缺必须最差”的校验项，靠

它发现并修正了两处会导致错误结论的设计问题，避免了把 bug 当成发现写进报告。

7. **解释对得上、查得到。**解释层不改网络，融合层重写后与原层的最大输出差为 4.77×10^{-7}；文本证据精确回指到词元，可当场人工核对；忠实性、稳定性两项指标表现良好，单样本归因与整体消融两条路线的结论一致。

10.2 模型的缺点

1. **问题一的对齐依赖“词匀速发音”近似。**方法一、二在没有逐词时间戳的情况下按均匀发音给词元分配时刻，语速变化大时会有词级误差；方法三的说话者身份靠人脸面积匹配，面积比阈值 0.4 是经验值，没有逐样本自适应。
2. **对齐质量没有在下游任务上检验。**问题一的语音、视觉特征与附件 2 不在同一个特征空间，附件 1 又只有 100 条，我们只用非零位置数等结构指标评价了三种方案，没有比较它们对情感预测的实际影响；视觉特征也只用了人脸几何与像素统计量，对细微表情的刻画偏粗。
3. **语音、视觉证据只能定位到词级。**数据没有逐词时间戳，本文没有利用附件 4 的原始视频做语音—文本强制对齐，因此给不出秒级的语音时段和视觉关键帧。
4. **“重建有益”只得到部分复现。**在整模态缺失下，去掉重建或去掉 AHL 后 MAE 反而略好。本文给出了可能的解释，但由于时间有限，没有设计专门的实验去验证。
5. **结果多为单次运行。**同一个 M1+M4 配置在筛选实验与确认实验中的段缺失 F1 相差约 1.5 个点，说明存在运行间波动，而本文没有做多随机种子重复、也没有给出置信区间。
6. **训练轮数没有调优。**验证曲线显示模型在训练中后期出现过拟合，固定训练 200 轮并非最优，本文没有系统比较早停的效果。
7. **专项测试集缺少标签。**附件 3、4 的可信度只能借助附件 2 上的表现间接判断；强度被放大的现象只在附件 4 的 5 条可找回样本上观察到，样本太少。

10.3 改进方向

针对上面的不足，后续可以从几个方面改进。第一，引入语音识别与强制对齐工具，得到逐词时间戳。这一步能同时改进两处：问题一的方法一、二不再依赖“词匀速发音”的近似；问题三的词级锚点可以换算成秒级的语音时段和视频关键帧，证据定位直接落到原始素材上。视觉方面，可以在人脸框内再接一个面部动作单元或表情特征提取器，补足对细微表情的刻画。第二，按验证集指标早停，并用多个随机种子重复主要实验，报告均值和区间，让小幅差

异的比较更有依据。第三，在验证集上检查强度放大是否普遍存在，若存在则拟合线性校准。第四，模型对文本的依赖过重，一旦转写出错就容易被带偏，可以在训练时提高文本连续段缺失的比例，迫使模型更多地利用语音和视觉；中段缺失改善最小的原因也值得进一步分析。

参考文献

[1] Zadeh A B, Liang P P, Poria S, et al., Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph, Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Melbourne: Association for Computational Linguistics, 2236-2246, 2018.

[2] Zadeh A, Chen M, Poria S, et al., Tensor fusion network for multimodal sentiment analysis, Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, Copenhagen: Association for Computational Linguistics, 1103-1114, 2017.

[3] Liu Z, Shen Y, Lakshminarasimhan V B, et al., Efficient low-rank multimodal fusion with modality-specific factors, Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Melbourne: Association for Computational Linguistics, 2247-2256, 2018.

[4] Tsai Y H H, Bai S, Liang P P, et al., Multimodal transformer for unaligned multimodal language sequences, Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, Florence: Association for Computational Linguistics, 6558-6569, 2019.

[5] Zhang S, Yang Y, Chen C, et al., Deep learning-based multimodal emotion recognition from audio, visual, and text modalities: A systematic review of recent advancements and future prospects, Expert Systems with Applications, 237:121692, 2024.

[6] Shi P, Wang J, Zhang X, Language-dominated fusion and self-distillation for multimodal sentiment analysis with incomplete modalities, Pattern Recognition, 172: 112644, 2026.

[7] Jain S, Wallace B C, Attention is not explanation, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Minneapolis: Association for Computational Linguistics, 3543-3556, 2019.

[8] Devlin J, Chang M W, Lee K, et al., BERT: Pre-training of deep bidirectional transformers for language understanding, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Minneapolis: Association for Computational Linguistics, 4171-4186, 2019.

[9] McFee B, Raffel C, Liang D, et al., librosa: Audio and music signal analysis in python, Proceedings of the 14th Python in Science Conference, Austin, 18-24, 2015.

[10] Davis S, Mermelstein P, Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences, IEEE Transactions on Acoustics, Speech, and Signal Processing, 28(4):357-366, 1980.

[11] Wu W, Peng H, Yu S, YuNet: A tiny millisecond-level face detector, Machine Intelligence Research, 20(5):656-665, 2023.

[12] Degottex G, Kane J, Drugman T, et al., COVAREP: A collaborative voice analysis repository for speech technologies, 2014 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Florence: IEEE, 960-964, 2014.

[13] Hazarika D, Zimmermann R, Poria S, MISA: Modality-invariant and -specific representations for multimodal sentiment analysis, Proceedings of the 28th ACM International Conference on Multimedia, Seattle: ACM, 1122-1131, 2020.

[14] Yu W, Xu H, Yuan Z, et al., Learning modality-specific representations with self-supervised multi-task learning for multimodal sentiment analysis, Proceedings of the AAAI Conference on Artificial Intelligence: volume 35, 10790-10797, 2021.

[15] Yuan Z, Li W, Xu H, et al., Transformer-based feature reconstruction network for robust multimodal sentiment analysis, Proceedings of the 29th ACM International Conference on Multimedia, Chengdu: ACM, 4400-4407, 2021.

[16] Zhang H, Wang W, Yu T, Towards robust multimodal sentiment analysis with incomplete data, Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Vancouver: Curran Associates, 2024.

[17] Zhang H, Wang Y, Yin G, et al., Learning language-guided adaptive hyper-modality representation for multimodal sentiment analysis, Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, Singapore: Association for Computational Linguistics, 756-767, 2023.

[18] Tarvainen A, Valpola H, Mean teachers are better role models: Weight-averaged

consistency targets improve semi-supervised deep learning results, Advances in Neural Information Processing Systems 30 (NIPS 2017), Long Beach: Curran Associates, 1195-1204, 2017.

[19] Hinton G, Vinyals O, Dean J, Distilling the knowledge in a neural network, arXiv preprint arXiv:1503.02531, 2015.

[20] Sundararajan M, Taly A, Yan Q, Axiomatic attribution for deep networks, Proceedings of the 34th International Conference on Machine Learning, Sydney: PMLR, 3319-3328, 2017.

附录 A 支撑材料与运行环境

A.1 支撑材料清单

表33列出了随论文提交的支撑材料。

表 33　支撑材料清单

类别	文件
问题一代码包	q1_code_package/：step1_extract （方法一）、step1_time50 （方法二）、step1_vad50 （方法三）、eval （评估与可视化），含 README 与 requirements.txt
问题一模型权重	models/bert-base-uncased、models/yunet/face_detection_yunet_2023mar.onnx
问题一特征文件	三种方案各 100 个 .npz，目录见第5.4节
附件 1 汇总脚本	tools/make_q1_table.py （由 .npz 生成附录附录 C的全量汇总表）
建模 Notebook	ldsd_notebook.ipynb （69 个单元格，15 节），可在 Kaggle 上一键运行
数据核查 Notebook	audit_notebook.ipynb
模型参数	ldsd_main.pt （9.08 MB） ldsd_segment.pt （10.16 MB） ablation_models.pt （78.49 MB，9 个消融模型打包）
预测与解释	attachment3_predictions.csv，attachment3_explanations.json attachment4_predictions.csv，attachment4_explanations.json
实验脚本	exp_segment.py （候选模块筛选），exp_factors.py （三因子扫描）
绘图脚本	make_architecture_fig.py，make_charts.py
结果表	summary_all.csv，robustness.csv，factor_scan_agg.csv 等共 12 份

A.2 运行环境与运行说明

问题一。在本地 Windows 环境运行，只需 CPU。

- 环境：Python 3.10 （conda 环境），PyTorch 使用 CPU 版，其余依赖按 requirements.txt 安装；librosa、OpenCV、transformers、ffmpeg 的版本号为

【待填：按 requirements.txt 填写】。

- 必设环境变量：`KMP_DUPLICATE_LIB_OK=TRUE`（避免 OpenMP 重复加载导致崩溃）、`PYTHONIOENCODING=utf-8`（中文输出不乱码）；数据不在默认位置时另设 `DATA_ROOT`。
- 运行方式：分别进入 step1_extract、step1_time50、step1_vad50 目录执行 `python main.py`（加 `--limit 3` 可先调试前 3 条），三种方案跑完后在 eval 目录执行 eval_align.py 得到表7，执行 visualize_sample.py 得到典型样本图；最后运行 tools/make_q1_table.py 生成附录附录 C的汇总表。
- 随机种子：SEED = 2026。

问题二、三。全部实验在 Kaggle 提供的 GPU 环境上完成，全量运行总耗时 7772.6 s（约 2.16 h）。

- 软件版本：Python、PyTorch、transformers 的版本为 **【待填：按运行环境填写】**；文本编码器为 bert-base-uncased。
- 运行入口：ldsd_notebook.ipynb 按顺序执行即可复现全部结果；数据上传、BERT 依赖、运行方式和各步耗时见 README.md 中的“Kaggle 全量运行指南”。
- 随机种子：**【待填：填写实际使用的随机种子】**。固定随机种子是为了保证结果可复现。
- 数据处理规则：有效长度在标准化之前从原始特征计算（式 (7)）；语音、视觉使用训练集统计量标准化（式 (8)）；附件 3 的文本由 text_bert 经 bert-base-uncased 重建。

附录 B 核心算法伪代码

算法 1 说话者人脸跟踪与有效时段对齐（问题一方法三）

输入： 视频片段（时长 D），三路帧级特征，$\kappa = 0.4$

输出： 对齐后的 text、audio、vision （各 50 个位置）

计算语音短时能量 e_j，$e_j \geq 0.05 \max e$ 判为语音帧；剔除短于 0.15 s 的语音段，填补短于 0.25 s 的静音间隙
在“语音帧且检测到人脸”的帧中取面积最大的人脸，记典型面积 A_s
for 每个视频帧 τ **do**
    $v(\tau) \leftarrow \mathbb{1}[\text{检测到人脸} \wedge A(\tau) \geq \kappa A_s]$
end for
if $v \equiv 0$ **then**
    退化为全程 50 等分（方法二）并返回
end if
拼接可见时段得 $\varphi(\tau) = \int_0^\tau v$，$D_{eff} = \varphi(D)$，锚点 $a_k = kD_{eff}/49$
三路只保留可见时段内的帧（词元按均匀发音取时刻），时间戳映射为 $\varphi(\tau_i)$
按式 (1) 把三路特征重采样到 $a_0, \ldots, a_{49}$
return text $(50, 768)$，audio $(50, 74)$，vision $(50, 35)$

算法 2 连续段缺失掩码生成（M1）

输入： 序列长度 T，缺失率 r，Dirichlet 浓度 0.6

输出： 缺失掩码 $M \in \{0, 1\}^T$

$M \leftarrow \mathbf{0}$；抽取段数 $k \sim \mathcal{U}\{1, 2, 3\}$
抽取段长比例 $(\rho_1, \ldots, \rho_k) \sim \text{Dirichlet}(0.6 \cdot \mathbf{1}_k)$
将 $[0, T)$ 划分为 k 个互不相交的区块 $B_1, \ldots, B_k$
for $j = 1$ **to** k **do**
    $\ell_j \leftarrow \max\left(1, \lfloor \rho_j \, rT \rfloor\right)$
    在区块 B_j 内选取起点 a_j，使 $[a_j, a_j + \ell_j)$ 落在 B_j 中
    $M[a_j : a_j + \ell_j] \leftarrow 1$
end for
return M

算法 3 干预式模态归因与片段扫描（问题三）

输入： 样本 $\mathbf{x}$，训练好的网络 f，窗口宽度 w，证据帧数 k

输出： 作用程度 s_m，主导模态 m^*，裕度 μ，关键证据

计算原始输出 $\hat{y}_{reg}(\mathbf{x})$、$p(c\,|\,\mathbf{x})$
for $m \in \{l, a, v\}$ **do**
    按训练时的缺失注入方式整条遮蔽模态 m，得到 $\mathbf{x}_{\setminus m}$
    按式 (28)(29) 计算 Δ_m^{reg}、Δ_m^{cls}
end for
按式 (30) 计算 s_m、m^*、μ
for $m \in \{l, a, v\}$ **do**
    for 有效帧 t（文本 $t \in [1, L)$，语音、视觉 $t < L_m$） **do**
        遮蔽模态 m 的窗口 $[t, t + w)$，按式 (31) 计算 $\mathrm{Imp}_m(t)$
    end for
end for
取主导模态中 Imp 最大的 k 帧，经帧—词元对应回指为原文词组或词级锚点
return 解释卡

附录 C 附件 1 全量特征提取结果

下表由 tools/make_q1_table.py 读取三种方案的 .npz 文件后生成（results/q1_summary.csv）。所有样本的特征维度均为 text $(50, 768)$、audio $(50, 74)$、vision $(50, 35)$；对齐粒度方法一为词级，方法二、三为 50 个时间桶。表头含义：dur 为片段时长（s），L_txt 为有效词元数，eff_s 与 eff_ratio 为方法三的有效时长与占比，n_seg 为说话段数，nzA/nzV 为语音 / 视觉非零位置数，后缀 H、T50、V50 分别对应方法一、二、三。

【待填：运行 tools/make_q1_table.py 生成 results/q1_summary.csv 后重新编译，这里会自动生成 100 条样本的汇总表】

附录 D 附件 3 全量预测结果

下表由 results/attachment3_predictions.csv 自动生成。

【待填：把 attachment3_predictions.csv 放到 results/ 目录后重新编译，这里会自动生成 30 条样本的全量结果表】

附录 E 附件 4 全量预测与解释结果

下表由 results/attachment4_predictions.csv 自动生成，完整解释卡见 attachment4_explanations.json。

【待填：把 attachment4_predictions.csv 放到 results/ 目录后重新编译，这里会自动生成 20 条样本的全量结果表】